

ANÁLISE COMPARATIVA ENTRE BANCOS DE DADOS RELACIONAIS E NÃO RELACIONAIS: UM ESTUDO PRÁTICO COM POSTGRESQL E MONGODB

Amanda Gundim Ribeiro

Cristhiny Vitória Marques de Souza

O crescente volume, variedade e complexidade dos dados no contexto organizacional e industrial têm impulsionado o uso de diferentes abordagens de armazenamento e gerenciamento da informação. Nesse cenário, destacam-se os bancos de dados relacionais e não relacionais, cada um com características específicas que influenciam sua aplicação. Este trabalho tem como objetivo desenvolver e analisar, de forma prática, implementações utilizando PostgreSQL e MongoDB, a fim de compreender suas diferenças em termos de modelagem, organização, manipulação e desempenho dos dados. A metodologia adotada envolve a construção de estruturas de dados em ambos os modelos, bem como a execução de operações de consulta, inserção e análise das informações. Como resultado, busca-se identificar as vantagens, limitações e contextos mais adequados para a utilização de cada um dos modelos.

Palavras-chave: Banco de dados relacional; Banco de dados não relacional; PostgreSQL; MongoDB; Modelagem de dados; Análise de dados.

1. Introdução

Na atual *Analytics Economy*, os dados consolidaram-se como a principal fonte de vantagem competitiva e o ativo intangível mais valioso do mundo dos negócios (Lima e Redaelli, 2023). No contexto da Indústria 4.0, as organizações enfrentam um ambiente de total transparência operacional, onde operações robotizadas e sensores produzem volumes massivos de dados captados em tempo real (Guerreiro *et al.*, 2023). Nesse cenário, a capacidade de competir depende da agilidade com que a empresa analisa esses dados para implementar ações estratégicas (Lima; Redaelli, 2023). O profissional de Engenharia de Produção (EP), inserido nesse ecossistema, necessita de autonomia analítica para reconhecer a importância estratégica dos dados e utilizar ferramentas quantitativas para tomar as melhores decisões (Lima; Redaelli, 2023).

O acesso direto ao Banco de Dados (BD) justifica-se pela necessidade de eliminar a "névoa de incerteza" por meio de informações on-line e instantâneas, permitindo que o gestor identifique e solucione problemas atempadamente (Laudon; Laudon, 2015), (Lampeão; Santana, 2020). Empresas com maior maturidade analítica não se limitam a resolver problemas localizados, mas integram dados de fontes internas e externas para gerar insights que influenciam toda a cadeia de valor (Lima; Redaelli, 2023). Assim, o acesso direto aos dados permite ao EP transcender a análise descritiva do passado, avançando para a análise preditiva e prescritiva, fundamentais para a otimização de processos e antecipação de desdobramentos futuros (Lima; Redaelli, 2023).

Diante desse contexto, justifica-se a realização deste estudo pela necessidade de compreender as diferenças estruturais, funcionais e de desempenho entre os modelos de banco de dados relacional e não relacional, especialmente em cenários que envolvem grande volume e diversidade de dados. A análise comparativa entre essas abordagens torna-se relevante para subsidiar a escolha mais adequada de tecnologias conforme as demandas específicas de sistemas de informação. Assim, o presente trabalho tem como objetivo desenvolver e analisar implementações utilizando PostgreSQL e MongoDB, evidenciando suas características, formas de modelagem, organização e manipulação dos dados, a fim de avaliar suas aplicações e identificar, de forma fundamentada, a abordagem mais adequada ao contexto proposto.

2. Referencial Teórico

2.1. SISTEMAS DE INFORMAÇÃO GERENCIAIS (SIG)

A base dos sistemas de informação modernos reside no pensamento sistêmico, um paradigma científico que permite analisar fenômenos como um todo coerente, focando nas interações entre as partes em vez de apenas na soma de elementos isolados (Lima; Redaelli, 2023). No âmbito empresarial, a organização é vista como um sistema vivo composto por subsistemas integrados (institucional, social, organizacional, de gestão, de informação e operacional), onde a visão sistêmica atua como a "quinta disciplina" fundamental para compreender inter-relacionamentos e padrões de mudança (Guerreiro *et al.*, 2023; Eyng; Reis, 2008).

Para apoiar os diferentes níveis hierárquicos, as empresas utilizam diversos tipos de SI:

- Sistemas de Processamento de Transações (SPT): Registram as atividades rotineiras no nível operacional. (Laudon; Laudon, 2015).
- Sistemas de Informação Gerenciais (SIG): Fornecem relatórios de desempenho para monitoramento e controle pela gerência média (Laudon; Laudon, 2015).
- Sistemas de Apoio à Decisão (SAD): Combinam dados e modelos analíticos para suportar decisões semi estruturadas e não estruturadas (Laudon; Laudon, 2015).
- Sistemas de Apoio ao Executivo (SAE): Auxiliam o nível estratégico com recursos gráficos avançados para decisões de longo alcance (Laudon; Laudon, 2015).

Esses sistemas sustentam o ciclo dado → informação → conhecimento. Os dados são sequências de fatos brutos representativos de eventos (Lima; Redaelli, 2023). A informação surge quando esses dados são processados e moldados em um formato significativo e útil para seres humanos (Laudon; Laudon, 2015). Por fim, o conhecimento é a consciência e compreensão de um conjunto de informações e de como elas podem ser aplicadas para apoiar tarefas específicas ou decisões (Lampeão; Santana, 2020).

2.1.1 Governança e Tecnologia da Informação

A governança de Tecnologia da Informação (TI) refere-se ao conjunto de estruturas, práticas e processos responsáveis por assegurar que os recursos de TI estejam alinhados aos objetivos estratégicos da organização, promovendo a geração de valor e a mitigação de riscos (Laudon; Laudon, 2015; Weill; Ross, 2004). Nesse contexto, a governança estabelece diretrizes para a tomada de decisão, definição de responsabilidades e controle sobre os ativos tecnológicos.

De acordo com frameworks amplamente utilizados no mercado, como o COBIT e o ITIL, a governança de TI envolve aspectos relacionados à gestão de riscos, conformidade, segurança da informação e avaliação de desempenho dos sistemas (Isaca, 2012). Esses elementos são

essenciais para garantir que os dados coletados, armazenados e processados pelos sistemas de informação sejam confiáveis, seguros e utilizados de forma estratégica pelas organizações.

2.2 ARQUITETURAS DE SOFTWARE

A arquitetura de software é a decomposição de alto nível de um sistema em suas partes e a definição de como elas interagem (Fowler *et al.*, 2007). Entre os modelos citados nas fontes, destacam-se:

- **Arquitetura em Camadas (Layered Architecture):** É uma das técnicas mais comuns, onde o sistema é dividido em subsistemas dispostos como "camadas de um bolo". Cada camada repousa sobre uma inferior e ignora a existência das superiores. As três camadas principais em aplicações corporativas são: Apresentação (interface com o usuário), Domínio (lógica de negócio) e Fonte de Dados (comunicação com bancos de dados e outros sistemas) (Fowler *et al.*, 2007).
- **Clean Architecture (Arquitetura Limpa):** Baseia-se na Regra de Dependência, que estabelece que as dependências de código-fonte devem apontar apenas para dentro, em direção às políticas de alto nível (regras de negócio) (Fowler *et al.*, 2007). As camadas externas (como a UI e o Banco de Dados) são consideradas mecanismos ou detalhes que dependem das camadas internas (políticas) (Fowler *et al.*, 2007). Isso torna o sistema independente de frameworks e testável sem elementos externos (Martin, 2018)
- **Arquitetura Hexagonal (Ports and Adapters):** Diferente da visão assimétrica de camadas, este modelo enxerga o sistema como um núcleo cercado por interfaces para sistemas externos, tratando tudo que é externo como uma interface de entrada ou saída (Fowler *et al.*, 2007)
- **Arquitetura Cliente-Servidor:** Pode ser de duas camadas (onde o cliente detém a interface e o servidor o banco de dados) ou multicamadas (N-camadas), que distribui o processamento entre clientes, servidores de aplicação e servidores de banco de dados para melhor escalabilidade (Fowler *et al.*, 2007).

A separação em camadas proposta pelas arquiteturas modernas, como *Clean Architecture* e arquitetura hexagonal, permite que o banco de dados seja tratado como uma camada de infraestrutura desacoplada das regras de negócio. Nesse modelo, o sistema não depende diretamente de um SGBD específico, mas sim de abstrações, o que favorece flexibilidade tecnológica, testabilidade e manutenção. Essa abordagem é particularmente relevante no

contexto deste trabalho, que compara diferentes paradigmas de banco de dados, permitindo analisar como diferentes soluções podem ser integradas sem comprometer a lógica central da aplicação.

2.3 INFRAESTRUTURA DE BANCO DE DADOS


2.3.1 Sistemas de Gestão de Banco de Dados (SGBD)

A infraestrutura de dados refere-se às tecnologias de armazenamento, gestão e análise necessárias para operar o negócio (Fowler *et al.*, 2007).

- Sistemas de Gestão de Banco de Dados (SGBD):
 - Relacionais (RDBMS): Organizam os dados em tabelas bidimensionais com linhas e colunas, utilizando a linguagem SQL para manipulação. São o padrão para a maioria das aplicações corporativas modernas (Fowler *et al.*, 2007)
 - Não Relacionais (NoSQL): Projetados para lidar com grandes volumes de dados (Big Data) estruturados e não estruturados que seriam difíceis de analisar no modelo relacional (Laudon; Laudon, 2015)

A Figura 1 apresenta a estrutura simplificada de funcionamento de um sistema de banco de dados, evidenciando a interação entre usuários, aplicações e os mecanismos internos do SGBD.

Figura 1 – Estrutura simplificada de um sistema de banco de dados



Fonte: Elmasri e Navathe (2011).

- Computação em Nuvem (*Cloud Computing*): Define infraestruturas de TI oferecidas como serviços via internet, incluindo servidores e bancos de dados (Guerreiro *et al.*, 2023). Divide-se em:
 - Nuvem Pública: Operada por provedores terceirizados para múltiplos clientes (Laudon; Laudon, 2015).
 - Nuvem Privada: Recursos exclusivos de uma única organização, gerenciados em rede privada (Laudon; Laudon, 2015).
 - Nuvem Híbrida: Combina nuvens públicas e privadas, permitindo o compartilhamento de dados e aplicações entre elas (Laudon; Laudon, 2015)
- *Data Warehouse* e *Data Marts*: Infraestruturas voltadas para a inteligência empresarial (BI).
 - O *Data Warehouse* consolida dados atuais e históricos de diversos sistemas para análise gerencial. (Laudon; Laudon, 2015).
 - O *Data Mart* é uma subdivisão focada em uma área ou população específica de usuários (Laudon; Laudon, 2015).

Na visão da *Clean Architecture*, o banco de dados é um detalhe de infraestrutura (como uma maçaneta de uma casa) e não deve poluir a arquitetura central. Ele serve apenas como um mecanismo de utilidade para mover dados entre o disco e a memória RAM (Martin, 2018).

2.3.2 PostgreSQL como banco de dados relacional

O PostgreSQL é um Sistema de Gerenciamento de Banco de Dados Relacional (SGBDR) de código aberto amplamente utilizado em aplicações corporativas, científicas e industriais devido à sua robustez, confiabilidade e elevada capacidade de processamento de grandes volumes de dados. Fundamentado no modelo relacional proposto por Edgar F. Codd, o PostgreSQL organiza as informações em tabelas compostas por linhas e colunas, utilizando a linguagem SQL (*Structured Query Language*) para manipulação, consulta e gerenciamento dos dados (Elmasri; Navathe, 2011).

Os bancos de dados relacionais caracterizam-se pela estruturação lógica das informações em entidades inter-relacionadas, permitindo que os dados sejam armazenados de forma organizada e consistente. Nesse modelo, a utilização de chaves primárias e estrangeiras possibilita o estabelecimento de relacionamentos entre tabelas, garantindo integridade referencial e reduzindo redundâncias no armazenamento das informações. Dessa forma, entidades como clientes, produtos, ordens de produção, fornecedores e estoques podem ser organizadas de maneira estruturada, permitindo a realização de consultas complexas por meio

de operações como JOIN, agregações e filtros condicionais (Silberschatz; Korth; Sudarshan, 2019).

Além disso, o PostgreSQL possui forte aderência aos princípios de normalização de dados, favorecendo a organização lógica das tabelas e a manutenção da consistência das informações. A modelagem relacional aplicada nesse tipo de banco contribui para a construção de estruturas mais eficientes, facilitando o gerenciamento de relacionamentos entre entidades e o controle da integridade dos registros armazenados (Date, 2004).

O PostgreSQL destaca-se ainda pelo suporte às propriedades ACID (Atomicidade, Consistência, Isolamento e Durabilidade), fundamentais para aplicações que exigem elevado nível de confiabilidade transacional, como sistemas ERP, controle de estoque, gestão financeira, planejamento da produção e sistemas de manufatura. Essas propriedades asseguram que as transações ocorram de forma íntegra e segura, mesmo em cenários de falha ou múltiplos acessos simultâneos (Silberschatz; Korth; Sudarshan, 2019).

No contexto da Engenharia de Produção, bancos de dados relacionais possuem elevada relevância devido à necessidade de controle estruturado das operações, rastreabilidade de processos e integração entre diferentes setores organizacionais. A utilização do PostgreSQL possibilita ao engenheiro acessar dados diretamente da fonte operacional, realizar análises em tempo real e gerar informações estratégicas para apoio à tomada de decisão, contribuindo para maior autonomia analítica, eficiência operacional e suporte às práticas de melhoria contínua.

2.3.3 MongoDB como banco de dados não relacional

O MongoDB é um Sistema de Gerenciamento de Banco de Dados Não Relacional (NoSQL) orientado a documentos, desenvolvido para lidar com grandes volumes de dados estruturados, semiestruturados e não estruturados de maneira flexível e escalável. Diferentemente dos bancos relacionais tradicionais, o MongoDB não organiza as informações em tabelas rígidas compostas por linhas e colunas, mas sim em documentos no formato BSON (*Binary JSON*), uma extensão do JSON que permite armazenamento eficiente e maior flexibilidade na estruturação dos dados (MongoDB Inc., 2024).

Uma das principais características do MongoDB consiste no modelo *schema-less*, no qual os documentos não necessitam seguir uma estrutura fixa previamente definida. Isso permite que diferentes registros dentro de uma mesma coleção possuam atributos distintos, favorecendo ambientes dinâmicos nos quais a estrutura dos dados sofre alterações frequentes. Essa flexibilidade torna o MongoDB especialmente adequado para aplicações modernas que

demandam rápida adaptação, elevado volume de informações e integração com múltiplas fontes de dados (Banker, 2016).

Além da flexibilidade estrutural, o MongoDB destaca-se pela elevada capacidade de escalabilidade horizontal, permitindo a distribuição dos dados entre múltiplos servidores por meio de técnicas como sharding e replicação. Essa característica é particularmente importante em cenários de Big Data, nos quais grandes quantidades de dados são geradas continuamente e necessitam de processamento eficiente e alta disponibilidade (Sadallage; Fowler, 2013).

No contexto industrial e organizacional, bancos de dados não relacionais são amplamente utilizados em aplicações relacionadas à Internet das Coisas (IoT), sensores industriais, monitoramento em tempo real, registros de logs, plataformas web e sistemas de análise de dados em larga escala. Nessas aplicações, a velocidade de geração das informações e a diversidade dos formatos de dados tornam os modelos tradicionais menos eficientes, favorecendo a utilização de bancos orientados a documentos como o MongoDB (Laudon; Laudon, 2015).

No âmbito da Engenharia de Produção, o MongoDB contribui para o armazenamento e análise de grandes volumes de dados operacionais provenientes de processos automatizados, dispositivos inteligentes e sistemas integrados de manufatura. Sua flexibilidade e capacidade de escalabilidade permitem maior agilidade na coleta, armazenamento e processamento das informações, favorecendo análises em tempo real e suporte à tomada de decisão em ambientes industriais caracterizados pela elevada complexidade e dinamismo.

2.3.4 Comparação entre PostgreSQL e MongoDB

A escolha entre bancos de dados relacionais e não relacionais depende diretamente das características da aplicação, da estrutura dos dados e das necessidades operacionais da organização. Nesse contexto, PostgreSQL e MongoDB representam dois modelos distintos de armazenamento e gerenciamento de informações, cada um com vantagens, limitações e aplicações específicas. Enquanto o PostgreSQL é fundamentado no modelo relacional tradicional, priorizando consistência, integridade referencial e estruturação rígida dos dados, o MongoDB adota uma abordagem orientada a documentos, oferecendo maior flexibilidade estrutural e elevada capacidade de escalabilidade horizontal (Silberschatz; Korth; Sudarshan, 2019; Banker, 2016).

O PostgreSQL apresenta melhor desempenho em aplicações que exigem forte controle transacional, relacionamentos complexos entre entidades e elevada confiabilidade dos dados, como sistemas ERP, controle financeiro, gestão de estoque e planejamento da produção. Por

outro lado, o MongoDB mostra-se mais adequado para aplicações que demandam flexibilidade estrutural, processamento de grandes volumes de dados e rápida escalabilidade, como sistemas de IoT, monitoramento em tempo real, plataformas web, sensores industriais e análise de logs (Laudon; Laudon, 2015).

Além das diferenças estruturais, ambos os modelos apresentam vantagens e limitações específicas. Bancos relacionais oferecem maior consistência e organização lógica dos dados, porém podem apresentar menor flexibilidade em ambientes altamente dinâmicos. Em contrapartida, bancos não relacionais permitem maior adaptação estrutural e escalabilidade, embora possam apresentar limitações relacionadas à integridade referencial e à padronização das informações (Sadalage; Fowler, 2013).

A Tabela 1 apresenta uma comparação entre PostgreSQL e MongoDB, considerando aspectos relacionados à estrutura dos dados, escalabilidade, consistência, aplicações e modelagem das informações.

Tabela 1 - Comparação entre exemplos de BDs relacionais e não relacionais

Aspecto	PostgreSQL	MongoDB
Modelo de dados	Relacional	Não relacional (documental)
Estrutura	Tabelas com linhas e colunas	Documentos JSON/BSON
Linguagem	SQL	Consultas orientadas a documentos
Esquema	Rígido e previamente definido	Flexível (<i>schema-less</i>)
Relacionamentos	Chaves primárias e estrangeiras	Referências ou documentos embutidos
Consistência	Forte consistência (ACID)	Consistência eventual (BASE)
Escalabilidade	Predominantemente vertical	Horizontal
Aplicações comuns	ERP, financeiro, estoque, manufatura	IoT, Big Data, logs, aplicações web
Vantagens	Integridade, confiabilidade e organização	Flexibilidade e alta escalabilidade
Limitações	Menor flexibilidade estrutural	Menor rigidez no controle relacional

Fonte: Elaborado pelas autoras (2026)

No contexto da Engenharia de Produção, a compreensão das diferenças entre bancos relacionais e não relacionais é fundamental para a escolha adequada da infraestrutura de dados. A seleção do modelo mais apropriado depende das características do processo analisado, do volume de dados gerados e da necessidade de integração, rastreabilidade e velocidade de processamento das informações. Dessa forma, o conhecimento acerca das vantagens e limitações de cada abordagem permite maior autonomia analítica e melhor suporte às decisões organizacionais.

2.4 EVOLUÇÃO DOS BANCOS DE DADOS

A evolução dos bancos de dados pode ser compreendida a partir de diferentes fases ao longo das décadas, acompanhando o avanço das tecnologias da informação e as crescentes demandas organizacionais por armazenamento, processamento e análise de dados.

Na década de 1960, os dados eram armazenados em arquivos sequenciais, caracterizados por baixo nível de abstração e elevada dependência entre programas e estruturas de dados. Esse cenário começou a se transformar na década de 1970, com a proposição do modelo relacional por Edgar F. Codd, baseado na organização dos dados em tabelas e na utilização de fundamentos matemáticos para representação e manipulação das informações (Codd, 1970).

Durante as décadas de 1980 e 1990, o modelo relacional consolidou-se como padrão dominante nos sistemas corporativos, impulsionado pela difusão da linguagem SQL e pelo desenvolvimento de sistemas gerenciadores de bancos de dados robustos (Elmasri; Navathe, 2011; Silberschatz; Korth; Sudarshan, 2019). Esse modelo destacou-se pela capacidade de garantir integridade, consistência e organização estruturada dos dados.

A partir dos anos 2000, com o crescimento exponencial do volume de dados e a expansão das aplicações web, surgiram os bancos de dados não relacionais (NoSQL), oferecendo maior escalabilidade, flexibilidade estrutural e melhor desempenho em cenários distribuídos (Sadalage; Fowler, 2013; Banker *et al.*, 2016).

Mais recentemente, consolidou-se o conceito de polyglot persistence, no qual diferentes tecnologias de bancos de dados são utilizadas de forma complementar, de acordo com as necessidades específicas de cada aplicação (Sadalage; Fowler, 2013). Nesse contexto, a escolha entre modelos relacionais e não relacionais deixa de ser excludente, passando a ser estratégica.

2.5 MODELAGEM DE DADOS


A modelagem de dados é o processo de criação de uma representação abstrata e estruturada da realidade de um sistema de informações. Segundo Elmasri e Navathe (2011), ela atua como um mapa que define a estrutura lógica, as restrições e os relacionamentos dos dados, garantindo que o banco de dados final suporte as operações organizacionais com integridade e eficiência.

No contexto dos bancos de dados relacionais, essa representação é consolidada através do Modelo Entidade-Relacionamento (MER). Conforme descrevem Silberschatz, Korth e Sudarshan (2019), os componentes fundamentais deste modelo são:

- Entidades: Objetos com existência física (ex: funcionários, produtos) ou conceitual (ex: ordens de produção, vendas).
- Atributos: Propriedades particulares que descrevem a entidade (ex: código do produto, data de emissão).
- Relacionamentos: Associações que definem como as entidades interagem entre si (ex: um Fornecedor "fornece" um Produto).

Conforme apresentado na Figura 2, o modelo Entidade-Relacionamento permite representar entidades, atributos e relacionamentos de maneira estruturada, facilitando a visualização lógica das interações existentes entre os elementos do sistema. Além disso, a utilização das cardinalidades possibilita identificar as restrições estruturais presentes nos relacionamentos entre as entidades.

Figura 2 – Exemplo de diagrama Entidade-Relacionamento (ER)



Fonte: Adaptado de Elmasri e Navathe (2011).

A importância de uma modelagem rigorosa é enfatizada por Date (2004), que argumenta que a qualidade do projeto lógico é o que determina a viabilidade a longo prazo de um sistema. Estruturas deficientes resultam em redundâncias desnecessárias e anomalias de dados, dificultando a rastreabilidade e a evolução do software. Portanto, o MER não é apenas uma ferramenta gráfica, mas uma base para a aplicação posterior das técnicas de normalização.

Para o Engenheiro de Produção, a modelagem de dados é a ferramenta que permite transformar o fluxo físico da fábrica (entrada de matéria-prima, processamento em máquinas, saída de produto acabado) em um fluxo digital confiável. Ao modelar corretamente as interações entre logística, manutenção e qualidade, o engenheiro assegura que a base de dados reflita com precisão o estado real da planta industrial, permitindo a extração de KPIs (como o OEE) e o suporte estratégico à melhoria contínua.

2.6 NORMALIZAÇÃO DE DADOS

A normalização de dados consiste em um conjunto de técnicas aplicadas à modelagem de bancos de dados com o objetivo de organizar as informações, reduzir redundâncias e garantir

maior integridade dos dados armazenados. Esse processo busca estruturar as tabelas de forma eficiente, evitando inconsistências relacionadas à inserção, atualização e remoção de registros (Date, 2004).


A aplicação da normalização é especialmente relevante em bancos de dados relacionais, nos quais múltiplas entidades compartilham informações interdependentes. Sem uma organização adequada, a repetição de dados pode comprometer a consistência das informações e dificultar a manutenção do banco de dados (Elmasri; Navathe, 2011).

As formas normais representam níveis progressivos de organização dos dados. A Primeira Forma Normal (1FN) estabelece que os atributos devem possuir valores atômicos e indivisíveis.

A Segunda Forma Normal (2FN) estabelece que uma tabela deve estar previamente na Primeira Forma Normal (1FN) e que todos os atributos não chave devem depender integralmente da chave primária. Esse conceito é especialmente relevante em tabelas com chaves primárias compostas, nas quais podem ocorrer dependências parciais. A 2FN elimina essas dependências, garantindo que cada atributo não chave esteja relacionado à totalidade da chave primária, e não apenas a parte dela (Silberschatz; Korth; Sudarshan, 2019).

Conforme apresentado na Figura 3, a aplicação das técnicas de normalização possibilita a separação lógica das informações em entidades distintas relacionadas por meio de chaves primárias e estrangeiras, reduzindo redundâncias e favorecendo maior consistência dos dados armazenados.

Figura 3 – Exemplo de estrutura de banco de dados normalizada com relacionamentos entre entidades



Fonte: Adaptado de Database Star (2026).

No contexto organizacional, a normalização contribui para construção de bancos de dados mais eficientes, facilitando consultas, integração entre sistemas e confiabilidade das análises realizadas. Na Engenharia de Produção, sua aplicação favorece maior padronização das informações operacionais e suporte mais confiável à tomada de decisão e às práticas de melhoria contínua.

2.7 RELACIONAMENTOS ENTRE ENTIDADES


Os relacionamentos entre entidades representam as associações existentes entre diferentes elementos dentro de um banco de dados, permitindo a integração lógica das informações armazenadas. No modelo relacional, as entidades correspondem aos objetos relevantes do sistema, enquanto os relacionamentos descrevem como esses elementos interagem entre si (Elmasri; Navathe, 2011).

Esses relacionamentos são estabelecidos por meio de chaves primárias e chaves estrangeiras, responsáveis por conectar tabelas distintas e garantir a integridade referencial das informações armazenadas (Silberschatz; Korth; Sudarshan, 2019).

Entre os principais tipos de relacionamentos destacam-se os relacionamentos um para um (1:1), um para muitos (1:N) e muitos para muitos (N:N). Nos relacionamentos N:N, torna-se necessária a utilização de tabelas associativas intermediárias para organização adequada dos vínculos entre as entidades e redução de redundâncias no banco de dados (Date, 2004).

Conforme ilustrado na Figura 4, os relacionamentos entre entidades permitem estruturar logicamente as informações e integrar diferentes elementos do sistema, favorecendo maior organização e eficiência das consultas realizadas no banco de dados.

Figura 4 – Exemplos de cardinalidade em relacionamentos entre entidades



Fonte: Adaptado de Paulo Henrique Costa Carvalho (2026).

A correta definição dos relacionamentos possui papel fundamental na modelagem de dados, influenciando diretamente a organização estrutural do banco, a consistência das informações e

a eficiência das operações analíticas. No contexto da Engenharia de Produção, esses relacionamentos favorecem a integração entre setores como produção, estoque, logística e qualidade, contribuindo para maior rastreabilidade dos processos e suporte à tomada de decisão.

2.8 AGREGAÇÃO E COMPOSIÇÃO

No contexto da modelagem de dados, agregação e composição são conceitos utilizados para representar diferentes níveis de relacionamento entre entidades dentro de um sistema (Fowler *et al.*, 2007).

A agregação representa uma relação do tipo “tem um”, na qual as entidades associadas podem existir independentemente umas das outras. Um exemplo ocorre na relação entre fornecedores e pedidos de compra, em que o fornecedor continua existindo mesmo que o pedido seja removido do sistema (Elmasri; Navathe, 2011).

Já a composição representa uma relação mais forte, caracterizada pelo conceito de “parte de”, em que a existência da entidade dependente está vinculada à entidade principal. Um exemplo clássico ocorre entre ordens de produção e itens da ordem, nos quais os itens existem apenas enquanto a ordem estiver registrada no sistema (Date, 2004).

Em bancos relacionais, esses relacionamentos são implementados por meio de chaves estrangeiras e regras de integridade referencial. Já em bancos não relacionais, podem ser representados por referências entre documentos ou documentos embutidos (*embedded documents*) (Sadalage; Fowler, 2013).

A correta distinção entre agregação e composição contribui para melhor organização estrutural dos dados, maior integridade das informações e melhor desempenho das consultas. No contexto da Engenharia de Produção, esses conceitos favorecem a integração entre diferentes processos organizacionais e maior rastreabilidade das operações produtivas.

2.9 MODELAGEM DE DADOS APLICADA À ENGENHARIA DE PRODUÇÃO

A modelagem de dados aplicada à Engenharia de Produção possui papel estratégico na organização, integração e análise das informações geradas ao longo dos processos produtivos e administrativos das organizações. Em ambientes industriais cada vez mais digitalizados, a correta estruturação dos dados torna-se fundamental para garantir rastreabilidade, confiabilidade das informações e suporte à tomada de decisão baseada em dados (Lima; Redaelli, 2023).

Os sistemas produtivos modernos geram grandes volumes de informações provenientes de diferentes setores organizacionais, como produção, manutenção, qualidade, estoque, logística, compras e planejamento. Nesse contexto, a modelagem de dados permite estruturar essas informações de forma lógica e integrada, facilitando consultas, análises e compartilhamento de dados entre sistemas corporativos distintos (Laudon; Laudon, 2015).


Na Engenharia de Produção, a modelagem normalmente envolve entidades relacionadas às operações industriais, como ordens de produção, produtos, máquinas, fornecedores, clientes, estoques e indicadores de desempenho. A definição adequada dessas entidades e de seus relacionamentos possibilita maior controle operacional e melhor visualização dos fluxos de informação dentro da organização (Elmasri; Navathe, 2011).

Além da organização estrutural, a modelagem de dados favorece a construção de sistemas mais padronizados e eficientes, reduzindo redundâncias e inconsistências nas informações armazenadas. Esse processo torna-se especialmente relevante em sistemas integrados de gestão empresarial (ERP), nos quais diferentes setores compartilham informações em tempo real e dependem da integridade dos dados para execução das operações (Silberschatz; Korth; Sudarshan, 2019).

A aplicação da modelagem de dados também está diretamente relacionada às práticas da Indústria 4.0, caracterizadas pela integração entre sistemas físicos e digitais, automação industrial, Internet das Coisas (IoT) e análise de grandes volumes de dados. Sensores, dispositivos inteligentes e sistemas automatizados geram continuamente informações que precisam ser estruturadas de maneira eficiente para possibilitar monitoramento, rastreabilidade e tomada de decisão em tempo real (Guerreiro *et al.*, 2023).

Conforme apresentado na Figura 5, os ambientes industriais modernos utilizam sistemas integrados capazes de coletar, armazenar, processar e analisar grandes volumes de dados provenientes de sensores, dispositivos inteligentes e sistemas automatizados. Essas informações são posteriormente convertidas em indicadores estratégicos, *dashboards* gerenciais e suporte à tomada de decisão em tempo real.

Figura 5 – Fluxo de integração de dados na Indústria 4.0 aplicado à Engenharia de Produção



Adaptado de Arantes *et al.* (2018).

Nesse cenário, a modelagem adequada dos dados contribui para maior autonomia analítica do engenheiro de produção, permitindo acesso direto às informações operacionais e geração de indicadores estratégicos relacionados à produtividade, eficiência, qualidade e desempenho dos processos produtivos. Além disso, favorece a implementação de sistemas de *Business Intelligence* (BI), *dashboards* gerenciais e ferramentas analíticas voltadas à melhoria contínua e otimização das operações organizacionais (Lima; Redaelli, 2023).

Portanto, a modelagem de dados aplicada à Engenharia de Produção ultrapassa a simples organização técnica das informações, assumindo papel fundamental na integração dos processos organizacionais e no suporte às decisões estratégicas em ambientes industriais altamente dinâmicos e orientados por dados.

3. METODOLOGIA


3.1 CARACTERIZAÇÃO DO TRABALHO

O presente trabalho caracteriza-se como uma pesquisa aplicada, pois busca utilizar conceitos de modelagem e gerenciamento de bancos de dados na resolução de problemas relacionados à organização, integração e análise de informações em ambientes organizacionais. Quanto à abordagem, o estudo possui caráter qualitativo e quantitativo, envolvendo tanto a análise conceitual das arquiteturas de bancos de dados quanto procedimentos práticos de organização, modelagem e manipulação das informações.

Do ponto de vista dos objetivos, a pesquisa possui caráter exploratório, visando ampliar a compreensão acerca dos bancos de dados relacionais e não relacionais, bem como dos procedimentos de modelagem, conexão e análise de dados aplicados a diferentes arquiteturas de armazenamento. Além disso, o trabalho caracteriza-se como um estudo prático envolvendo os modelos PostgreSQL e MongoDB, permitindo análise comparativa entre abordagens relacionais e documentais aplicadas ao contexto organizacional e industrial.

A Figura 6 apresenta de forma resumida as etapas metodológicas adotadas para acesso, organização, modelagem e análise dos dados provenientes dos bancos PostgreSQL e MongoDB utilizados neste estudo.

Figura 6 – Fluxo metodológico adotado no desenvolvimento da pesquisa



Fonte: Elaborado pelas autoras (2026)

A Figura 6 apresenta o fluxo metodológico adotado no desenvolvimento deste trabalho. Inicialmente, foram disponibilizadas as bases de dados em PostgreSQL e MongoDB, seguidas dos procedimentos de conexão, extração e importação das informações para o Power BI. Posteriormente, os dados foram organizados, modelados e analisados por meio da construção

de *dashboards* e indicadores de desempenho, permitindo a comparação entre os modelos relacional e não relacional aplicados ao contexto da Engenharia de Produção.

3.2 BASE DE DADOS UTILIZADA

A base de dados utilizada neste trabalho foi fornecida pelo professor da disciplina e composta por dois bancos de dados com arquiteturas distintas: um banco de dados relacional implementado em PostgreSQL e um banco de dados não relacional implementado em MongoDB.

O banco PostgreSQL continha informações estruturadas em tabelas relacionadas por meio de chaves primárias e estrangeiras, representando dados de um sistema ERP. Já o banco MongoDB era composto por coleções documentais armazenadas em formato BSON (*Binary JSON*), contendo informações relacionadas ao ambiente produtivo e indicadores operacionais. A utilização simultânea dos dois bancos permitiu realizar uma análise comparativa entre modelos relacionais e não relacionais, considerando aspectos relacionados à modelagem dos dados, estrutura de armazenamento, integração das informações e geração de indicadores gerenciais.

3.3 FERRAMENTAS UTILIZADAS

Para o desenvolvimento do trabalho foram utilizadas ferramentas voltadas ao acesso, manipulação e análise de dados.

No ambiente relacional foi utilizado o PostgreSQL como Sistema Gerenciador de Banco de Dados (SGBD), sendo o acesso realizado por meio do software DBeaver. No ambiente não relacional foi utilizado o MongoDB, acessado por meio da ferramenta MongoDB Compass.

Para construção dos relatórios e análises foi utilizado o Microsoft Power BI, responsável pela modelagem analítica dos dados, criação de relacionamentos, elaboração de medidas e desenvolvimento dos *dashboards*. Também foi utilizada a linguagem DAX (*Data Analysis Expressions*) para construção dos indicadores de desempenho e medidas analíticas empregadas nos relatórios.

3.4 PROCEDIMENTO DE ORGANIZAÇÃO DOS DADOS

Os dados foram organizados de acordo com as características de cada arquitetura de banco de dados utilizada.

No PostgreSQL, os dados foram importados diretamente para o Power BI por meio da conexão com o banco de dados remoto. Após a importação, as tabelas foram classificadas em tabelas fato e tabelas dimensão, permitindo a construção de um modelo analítico estruturado.

No MongoDB, os dados foram inicialmente acessados por meio do MongoDB Compass. Em seguida, as coleções foram exportadas individualmente para arquivos no formato CSV e posteriormente importadas para o Power BI. Após a importação, as tabelas também foram classificadas em fatos e dimensões, possibilitando a construção de um modelo analítico semelhante ao utilizado no banco relacional.

3.5 MODELAGEM LÓGICA DOS DADOS

A modelagem lógica dos dados foi desenvolvida de acordo com as características específicas de cada banco de dados analisado.

No PostgreSQL, foram utilizados os relacionamentos já existentes entre as tabelas do sistema ERP, baseados em chaves primárias e estrangeiras. Após a importação para o Power BI, os relacionamentos foram identificados automaticamente e posteriormente validados pelas autoras, garantindo aderência à estrutura lógica do sistema.

No MongoDB, devido à natureza documental dos dados, foi necessária uma etapa adicional de organização e modelagem analítica. Após a exportação das coleções, foram definidos relacionamentos entre as tabelas utilizando campos em comum, permitindo a construção de um modelo dimensional no formato esquema estrela (*star schema*), adequado para análises em Power BI.

3.6 PROCEDIMENTO DE CONEXÃO AO BANCO DE DADOS

A conexão ao banco PostgreSQL foi realizada por meio do software DBeaver, utilizando os parâmetros de acesso fornecidos pelo professor, incluindo host, porta, nome do banco de dados, usuário e senha. Após a autenticação, foi possível acessar diretamente as tabelas do sistema ERP e realizar sua integração com o Power BI.

A conexão ao MongoDB foi realizada utilizando o MongoDB Compass. O acesso ocorreu por meio de uma URI de conexão fornecida pelo professor, permitindo a autenticação e acesso às coleções documentais do banco de dados. Como não foi possível estabelecer conexão direta entre o MongoDB e o Power BI no ambiente utilizado, as coleções foram exportadas para arquivos CSV e posteriormente importadas para análise.

3.7 PROCEDIMENTO DE EXTRAÇÃO E ANÁLISE DOS DADOS

Após o estabelecimento das conexões, foi realizada a extração dos dados dos dois bancos para construção dos modelos analíticos no Power BI.

No banco PostgreSQL, os dados foram importados diretamente para o Power BI. No MongoDB, os dados foram previamente exportados para arquivos CSV e posteriormente carregados na ferramenta.

Em ambos os casos, as tabelas foram organizadas em fatos e dimensões e os relacionamentos foram configurados para garantir consistência das análises realizadas. Posteriormente, foram desenvolvidos *dashboards* contendo indicadores gerenciais e operacionais.

Para o banco PostgreSQL, foram construídos painéis voltados à análise comercial, operacional e financeira, contemplando indicadores como receita bruta, receita líquida, eficiência produtiva e Demonstração do Resultado do Exercício (DRE).

Para o banco MongoDB, foram desenvolvidos indicadores relacionados ao desempenho produtivo, incluindo OEE (*Overall Equipment Effectiveness*), disponibilidade, performance, qualidade, taxa de refugo, tempo médio por peça e análise dos motivos de parada dos equipamentos.

Os resultados obtidos foram analisados de forma comparativa, buscando identificar as características, vantagens e limitações de cada arquitetura de banco de dados no contexto da Engenharia de Produção.

4. RESULTADOS E DISCUSSÕES

4.1 POSTGRESQL

O acesso ao banco de dados foi realizado por meio de um cliente SQL gráfico (DBeaver), utilizando conexão direta via protocolo TCP/IP com um servidor PostgreSQL remoto. O processo seguiu um fluxo padrão de configuração de conexão em SGBDs relacionais.

Inicialmente, foi instalado o DBeaver, que atua como uma interface de gerenciamento de banco de dados compatível com múltiplos drivers JDBC. Ao abrir a aplicação, foi criada uma nova conexão selecionando o driver do PostgreSQL, o que implica o uso do protocolo nativo do PostgreSQL sobre a porta padrão 5432.

Na etapa de configuração, foram informados os parâmetros de conexão necessários para autenticação e localização do servidor:

Host: pep-postgresql.arch7.dev (endpoint do servidor remoto)


Porta: 5432 (porta padrão do PostgreSQL)

Database: erp (base de dados alvo)

Username: erp

Password: credencial de autenticação

Figura 7 – Servidor PostgreSQL conectado via DBeaver



Fonte: Elaborado pelas autoras (2026)

4.1.1 Elaboração do relatório

Os dados do sistema ERP foram carregados diretamente no Power BI por meio de uma conexão com o banco de dados PostgreSQL hospedado em ambiente Azure. Após a autenticação, todas as tabelas do schema foram importadas para o modelo sem necessidade de extração intermediária, garantindo maior integridade e rastreabilidade dos dados.

Inicialmente, foi realizada a classificação das tabelas em dois grupos principais:

- Tabelas Fato (FATO_*): armazenam os eventos transacionais e as medidas quantitativas do negócio, como movimentações de estoque, pedidos de venda, ordens de produção, compras e lançamentos contábeis.
- Tabelas Dimensão (DM_*): armazenam atributos descritivos utilizados para contextualizar e categorizar as análises, como produtos, clientes, fornecedores, centros de custo, recursos produtivos e municípios.

Figura 8 – Tabelas importadas PostgreSQL para o Power BI e classificadas como fato e dimensão



Fonte: Elaborado pelas autoras (2026)

Após a importação, o Power BI identificou automaticamente os relacionamentos entre as tabelas com base nas chaves primárias e estrangeiras existentes no banco de dados. Em seguida, foi realizada uma validação manual do modelo para verificar se os relacionamentos propostos correspondiam à estrutura lógica do ERP.

No modelo de dados, cada tabela representa uma entidade do negócio.

Exemplos:

- Produto

- Cliente
- Fornecedor
- Ordem de Produção
- Pedido de Venda
- Centro de Custo

Os campos presentes em cada tabela representam seus atributos.

O modelo é predominantemente composto por relacionamentos do tipo um-para-muitos (1:N). Nesse tipo de relacionamento, um registro da tabela dimensão pode estar associado a diversos registros da tabela fato.


Exemplos identificados no modelo:

Produto → Ordem de Produção: Um produto pode possuir diversas ordens de produção ao longo do tempo, mas cada ordem de produção está associada a apenas um produto.

Cliente → Pedido de Venda: Um cliente pode realizar vários pedidos de venda, enquanto cada pedido pertence a apenas um cliente.

Conta Contábil → Lançamentos Contábeis: Uma conta contábil pode ser utilizada em diversos lançamentos, porém cada lançamento está vinculado a uma única conta.

Figura 9 – Modelo de dados relacional utilizado na construção do relatório




Fonte: Elaborado pelas autoras (2026)

Figura 10 – Detalhamento da região esquerda do modelo de dados



Fonte: Elaborado pelas autoras (2026)

Figura 11 – Detalhamento da região direita do modelo de dados



Fonte: Elaborado pelas autoras (2026)

Observa-se que o modelo relacional segue os princípios de normalização discutidos anteriormente, apresentando entidades separadas por domínio de negócio e relacionamentos estabelecidos por chaves primárias e estrangeiras. Essa estrutura reduz redundâncias e favorece a integridade dos dados.


As tabelas do sistema ERP apresentam aderência aos princípios da Terceira Forma Normal (3FN), uma vez que os atributos de cada entidade dependem exclusivamente de suas respectivas chaves primárias, sem dependências parciais ou transitivas identificadas no modelo analisado. Essa organização contribui para a redução de redundâncias, evita anomalias de atualização e favorece a consistência das informações armazenadas.

4.1.2 Análise dos resultados

Os resultados apresentados no relatório evidenciam três perspectivas principais do negócio: comercial, operacional (produção) e financeira (DRE), permitindo uma análise integrada de desempenho.

Do ponto de vista comercial, observa-se um volume expressivo de receita, com Receita Bruta de R\$ 594,8 milhões, reduzida por descontos de aproximadamente R\$ 32,5 milhões, resultando em uma Receita Líquida de R\$ 562,3 milhões. A distribuição mensal da receita líquida é relativamente estável, com variações moderadas ao longo do ano, indicando baixa sazonalidade e previsibilidade de faturamento. A concentração de clientes é relevante: o maior cliente representa cerca de 22,27% da receita, o que caracteriza dependência comercial significativa e potencial risco de concentração. Em termos de mix de produtos, poucos itens concentram grande parte da receita (ex: bombas e válvulas), evidenciando uma estratégia focada em linhas principais. Regionalmente, há predominância do estado de SP, com mais de 43% da receita, indicando concentração geográfica.

Figura 12 – *Dashboard* de desempenho comercial




Fonte: Elaborado pelas autoras (2026)

Na perspectiva operacional, o painel de produção mostra que foram produzidas 594.566 unidades, frente a uma previsão de 613.684, resultando em uma eficiência global de 96,88% . Esse indicador sugere boa aderência ao planejamento, embora com leve subprodução. A análise mensal mostra oscilações na eficiência, com alguns períodos acima de 100% (superprodução) e outros abaixo, indicando variações operacionais que podem estar relacionadas a disponibilidade de recursos, paradas ou variações de demanda. A produção está concentrada principalmente em duas famílias: Válvulas Industriais e Bombas Hidráulicas, que juntas representam a maior parte do volume produzido, evidenciando foco produtivo. A

granularidade por ordem de produção demonstra rastreabilidade operacional, com controle por produto, mês e status.

Figura 13 – *Dashboard* de desempenho operacional da produção



Fonte: Elaborado pelas autoras (2026)

Sob a ótica financeira (DRE), a empresa apresenta um resultado líquido positivo de R\$ 43,7 milhões, indicando lucratividade. No entanto, a análise estrutural revela que os principais impactos negativos vêm de:

- Deduções da receita (~28%)
- Custo dos produtos vendidos (~47%)

Esses dois componentes consomem a maior parte da receita, restando margens reduzidas para despesas operacionais e lucro. As despesas comerciais e administrativas, embora menores, ainda representam impacto relevante. A margem líquida final é relativamente baixa em relação à receita total, o que sugere necessidade de controle de custos ou otimização de preços.

Figura 14 – Dashboard de desempenho financeiro



Fonte: Elaborado pelas autoras (2026)

4.1.3 Elaboração dos resultados

Para fazer o cálculo da Receita Bruta para a DRE foi usada uma medida na tabela FATO_erp lançamento_contabil:

ReceitaBruta = CALCULATE(SUM('FATO_erp lancamento_contabil'[valor]),'DIM_erp
conta_contabil'[grupo_dre_codigo] ="RECEITA_BRUTA")

Para calcular a eficiência foi usada uma medida na tabela FATO_erp ordem_producao:

Eficiência (%) =

DIVIDE(
[Produção Realizado],
[Produção Prevista]
)

Na mesma tabela, medidas para o cálculo de número de OPs:

Ordens Produção =

DISTINCTCOUNT('FATO_erp ordem_producao'[codigo])

Produção prevista:

Produção Prevista =

SUM('DIM_erp previsao_demanda'[qtd_prevista])

Produção realizada:

Produção Realizado =

SUM('FATO_erp ordem_producao'[qtd_planejada])

Na tabela FATO_Vendas, quantidade vendida:

Qtd Vendida =

SUM(FATO_Vendas[FATO_erp item_pedido.quantidade])

Receita bruta:

Receita Bruta =

SUMX(
FATO_Vendas,
FATO_Vendas[FATO_erp item_pedido.quantidade] *
FATO_Vendas[FATO_erp item_pedido.preco_unitario]
)

Receita líquida:

Receita Líquida =

[Receita Bruta] - [Valor Desconto]

Valor do desconto:

Valor Desconto =

SUMX(

FATO_Vendas,

FATO_Vendas[FATO_erp item_pedido.quantidade] *

FATO_Vendas[FATO_erp item_pedido.preco_unitario] *

FATO_Vendas[FATO_erp item_pedido.desconto_pct] / 100

)

Os demais resultados foram obtidos de forma direta com as colunas nas ferramentas visuais do Power BI.

4.2 MONGODB

Para a conexão com o banco de dados não relacional MongoDB, foi utilizada a ferramenta gráfica MongoDB Compass, que permite a visualização e manipulação dos dados de forma intuitiva. Inicialmente, realizou-se a instalação do software por meio do site oficial do MongoDB, seguindo o procedimento padrão de instalação.

Após a instalação, o MongoDB Compass foi executado, sendo necessário informar uma Connection URI (Uniform Resource Identifier) para estabelecer a conexão com o banco de dados. Foi utilizada a seguinte URI fornecida no material de apoio:


mongodb://usuario:*****@pep-mongo.arch7.dev:27018

Em seguida, ao acionar a opção “Connect”, o sistema realizou a autenticação e estabeleceu a conexão com o servidor remoto. Uma vez conectado, foi possível acessar o banco de dados denominado “mes”, no qual estavam disponíveis as coleções previamente estruturadas. Conforme especificado na documentação, o banco contém seis coleções.

Diferentemente de bancos de dados relacionais, como o PostgreSQL, em que os dados são organizados em tabelas compostas por linhas e colunas, o MongoDB adota um modelo orientado a documentos. Nesse modelo, os dados são armazenados em coleções, que contêm documentos no formato JSON (JavaScript Object Notation).

Por fim, a visualização dos dados foi realizada diretamente no MongoDB Compass. Após acessar o banco de dados “mes” e selecionar uma coleção, os documentos foram exibidos automaticamente na interface. A ferramenta também permite a execução de operações como filtragem, busca, edição e exportação dos dados, facilitando a análise e manipulação das informações armazenadas.


Figura 15 – Visualização da coleção apontamentos_producao no MongoDB Compass



Fonte: Elaborado pelas autoras (2026)

Após a etapa de acesso e visualização dos dados no MongoDB, realizou-se a extração das informações necessárias por meio da exportação das coleções para o formato CSV (Comma-Separated Values). Cada coleção foi exportada individualmente, permitindo a posterior utilização dos dados em ferramentas de análise, conforme destacado na Figura 15.

Figura 16 – Exportação de coleções do MongoDB para o formato CSV



Fonte: Elaborado pelas autoras (2026)

Em seguida, os arquivos CSV foram importados para o software Power BI, onde se iniciou o processo de modelagem dos dados. Nessa etapa, foram estabelecidas as relações entre as tabelas com base nos campos em comum, garantindo a integridade e a consistência das informações no modelo.

Posteriormente, foram definidos e construídos os indicadores de desempenho considerados mais relevantes para o processo em análise. A escolha dos indicadores foi orientada pela capacidade de representar aspectos críticos da operação e apoiar a tomada de decisão.

Por fim, com os dados estruturados e os indicadores definidos, foi elaborado um painel interativo no Power BI, possibilitando a visualização clara e dinâmica das informações, bem como a análise dos resultados obtidos.

Antes da criação dos relacionamentos no Power BI, foi realizada a classificação das tabelas em fatos e dimensões, etapa fundamental para a construção de um modelo de dados eficiente.

As tabelas fato foram definidas como aquelas que concentram os dados quantitativos do processo, como produção, tempo operando, quantidade de peças e indicadores operacionais. Essas tabelas são caracterizadas por apresentarem grande volume de registros e por servirem de base para o cálculo das medidas, como OEE, taxa de refugo e tempo por peça.


Por outro lado, as tabelas dimensão foram estruturadas com o objetivo de fornecer contexto analítico aos dados, contendo informações descritivas como produto, máquina, tempo (mês) e centro de trabalho. Essas tabelas permitem a segmentação e o detalhamento das análises.

A partir dessa separação, foi possível estruturar um modelo relacional no formato de esquema estrela (*star schema*), no qual as tabelas dimensão se conectam diretamente às tabelas fato por

meio de chaves comuns. Essa abordagem facilita a criação de relacionamentos consistentes, melhora o desempenho das consultas e torna a análise mais intuitiva no Power BI.

Após essa organização, foram estabelecidos os relacionamentos entre as tabelas com base nos campos compartilhados, garantindo a integridade dos dados e permitindo a correta consolidação das informações para o cálculo dos indicadores. Os relacionamentos podem ser observados na Figura 16.

Figura 17 – Modelo de dados em esquema estrela (*Clean Architecture*) utilizado no Power BI



Fonte: Elaborado pelas autoras (2026)

Os relacionamentos entre as entidades foram modelados predominantemente como associações do tipo um-para-muitos (1:N), refletindo a natureza operacional dos dados. Especificamente:

- Ordens de Produção → Inspeções: uma única ordem de produção pode estar associada a múltiplos registros de inspeção, devido à possibilidade de realização de mais de uma inspeção ao longo do processo produtivo.
- Ordens de Produção → Apontamentos de Produção: uma ordem pode possuir diversos apontamentos, uma vez que o registro da produção pode ocorrer em diferentes momentos ou etapas.

- Ordens de Produção → Eventos de Máquina: uma mesma ordem pode gerar múltiplos eventos de máquina (paradas, falhas, ajustes), caracterizando uma relação 1:N.
- Máquina → Ordens de Produção: uma máquina pode ser utilizada em diversas ordens de produção ao longo do tempo.
- Máquina → Eventos de Máquina: diferentes eventos podem estar associados a uma mesma máquina.
- Máquina → Manutenções: uma máquina pode passar por múltiplas intervenções de manutenção.
- Máquina → Apontamentos de Produção: uma mesma máquina pode estar vinculada a diferentes registros de produção.

Adicionalmente, foram identificados relacionamentos do tipo muitos-para-muitos (N:N), que exigem maior atenção no tratamento analítico:

- SKU de Produto → Ordens de Produção, Inspeções e Apontamentos: um mesmo SKU pode ser produzido, inspecionado e apontado diversas vezes em diferentes ordens, caracterizando uma relação não exclusiva entre essas entidades.
- Datas → Produção, Inspeções e Apontamentos: em uma mesma data podem ocorrer múltiplos registros de produção, inspeções e apontamentos, o que também configura uma relação muitos-para-muitos.

Essas definições de cardinalidade foram fundamentais para garantir a correta modelagem dos dados e evitar ambiguidades nas análises realizadas no Power BI.

4.2.1 Análise dos resultados

A partir da modelagem dos dados no Power BI, foram desenvolvidos indicadores-chave de desempenho (KPIs), com destaque para o OEE (*Overall Equipment Effectiveness*), calculado a partir das três dimensões fundamentais: disponibilidade, performance e qualidade. Esses indicadores permitiram uma análise integrada da eficiência produtiva.


O valor médio de OEE observado foi de aproximadamente 80,72%, mantendo-se relativamente estável ao longo dos meses, com variações pouco expressivas entre aproximadamente 79,9% e 81,7% . Esse comportamento indica um processo produtivo consistente, porém com margem relevante para melhoria, considerando que benchmarks industriais frequentemente apontam valores acima de 85% como referência de excelência.

Ao decompor o OEE, observa-se que a qualidade apresenta desempenho elevado, com valores próximos de 98%, evidenciando baixa incidência de produtos não conformes . Esse resultado é reforçado pela taxa de refugo de apenas 1,64%, indicando que o processo produtivo apresenta bom controle de qualidade e baixa perda de material .

A performance, por sua vez, situa-se em torno de 91%, sugerindo que o ritmo de produção está próximo do ideal, mas ainda sofre perdas relacionadas à velocidade operacional ou pequenas ineficiências no processo. Já a disponibilidade apresenta valores próximos de 89%, sendo o componente mais crítico do OEE, o que indica que as principais perdas estão associadas a paradas de máquina e indisponibilidade de equipamentos .

Essa análise é corroborada pelos dados de paradas, que totalizam 4.285 ocorrências, sendo os principais motivos relacionados a ajustes de processo, falta de operador e falta de material . Esses fatores impactam diretamente o tempo operando, reduzindo a disponibilidade dos equipamentos.

Figura 18 – Painel de indicadores de eficiência produtiva (OEE)




Fonte: Elaborado pelas autoras (2026)

Além disso, o tempo médio de produção foi de aproximadamente 1,39 minutos por peça, indicando um processo relativamente eficiente em termos de produtividade. No entanto, ao relacionar esse indicador com as perdas de disponibilidade, percebe-se que ganhos adicionais poderiam ser obtidos com a redução de paradas não planejadas.

No que se refere à produção, observa-se equilíbrio entre os turnos, com divisão praticamente igual da produção total (aproximadamente 50% para cada turno), o que sugere uma boa distribuição da carga produtiva. A produção total atingiu cerca de 606 mil peças, com

aderência ao planejamento, visto que a quantidade de peças boas (597 mil) está muito próxima da planejada (595 mil) .

Figura 19 – Painel de indicadores de produção e produtividade




Fonte: Elaborado pelas autoras (2026)

Por fim, a análise de manutenção evidencia um volume significativo de intervenções corretivas em relação às preventivas, além de custos elevados associados às manutenções, o que reforça o impacto negativo sobre a disponibilidade dos equipamentos. Esse cenário indica oportunidade de melhoria por meio do fortalecimento da manutenção preventiva e de estratégias de confiabilidade.

Em síntese, os resultados demonstram que o sistema produtivo apresenta bom desempenho em qualidade e estabilidade operacional, porém com oportunidades claras de melhoria na disponibilidade dos equipamentos, especialmente por meio da redução de paradas e aprimoramento da gestão de manutenção.

Figura 20 – Painel de indicadores de manutenção



Fonte: Elaborado pelas autoras (2026)

4.2.2 Por que é um banco não relacional?

O banco de dados utilizado, MongoDB, é classificado como não relacional (NoSQL) em função da forma como armazena, organiza e gerencia os dados, distinguindo-se significativamente dos bancos de dados relacionais tradicionais, como o PostgreSQL.

Nos bancos de dados relacionais, as informações são estruturadas em tabelas compostas por linhas e colunas, com esquemas rígidos e previamente definidos. Nesse modelo, situações como múltiplas paradas em uma mesma ordem de produção exigem estruturas específicas, como vetores ou tabelas relacionadas (por exemplo, paradas[0], paradas[1], etc.). Além disso, há forte dependência de relacionamentos explícitos, implementados por meio de chaves primárias e estrangeiras, garantindo a integridade referencial entre diferentes entidades.

Em contrapartida, o MongoDB adota um modelo orientado a documentos, no qual os dados são armazenados em coleções compostas por documentos no formato JSON (ou BSON). Esses documentos possuem estrutura flexível, permitindo que registros de uma mesma coleção apresentem variações em seus campos sem a necessidade de um esquema fixo, como ocorre no exemplo das paradas.

Outra característica que o define como não relacional é a ausência de relacionamentos rígidos entre entidades. Embora seja possível estabelecer referências entre coleções, o modelo prioriza a desnormalização, ou seja, o armazenamento de dados relacionados dentro de um mesmo documento, reduzindo a necessidade de operações complexas de junção (joins) e favorecendo o desempenho em determinadas consultas.

Adicionalmente, o MongoDB não exige a definição prévia de um esquema estruturado, o que proporciona maior flexibilidade na inserção, modificação e evolução dos dados ao longo do tempo. Essa característica torna-se especialmente relevante em contextos com alta variabilidade, crescimento contínuo ou mudanças frequentes nos requisitos de dados.

4.2.3 Construção dos indicadores

A solução foi construída a partir de uma abordagem de modelagem analítica sobre dados originalmente não relacionais, na qual as tabelas foram previamente classificadas em fato e dimensão e posteriormente integradas no Power BI por meio de chaves comuns, permitindo a criação de um modelo semântico consistente.

A tabela fato ('FATO_mes_apontamentos_producao') concentra as métricas operacionais (tempo, produção e qualidade), enquanto as dimensões fornecem os contextos de análise. A partir desse modelo, foram definidas medidas em DAX para cálculo do OEE (*Overall Equipment Effectiveness*), decomposto em três componentes fundamentais. A Disponibilidade mede a relação entre o tempo efetivamente operado e o tempo planejado, sendo expressa por (

$Disponibilidade = \frac{\sum tempo_operando_min}{\sum tempo_planejado_min}$), implementada em DAX com
'DIVIDE(SUM('FATO_mes_apontamentos_producao'[tempo_operando_min]),
SUM('FATO_mes_apontamentos_producao'[tempo_planejado_min]))'.

A Qualidade avalia a proporção de peças boas produzidas, definida por ($Qualidade = \frac{\sum pecas_boas}{\sum tpecas_total}$), calculada com

``DIVIDE(SUM(`FATO_mes_apontamentos_producao`[pecas_boas]), SUM(Producao[pecas_total]))``. A Performance compara a produção real com a capacidade teórica baseada no tempo de ciclo ideal, considerando a necessidade de conversão de segundos para minutos, sendo dada por ($Performance = \frac{\sum(\frac{tempo_ciclo_ideal_seg}{60} \times pecas_total), i}{\sum tempo_empo_operando_min}$), implementada com ``DIVIDE(SUMX(`FATO_mes_apontamentos_producao`, (`FATO_mes_apontamentos_producao`[tempo_ciclo_ideal_seg] / 60) * `FATO_mes_apontamentos_producao`[pecas_total]), SUM(`FATO_mes_apontamentos_producao`[tempo_operando_min]))``, onde o uso de ``SUMX`` permite cálculo em nível de linha antes da agregação.

O OEE é então obtido pela multiplicação das três componentes, ($OEE = Disponibilidade \times Qualidade \times Performance$), implementado como ``[Disponibilidade] * [Performance] * [Qualidade]``, devendo ser formatado como percentual.

Complementarmente, foram definidos indicadores auxiliares: a Taxa de Refugo, ($\frac{\sum pecas_refugo}{\sum tpecas_total}$), com ``DIVIDE(SUM(`FATO_mes_apontamentos_producao`[pecas_refugo]), SUM(`FATO_mes_apontamentos_producao`[pecas_total]))``, e o Tempo Médio por Peça, $\frac{\sum tempo_operando_min}{\sum tpecas_total}$, com ``DIVIDE(SUM(`FATO_mes_apontamentos_producao`[tempo_operando_min]), SUM(`FATO_mes_apontamentos_producao`[pecas_total]))``. O uso sistemático da função ``DIVIDE`` garante robustez contra divisões por zero, e a estrutura dimensional criada no Power BI compensa a ausência de relacionamentos nativos do banco não relacional, viabilizando análises consistentes e performáticas dos indicadores industriais.

4.2.3.1 Paradas por motivo

A base de dados analisada apresenta estrutura oriunda de banco não relacional, na qual as informações de paradas estão armazenadas em formato aninhado, sendo distribuídas em múltiplos campos dentro de uma mesma Ordem de Produção (OP), como `paradas[0]`, `paradas[1]`, `paradas[2]`, entre outros. Essa modelagem caracteriza um formato não normalizado, inadequado para análises agregadas diretas, uma vez que múltiplas ocorrências de um mesmo atributo (motivo de parada) estão representadas em colunas distintas ao invés de registros individuais.

Para viabilizar a análise da quantidade de paradas por motivo, foi necessário realizar um processo de transformação estrutural dos dados, equivalente à normalização para um formato tabular analítico. Essa transformação consistiu na projeção e união (UNION) dos diferentes campos de motivo de parada em uma única coluna, de modo que cada ocorrência de parada passasse a ser representada como uma linha independente. Com isso, garantiu-se a atomicidade dos registros e a correta representação da cardinalidade entre OPs e paradas (relação um-para-muitos). Isso foi feito por meio da criação de uma nova tabela usando linguagem DAX:

Tabela_Paradas =

```
FILTER(
    UNION(
        SELECTCOLUMNS('FATO_mes apontamentos_producao', "Motivo", 'FATO_mes
apontamentos_producao'[paradas[0]].motivo)),
        SELECTCOLUMNS('FATO_mes apontamentos_producao', "Motivo", 'FATO_mes
apontamentos_producao'[paradas[1]].motivo)),
        SELECTCOLUMNS('FATO_mes apontamentos_producao', "Motivo", 'FATO_mes
apontamentos_producao'[paradas[2]].motivo)),
        SELECTCOLUMNS('FATO_mes apontamentos_producao', "Motivo", 'FATO_mes
apontamentos_producao'[paradas[3]].motivo))
    ),
    NOT ISBLANK([Motivo])
).
```

Posteriormente foi feita uma medida para contar as linhas dessa nova tabela, possibilitando saber a quantidade de paradas por motivo:

Qtd Paradas = COUNTROWS(Tabela_Paradas)

Adicionalmente, foram aplicados filtros para remoção de valores nulos, assegurando a integridade da análise. A partir dessa estrutura consolidada, tornou-se possível aplicar funções de agregação, especificamente a contagem de ocorrências (COUNT), agrupadas pelo atributo “motivo de parada”.

Esse procedimento permitiu contabilizar corretamente todas as paradas, inclusive nos casos em que uma única OP apresenta múltiplas ocorrências, eliminando distorções que ocorreriam caso apenas uma instância por OP fosse considerada. Como resultado, obteve-se uma visão fidedigna da frequência dos motivos de parada, viabilizando a construção de indicadores e visualizações consistentes no Power BI.

4.3 COMPARAÇÃO ENTRE POSTGRESQL E MONGODB

Após a análise individual dos resultados obtidos em cada arquitetura, realizou-se uma comparação consolidada entre os modelos, considerando aspectos relacionados à modelagem, integração dos dados, construção dos indicadores e utilização em ambientes de Engenharia de Produção.

Com o objetivo de comparar os dois modelos de banco de dados analisados, a Tabela 2 apresenta uma síntese das principais características observadas durante o desenvolvimento do trabalho, considerando aspectos relacionados à estrutura dos dados, processo de conexão, modelagem analítica e construção dos indicadores.

Tabela 2 – Comparação entre PostgreSQL e MongoDB no contexto do estudo

Critério	PostgreSQL	MongoDB
Modelo de dados	Relacional	Não relacional (documental)
Estrutura de armazenamento	Tabelas relacionadas por chaves	Coleções e documentos BSON
Organização dos dados	Estruturada e rígida	Flexível e adaptável
Integração com Power BI	Conexão direta	Necessidade de exportação para CSV
Modelagem analítica	Mais simples	Exigiu transformações adicionais
Relacionamentos	Explícitos por PK e FK	Implícitos ou definidos na modelagem
Flexibilidade estrutural	Menor	Maior
Facilidade para construção de indicadores	Maior	Moderada
Aplicações típicas	ERP, sistemas corporativos e financeiros	Big Data, IoT e aplicações escaláveis

Fonte: Elaborado pelas autoras (2026)

Conforme apresentado na Tabela 2, os dois modelos possuem características distintas que influenciam diretamente a forma de armazenamento, organização e análise dos dados. O PostgreSQL demonstrou maior facilidade para a construção dos modelos analíticos e dos *dashboards* desenvolvidos no Power BI, principalmente devido à existência de relacionamentos previamente definidos e à possibilidade de conexão direta com a ferramenta de visualização.

Por outro lado, o MongoDB apresentou maior flexibilidade estrutural, permitindo o armazenamento de informações em formato documental e maior adaptação a cenários com elevada variabilidade de dados. Entretanto, para utilização analítica, foi necessária uma etapa

adicional de exportação das coleções para arquivos CSV, seguida da construção dos relacionamentos necessários dentro do Power BI.

Os resultados obtidos evidenciam que a escolha entre bancos relacionais e não relacionais depende diretamente do contexto de aplicação. Enquanto o PostgreSQL mostrou-se mais adequado para ambientes com dados estruturados e forte necessidade de integridade relacional, o MongoDB apresentou vantagens em cenários que exigem flexibilidade estrutural, escalabilidade e armazenamento de dados com formatos heterogêneos.

Dessa forma, observa-se que ambas as arquiteturas possuem potencial de aplicação na Engenharia de Produção, cabendo ao profissional avaliar as características do problema, dos dados disponíveis e dos objetivos analíticos para selecionar a solução mais adequada.

5. CONSIDERAÇÕES FINAIS

O presente trabalho teve como objetivo desenvolver e analisar, de forma prática, implementações utilizando os bancos de dados PostgreSQL e MongoDB, buscando compreender suas diferenças em termos de modelagem, organização, manipulação e análise de dados no contexto da Engenharia de Produção.

Os resultados obtidos permitiram atingir o objetivo proposto, uma vez que foi possível realizar o acesso, a modelagem, a extração e a análise de dados em ambas as arquiteturas, além de desenvolver *dashboards* gerenciais capazes de apoiar a tomada de decisão por meio da utilização do Power BI. A construção dos relatórios possibilitou transformar dados operacionais em informações relevantes para análise de desempenho comercial, financeiro, produtivo e de manutenção.

A análise realizada evidenciou diferenças significativas entre os modelos estudados. O PostgreSQL apresentou maior facilidade para organização dos dados, criação de relacionamentos e construção de análises estruturadas, em função de sua arquitetura relacional baseada em tabelas, chaves primárias e chaves estrangeiras. Essa característica favoreceu a integração direta com o Power BI e simplificou o processo de modelagem analítica dos dados. Por outro lado, o MongoDB demonstrou maior flexibilidade estrutural, permitindo o armazenamento de informações em formato documental e a adaptação a cenários com elevada variabilidade de dados. Entretanto, para utilização analítica no Power BI, foram necessárias etapas adicionais de transformação, organização e modelagem dos dados, especialmente devido à presença de estruturas aninhadas e relacionamentos implícitos entre as coleções.

A utilização do Power BI mostrou-se fundamental para o desenvolvimento do estudo, pois permitiu analisar os dois modelos utilizando uma mesma plataforma de *Business Intelligence*.

Dessa forma, tornou-se possível comparar as arquiteturas sob uma perspectiva prática, avaliando não apenas aspectos teóricos de modelagem, mas também sua aplicação na geração de indicadores e suporte à tomada de decisão.

Considerando o cenário analisado neste trabalho, o PostgreSQL apresentou maior aderência às necessidades de análise e construção de indicadores gerenciais, em função da estrutura já organizada e da facilidade de integração com ferramentas analíticas. Entretanto, isso não significa superioridade absoluta em relação ao MongoDB, uma vez que a escolha da tecnologia mais adequada depende das características do problema, do volume de dados, da necessidade de escalabilidade e do grau de flexibilidade exigido pela aplicação.

Como limitação do estudo, destaca-se a utilização de bases de dados previamente disponibilizadas para fins acadêmicos, restringindo a análise a um conjunto específico de cenários e estruturas de dados. Além disso, não foram realizados testes de desempenho computacional, escalabilidade ou tempo de resposta entre os bancos, concentrando-se a avaliação nos aspectos de modelagem, organização e análise das informações.

Como sugestão para trabalhos futuros, recomenda-se a realização de estudos envolvendo bases de dados de maior porte, a comparação de desempenho entre diferentes arquiteturas em ambientes reais de produção, bem como a integração dos bancos de dados com ferramentas de análise avançada e aplicações de inteligência artificial. Também podem ser explorados cenários de polyglot persistence, nos quais bancos relacionais e não relacionais são utilizados de forma complementar para atender diferentes necessidades organizacionais.

Por fim, conclui-se que tanto os bancos de dados relacionais quanto os não relacionais possuem aplicações relevantes na Engenharia de Produção, cabendo ao profissional selecionar a tecnologia mais adequada às características do processo analisado. O conhecimento das vantagens, limitações e possibilidades de cada abordagem amplia a capacidade analítica do engenheiro e contribui para decisões mais assertivas em ambientes organizacionais cada vez mais orientados por dados.

REFERÊNCIAS BIBLIOGRÁFICAS

ARANTES, Márcio Da Silva *et al.* **General Architecture for Data Analysis in Industry 4.0 using SysML and Model Based System Engineering**. In: IEEE INTERNATIONAL SYSTEMS CONFERENCE (SYSCON), 12., 2018, Vancouver. Proceedings [...]. Vancouver: IEEE, 2018. DOI: 10.1109/SYSCON.2018.8369574.

BANKER, K. *et al.* **MongoDB in Action**: covers MongoDB version 3.0. 2. ed. Shelter Island: Manning Publications, 2016.

CARVALHO, Paulo Henrique Costa. MER SQL: Modelo Entidade Relacionamento e SQL. Disponível em: <https://paulohcc.com/mer-sql/> . Acesso em: 11 maio 2026.

DATABASE STAR. **Database normalization examples**. Disponível em: <https://www.databasestar.com/database-normalization/images/Normalisation-ERD-Examples-4NF.png>. Acesso em: 11 maio 2026.

DATE, C. J. **An Introduction to Database Systems**. 8. ed. Boston: Pearson, 2004.

ELMASRI, R.; NAVATHE, S. B. **Sistemas de Banco de Dados**. 6. ed. São Paulo: Pearson Addison Wesley, 2011.

FOWLER, Martin *et al.* **Padrões de Arquitetura de Aplicações Corporativas**. Porto Alegre: Bookman, 2007. 497 p.

GUERREIRO, Reinaldo *et al.*, Indústria 4.0: Características e Potenciais Impactos no Ambiente Interno das Empresas . Advances in Scientific and Applied Accounting, 2023. <https://doi.org/10.14392/asaa.2023160305>

LAMPEÃO, Odibar João; SANTANA, Marília Barreto de. Sistemas de informação em contexto de mudança organizacional: uma reflexão sobre suas potencialidades. **Revista dos Mestrados Profissionais – RMP**, Recife, v. 7 , n. 2, 2020.

LAUDON, Kenneth C.; LAUDON, Jane P. **Sistemas de Informação Gerenciais**. 11. ed. São Paulo: Pearson, 2015.

LIMA, José Jerônimo de Menezes; REDAELLI, Emir José. MODELO DE MATURIDADE EM COMPETIÇÃO ANALÍTICA. **Revista Foco**, Curitiba, v. 16, n. 5, p. 1-24, 17 maio 2023. South Florida Publishing LLC. <http://dx.doi.org/10.54751/revistafoco.v16n5-083>.

MARTIN, Robert C.. **Clean Architecture**: a craftsman's guide to software struchture and design. S.L: Prentice Hall, 2018. 364 p.

MONGODB INC. **MongoDB Documentation**. Disponível em: <https://www.mongodb.com/docs/>. Acesso em: 11 maio 2026.

SADALAGE, P. J.; FOWLER, M. **NoSQL Distilled**: A Brief Guide to the Emerging World of Polyglot Persistence. Boston: Addison-Wesley, 2013.

SILBERSCHATZ, A.; KORTH, H. F.; SUDARSHAN, S. **Sistema de Banco de Dados**. 7. ed. Rio de Janeiro: Elsevier, 2019.