

Extração Autônoma de Dados Operacionais: um Procedimento Padrão para o Engenheiro de Produção

Geovana Vithória de Andrade Santos (Universidade Federal de Goiás - UFG)

Maria Eduarda Ribeiro de Paula (Universidade Federal de Goiás - UFG)



O avanço da Indústria 4.0 tem ampliado o volume de dados operacionais disponíveis nas organizações industriais, transformando o perfil profissional do Engenheiro de Produção. Nesse contexto, a dependência de equipes de Tecnologia da Informação para extração de dados gera gargalos analíticos que comprometem a agilidade da tomada de decisão. O presente trabalho descreve, por meio de um Procedimento Operacional Padrão (POP), o processo de conexão, extração e análise de dados operacionais diretamente de bancos de dados relacionais e não relacionais. A pesquisa é aplicada e demonstrativa, com abordagem quali-quantitativa, executada sobre um dataset representativo de um ambiente industrial. O procedimento foi estruturado em cinco fases: conexão ao banco, exploração da estrutura, extração, geração de indicadores e interpretação dos resultados, utilizando Python, pandas e Jupyter Notebook. Os resultados demonstram que o engenheiro de produção possui capacidade técnica para acessar fontes primárias de dados e transformá-los em conhecimento estratégico, completando o ciclo dado-informação-conhecimento-decisão, reduzindo o tempo de resposta operacional e promovendo a melhoria contínua.

Palavras-chave: Banco de dados; NoSQL; SQL; análise de dados.

1. Introdução

No cenário econômico e corporativo atual, marcado por um mercado altamente ágil, dinâmico e competitivo, as organizações industriais são constantemente desafiadas a atender às crescentes exigências dos consumidores, otimizar seus recursos e manter sua posição de destaque no setor. A evolução dos paradigmas industriais, comumente denominada Indústria 4.0, tem exigido das organizações a integração de tecnologias digitais aos processos físicos de manufatura. Dentre os principais pilares desta transformação, destaca-se o uso de sistemas de informação e a disponibilização de grandes volumes de dados operacionais em tempo real (Fukuda; Mariz; Mesquita, 2017).

O ambiente industrial contemporâneo exige tomadas de decisão que sejam baseadas em evidências quantitativas e qualitativas seguras. Com o advento de novas tecnologias e a interconectividade dos equipamentos fabris, a gestão de operações passou a depender fortemente da análise de dados precisos. Para que o processo de tomada de decisão seja efetivo, os gestores e engenheiros precisam ter acesso rápido e confiável às informações geradas no chão de fábrica.

No contexto da Engenharia de Produção, essa alta disponibilidade de dados alterou significativamente o perfil profissional exigido pelo mercado, que agora necessita de engenheiros com maior domínio de tecnologias de informação e autonomia analítica (Sackey et al., 2016). Com o surgimento de tecnologias como a computação em nuvem, a Internet das Coisas (IoT) e a infraestrutura de Sistemas de Informação Gerenciais (SIG), o Engenheiro de Produção deixou de ser apenas um observador dos processos físicos para atuar diretamente na análise de dados e informações digitais.

No entanto, em muitas organizações, a extração e a análise desses dados ainda dependem de relatórios estáticos gerados por sistemas legados ou de chamados intermediários à equipe de Tecnologia da Informação (TI). Esse processo gera atrasos e a perda da granularidade das informações, impedindo que o profissional acesse os dados primários (Carvalho, 2019). A dependência da equipe de TI para a extração de dados operacionais cria gargalos analíticos, uma vez que o profissional não consegue responder às suas próprias dúvidas no momento em que o problema de produção ocorre. A integração do profissional com a tecnologia da informação é apontada por Ciolacu et al. (2017) como um dos requisitos para o desempenho e eficiência da nova geração de estudantes e engenheiros.

O acesso direto aos bancos de dados primários promove a autonomia analítica do Engenheiro de Produção. Ao atuar diretamente na fonte dos dados (seja em bancos de dados relacionais como o PostgreSQL ou não-relacionais como o MongoDB), o profissional consegue gerar

indicadores de desempenho mais precisos para identificar falhas e otimizar processos produtivos. De acordo com Date (2004), a separação clara entre as camadas de aplicação e o armazenamento de dados assegura a segurança e a consistência das informações, permitindo que diferentes setores utilizem a base de dados como fonte da verdade. Conforme Laudon e Laudon (2014), a utilização de sistemas de informação permite converter dados brutos em conhecimento para a organização.

Para conferir maior assertividade a essas análises, destacam-se na literatura ferramentas e procedimentos de padronização. Sousa et al. (2018) apontam a modelagem de dados como a prática de representar as informações por meio de estruturas formais que possibilitam a análise e resolução de problemas, contribuindo para a melhoria de todo o sistema. Paralelamente, o mapeamento e o desenho de procedimentos operacionais possibilitam registrar de forma estruturada todas as etapas e componentes de uma análise, objetivando a padronização, a repetibilidade e o combate aos desperdícios de tempo (Francisconi, 2021).

Diante da segurança e dos resultados concretos que a gestão de dados proporciona, o presente trabalho justifica-se pela relevância acadêmica e prática da integração entre a Engenharia de Produção e a tecnologia de dados. O trabalho visa descrever, por meio de um Procedimento Operacional Padrão (POP), o passo a passo para a conexão, extração e análise de dados operacionais diretamente da fonte. Dessa forma, busca-se demonstrar que o Engenheiro de Produção possui a capacidade técnica de extrair e analisar informações para apoiar a tomada de decisões, diminuindo o tempo de resposta nas operações e promovendo a melhoria contínua.

A partir dessa problemática, formula-se a seguinte questão de pesquisa: De que maneira a extração de dados diretamente do banco de dados, combinada com as metodologias de Engenharia de Produção, pode contribuir para a autonomia analítica e a melhoria da tomada de decisão operacional?

A estrutura do trabalho foi organizada de modo que apresentasse a introdução, na qual é exposta uma abordagem inicial do assunto; o referencial teórico, com os conceitos de Sistemas de Informação Gerenciais (SIG), arquitetura de software e bancos de dados; a metodologia (POP) para execução do estudo; os resultados observados e, por fim, as considerações finais e referências bibliográficas.

2. Referencial Teórico

2.1 Sistemas de Informação e Sistemas Integrados de Gestão

Os sistemas de informação constituem um conjunto de recursos — incluindo pessoas, hardware, software, redes e dados — responsáveis por coletar, processar e disseminar informações dentro

das organizações (O'BRIEN, 2004). Conforme Laudon e Laudon (2014), esses sistemas podem ser classificados de acordo com o nível organizacional que suportam: os Sistemas de Processamento de Transações (SPT) registram as operações do cotidiano; os Sistemas de Informação Gerencial (SIG) consolidam dados transacionais em relatórios para o nível gerencial-médio; e os Sistemas de Apoio à Decisão (SAD) auxiliam análises não estruturadas para a alta administração. É importante distinguir o SIG — categoria funcional de sistema de informação voltada a relatórios consolidados — dos Sistemas Integrados de Gestão, denominados *Enterprise Resource Planning* (ERP). O ERP é uma plataforma corporativa que integra dados e processos de diferentes áreas funcionais da empresa em um único banco de dados, funcionando essencialmente como um SPT de escopo corporativo. Segundo Laudon e Laudon (2014), os sistemas ERP integram e coordenam os processos de negócios em todas as áreas funcionais da empresa, fornecendo uma visão única e em tempo real dos dados operacionais e financeiros.

Tais sistemas também atuam como mecanismos de feedback organizacional, permitindo o monitoramento do desempenho e o alinhamento com os objetivos estratégicos (STAIR; REYNOLDS, 2011).

No contexto organizacional, os sistemas de informação são classificados de acordo com o nível de suporte oferecido. De acordo com O'Brien (2004), destacam-se os Sistemas de Processamento de Transações (SPT), responsáveis pelo registro das operações diárias; os Sistemas de Informação Gerencial (SIG), utilizados para geração de relatórios e controle; e os Sistemas de Apoio à Decisão (SAD), voltados para análises mais complexas. Nesse cenário, os sistemas ERP consolidam essas funções ao integrar dados provenientes de diferentes áreas em uma única plataforma (LAUDON; LAUDON, 2014).

A utilização desses sistemas está diretamente relacionada ao pensamento sistêmico, que considera a organização como um conjunto de elementos interdependentes. Segundo Peter Senge (1990), o pensamento sistêmico permite compreender as inter-relações entre os processos organizacionais, favorecendo uma visão integrada das operações. Essa abordagem é fundamental para a Engenharia de Produção, uma vez que possibilita a análise conjunta dos diferentes fluxos produtivos e informacionais.

O funcionamento dos sistemas integrados de gestão está baseado no ciclo de transformação de dados em conhecimento. Conforme Stair e Reynolds (2011), os dados representam fatos brutos sem interpretação; ao serem processados e organizados, transformam-se em informações; e, quando analisadas e contextualizadas, essas informações geram conhecimento para a tomada de decisão. No ambiente produtivo, dados como tempos de ciclo, volumes de produção e

paradas de máquinas são coletados por sistemas transacionais e posteriormente processados pelos sistemas de informação, refletindo o desempenho operacional (LAUDON; LAUDON, 2014).

Dessa forma, os sistemas integrados de gestão, aliados ao uso estruturado de sistemas de informação, possibilitam a transformação de dados operacionais em informações estratégicas, sendo fundamentais para o planejamento, controle e melhoria contínua dos processos organizacionais.

2.2 Arquitetura de software

A arquitetura de software refere-se à estrutura organizacional dos sistemas, definindo como seus componentes são organizados e como interagem entre si. Segundo Len Bass, Paul Clements e Rick Kazman (2012), a arquitetura estabelece os elementos do sistema, suas relações e os princípios que orientam seu design e evolução, sendo fundamental para garantir desempenho, escalabilidade e manutenção. Um dos conceitos centrais é a separação em camadas, que organiza o sistema em níveis como apresentação, aplicação e dados. De acordo com Martin Fowler (2002), essa divisão reduz o acoplamento entre componentes, facilitando a manutenção e evolução dos sistemas.

Evoluindo esse conceito, a *Clean Architecture*, proposta por Robert C. Martin (2017), estabelece uma organização baseada na independência das camadas, na qual as regras de negócio são isoladas das dependências externas, como interfaces e bancos de dados. Nesse modelo, o banco de dados deve ser tratado como um detalhe de implementação, pertencente à camada de infraestrutura, e não como o centro da aplicação. No contexto dessa abordagem, o banco de dados assume o papel de infraestrutura, sendo responsável pelo armazenamento persistente das informações. Conforme C. J. Date (2004), a separação entre a camada de aplicação e a camada de dados é essencial para garantir integridade, segurança e independência das informações, permitindo que alterações no sistema não comprometam a estrutura da base de dados.

Essa organização arquitetural possibilita maior flexibilidade no acesso e manipulação dos dados, permitindo que ferramentas analíticas e usuários especializados realizem consultas diretamente na base de dados sem interferir na lógica operacional do sistema. Além disso, o uso de camadas bem definidas contribui para a escalabilidade e reutilização dos sistemas, aspectos fundamentais em ambientes organizacionais que dependem da análise contínua de grandes volumes de dados. Dessa forma, a arquitetura baseada em camadas e nos princípios da *Clean Architecture*, aliada à separação do banco de dados como componente de infraestrutura,

constitui um elemento essencial para garantir a organização, confiabilidade e acessibilidade das informações utilizadas na tomada de decisão.

2.3 Bancos de Dados (histórico, modelos, normalização, agregações e composições)

Os bancos de dados constituem a base para o armazenamento e gerenciamento de informações nas organizações, sendo fundamentais para o suporte à tomada de decisão. Historicamente, os primeiros modelos de banco de dados surgiram nas décadas de 1960 e 1970, com estruturas hierárquicas e em rede, evoluindo posteriormente para o modelo relacional, proposto por Edgar F. Codd (1970), que introduziu a organização dos dados em tabelas (relações) e estabeleceu princípios como integridade e independência dos dados. Segundo Ramez Elmasri e Shamkant Navathe (2016), os bancos de dados podem ser definidos como coleções organizadas de dados inter-relacionados, projetadas para atender às necessidades de informação de uma organização. O modelo relacional tornou-se amplamente adotado devido à sua simplicidade e robustez, permitindo a manipulação dos dados por meio da linguagem SQL. No entanto, com o crescimento do volume, variedade e velocidade dos dados, surgiram os bancos de dados não relacionais (NoSQL), que oferecem maior flexibilidade estrutural e escalabilidade. De acordo com Pramod J. Sadalage e Martin Fowler (2013), os bancos NoSQL são projetados para lidar com grandes volumes de dados distribuídos, sendo classificados em modelos como chave-valor, documentos, colunas e grafo, enquanto os bancos relacionais priorizam consistência e integridade, os NoSQL enfatizam escalabilidade e desempenho em ambientes distribuídos.

A organização eficiente dos dados em bancos relacionais depende do processo de normalização, que visa eliminar redundâncias e evitar inconsistências. Conforme proposto por Edgar F. Codd (1970), a normalização é estruturada em formas normais progressivas. A Primeira Forma Normal (1FN) exige que todos os atributos de uma tabela contenham apenas valores atômicos e indivisíveis, ou seja, sem grupos repetitivos ou listas em um único campo — por exemplo, uma tabela de ordens de produção não pode armazenar múltiplos componentes em uma única coluna; cada componente deve ocupar sua própria linha. A Segunda Forma Normal (2FN), aplicável a tabelas com chave primária composta, exige que todos os atributos não-chave dependam da chave primária inteira, e não apenas de parte dela — em uma tabela de itens de pedido com chave (id_pedido, id_produto), a descrição do produto depende apenas de id_produto e deve ser movida para uma tabela separada de produtos. A Terceira Forma Normal (3FN) elimina dependências transitivas, determinando que nenhum atributo não-chave dependa de outro atributo não-chave, por exemplo, se uma tabela de funcionários armazena o id_setor e o nome_setor, o nome_setor depende de id_setor (não diretamente da chave primária do

funcionário) e deve ser separado em uma tabela de setores. Segundo Elmasri e Navathe (2016), a aplicação dessas formas contribui para a integridade dos dados e para a eficiência das operações de consulta.

Além da estruturação dos dados, a análise das informações armazenadas depende de operações de consulta e manipulação. Em SQL, funções de agrupamento, como SUM, AVG, COUNT e GROUP BY, permitem resumir e sumarizar grandes volumes de dados, enquanto operações de junção (JOIN) possibilitam combinar registros de diferentes tabelas com base em chaves relacionadas (Date, 2004). Esses recursos são fundamentais para transformar dados operacionais em indicadores e apoiar a tomada de decisão. É importante não confundir esses mecanismos de consulta SQL com os conceitos estruturais de agregação e composição da modelagem de dados, que serão tratados no parágrafo seguinte e se referem à natureza dos vínculos entre entidades no modelo relacional e na UML.

Os relacionamentos entre entidades em um banco de dados relacional são classificados de acordo com sua cardinalidade. O relacionamento um para um (1:1) ocorre quando cada registro de uma entidade corresponde exatamente a um registro de outra, como a relação entre um funcionário e seu crachá. O relacionamento um para muitos (1:N) é o mais frequente: um setor, por exemplo, pode conter vários funcionários, mas cada funcionário pertence a um único setor. Já o relacionamento muitos para muitos (N:M), como entre produtos e fornecedores, em que um produto pode ser fornecido por vários fornecedores e um fornecedor pode atender vários produtos, exige a criação de uma tabela associativa para sua implementação (Elmasri; Navathe, 2016).

No que se refere à natureza dos vínculos entre entidades, a modelagem distingue dois conceitos fundamentais: agregação e composição. A agregação representa uma relação do tipo "tem um", na qual as partes existem independentemente do todo, como a relação entre fornecedor e pedido de compra, em que o fornecedor permanece cadastrado no sistema mesmo sem pedidos associados. A composição, por sua vez, representa uma relação do tipo "parte de", em que as partes não existem sem o todo, como os itens de uma ordem de produção, que perdem o sentido caso a ordem seja excluída. Em bancos relacionais, a composição é implementada com a cláusula ``ON DELETE CASCADE``; em bancos documentais como o MongoDB, é representada por documentos embutidos (Fowler; Sadalage, 2013).

Por fim, o conceito de persistência poliglota (polyglot persistence) representa uma tendência consolidada na arquitetura de sistemas modernos: em vez de adotar um único SGBD para todas as necessidades, as organizações utilizam diferentes bancos de dados para diferentes problemas dentro de uma mesma solução, bancos relacionais para dados transacionais estruturados, como

ERP e controle de estoque, e bancos documentais ou de séries temporais para dados de sensores, logs de produção e monitoramento em tempo real (FOWLER; SADALAGE, 2013).

2.4 Escolha do Sistema Gerenciador de Banco de Dados (SGBD) no contexto da Engenharia de Produção

A escolha do Sistema Gerenciador de Banco de Dados (SGBD) adequado constitui um fator estratégico para a eficiência na coleta, armazenamento, processamento e análise de dados operacionais. No contexto da Engenharia de Produção, diferentes processos industriais geram dados com características distintas, exigindo modelos de armazenamento compatíveis com o volume, a estrutura e a velocidade das informações produzidas.

Os bancos de dados relacionais, como PostgreSQL e MySQL, organizam as informações em tabelas estruturadas e inter-relacionadas, utilizando o modelo relacional proposto por Codd (1970). Esses sistemas priorizam a integridade dos dados e a consistência transacional por meio das propriedades ACID (Atomicidade, Consistência, Isolamento e Durabilidade), sendo amplamente utilizados em aplicações corporativas e sistemas ERP. Segundo Elmasri e Navathe (2016), os bancos relacionais são especialmente indicados para cenários em que os dados possuem estrutura bem definida e relacionamentos consistentes, como ordens de produção, controle de estoque, cadastro de fornecedores e apontamentos de produção.

Entre os principais SGBDs relacionais, destaca-se o PostgreSQL, reconhecido pela robustez, conformidade com padrões SQL e suporte avançado a consultas complexas e análises analíticas. Já o MySQL possui ampla adoção em aplicações corporativas devido à simplicidade de administração, desempenho operacional e facilidade de integração com sistemas web e aplicações empresariais.

Com o crescimento do volume e da variedade de dados industriais, surgiram os bancos de dados não relacionais (NoSQL), projetados para oferecer maior flexibilidade estrutural e escalabilidade horizontal. Diferentemente dos bancos relacionais, os bancos NoSQL não exigem um esquema rígido de tabelas, permitindo armazenar dados heterogêneos e semi estruturados. Conforme Fowler e Sadalage (2013), esses sistemas são particularmente úteis em ambientes de alta variabilidade e grande volume de dados.

O MongoDB, por exemplo, utiliza o modelo documental, armazenando informações em documentos no formato JSON/BSON. Essa característica permite registrar dados com estruturas variáveis, tornando-o adequado para aplicações industriais como inspeções de qualidade, registros de manutenção, logs operacionais e dados provenientes de dispositivos IoT. Já o Cassandra adota o modelo orientado a colunas distribuídas, sendo otimizado para

aplicações com elevada taxa de escrita e necessidade de alta disponibilidade, como sistemas de monitoramento contínuo de máquinas e coleta massiva de dados em tempo real.

A definição do SGBD mais adequado deve considerar critérios como volume de dados, velocidade de geração das informações, necessidade de consistência, flexibilidade estrutural e complexidade dos relacionamentos existentes. Em muitos cenários industriais, diferentes bancos podem coexistir em uma mesma arquitetura computacional, conceito conhecido como persistência poliglota (polyglot persistence), no qual cada tecnologia é utilizada conforme sua especialidade funcional (Fowler; Sadalage, 2013).


Além disso, a escolha do banco de dados impacta diretamente as ferramentas utilizadas para administração e análise dos dados. Em aplicações voltadas à Engenharia de Produção, é comum a integração entre SGBDs, ferramentas gráficas de gerenciamento e bibliotecas Python voltadas à extração e manipulação de dados. O Quadro 1 apresenta uma síntese comparativa dos principais SGBDs estudados, enquanto a figura 1 apresenta as decisões para escolher o SGDB ideal.

Quadro 1 - Principais Sistemas Gerenciadores de Banco de Dados

SGBD	Modelo	Exemplo de Uso na Produção Industrial
PostgreSQL	Relacional	Ordens de produção, controle de estoque, apontamento de produção, cadastro de produtos e indicadores de desempenho (OEE, taxa de refugo).
MySQL	Relacional	Registro de fornecedores, controle de entrada e saída de materiais, planejamento da produção (MRP) e histórico de manutenções.
MongoDB	Não relacional (Documental)	Logs de paradas de máquina, registros de inspeção de qualidade com campos variáveis, dados de sensores IoT e rastreabilidade de lotes.
Cassandra	Não relacional (Colunar)	Monitoramento contínuo de equipamentos em larga escala, coleta de dados de múltiplas linhas de produção simultaneamente e séries temporais de alto volume.

Fonte: Elaborado pelos autores.

Figura 1 — Fluxograma de escolha do SGDB



Fontes: Elaborado pelos autores.

Na Engenharia de Produção, os bancos NoSQL tornam-se especialmente relevantes em situações nas quais os bancos relacionais apresentam limitações estruturais ou de desempenho. Um exemplo ocorre nos registros de inspeção de qualidade, em que diferentes produtos podem possuir conjuntos distintos de atributos avaliados. Em bancos relacionais, essa variabilidade frequentemente resulta em tabelas com grande quantidade de campos nulos ou na necessidade

de múltiplas tabelas auxiliares. Em bancos documentais, como o MongoDB, cada documento pode armazenar apenas os atributos necessários, aumentando a flexibilidade do sistema.

Outro cenário típico refere-se ao monitoramento industrial em tempo real. Sensores instalados em equipamentos podem gerar milhares de registros por segundo relacionados à temperatura, vibração, pressão e consumo energético. Nesses casos, bancos distribuídos como Cassandra apresentam melhor desempenho devido à capacidade de processamento paralelo e elevada taxa de escrita.

Os bancos NoSQL também apresentam vantagens em aplicações envolvendo rastreabilidade complexa e análise de redes produtivas. Em cadeias produtivas integradas, um componente pode estar relacionado simultaneamente a fornecedores, ordens de produção, lotes e produtos finais. Estruturas dessa natureza tendem a gerar consultas complexas em modelos relacionais tradicionais, favorecendo a adoção de bancos orientados a grafos em aplicações específicas.

Dessa forma, a seleção do SGBD deve estar alinhada às características operacionais do sistema produtivo e aos objetivos analíticos da organização. A compreensão das diferenças entre bancos relacionais e não relacionais amplia a autonomia técnica do Engenheiro de Produção, permitindo que o profissional escolha tecnologias mais adequadas para transformar dados operacionais em informações estratégicas para a tomada de decisão.


3. Metodologia

Esta pesquisa caracteriza-se como aplicada de natureza demonstrativa, com abordagem qualitativa. Do ponto de vista dos objetivos, é simultaneamente descritiva, pois sistematiza e documenta um procedimento técnico, e exploratória, uma vez que investiga a aplicabilidade do acesso direto a bancos de dados como prática autônoma do engenheiro de produção (GIL, 2002). Quanto aos procedimentos técnicos, o trabalho não se enquadra como estudo de caso no sentido clássico de Yin (2015), que pressupõe a investigação de um fenômeno em seu contexto organizacional real com múltiplas fontes de evidência. Trata-se, antes, de uma pesquisa demonstrativa: o procedimento operacional proposto é executado sobre um dataset estruturado, utilizado como material empírico para validação do método.

A fonte de dados consiste em um conjunto de dados representativo de um ambiente de produção industrial, disponibilizado pelo docente responsável pela disciplina. Essa abordagem é metodologicamente coerente: um Procedimento Operacional Padrão (POP), por definição, deve ser elaborado de forma independente dos dados específicos sobre os quais será aplicado, garantindo sua replicabilidade a diferentes contextos organizacionais (ABNT NBR ISO 9001, 2015).

Para garantir a repetibilidade, a qualidade e a rastreabilidade do procedimento de extração de dados, as etapas metodológicas deste trabalho foram estruturadas em um fluxo lógico e sequencial. A Figura 1 apresenta o fluxograma do Procedimento Operacional Padrão proposto, detalhando desde a conexão inicial com o Banco de Dados até a conversão final dos dados brutos em conhecimento estratégico para a tomada de decisão. Este mapeamento visual serve como guia para que o engenheiro de produção execute a análise de forma autônoma e padronizada.

Figura 2 — Fluxograma metodológico da pesquisa.



Fonte: Elaborado pelos autores.

O POP a ser executado está estruturado nas seguintes fases:

1. Fase 1: Conexão ao banco de dados: após o recebimento do dataset pelo docente, identificou-se o SGBD utilizado e estabeleceu-se a conexão por meio da biblioteca Python compatível (psycopg2 para PostgreSQL, mysql-connector para MySQL ou pymongo para MongoDB), configurando-se a string de conexão com os parâmetros

fornecidos (host, porta, nome do banco, usuário e senha), e a conectividade será verificada por meio de uma consulta de teste.

2. Fase 2 - Exploração da estrutura: uma vez conectado, realizou-se a inspeção do esquema do banco de dados, identificando tabelas ou coleções disponíveis, tipos de dados, chaves primárias, chaves estrangeiras e relacionamentos existentes. Essa fase resultou na elaboração de um diagrama do modelo de dados, elaborado como evidência do entendimento da estrutura antes da extração.
3. Fase 3 - Extração dos dados: com base na estrutura identificada na fase anterior, foram desenvolvidas consultas em SQL ou pipelines de agregação (MongoDB), conforme o SGBD adotado com o objetivo de recuperar os dados relevantes para a análise. As queries foram documentadas e comentadas no artigo, explicitando sua finalidade e os conceitos teóricos que aplicam, tais como normalização, agregação e composição.
4. Fase 4 - Análise e geração de indicadores: os dados extraídos foram carregados em estruturas do tipo DataFrame, utilizando a biblioteca pandas, para tratamento, limpeza e análise, resultando em indicadores de Engenharia de Produção pertinentes ao contexto do dataset, conforme as variáveis disponíveis.
5. Fase 5 - Interpretação e recomendação: os indicadores obtidos foram interpretados conforme os fundamentos de SIG estudados, completando o ciclo dado → informação → conhecimento → decisão. Os resultados foram consolidados e apresentados por meio de tabelas e gráficos e discutidos na seção de resultados do artigo.

O procedimento foi executado com as seguintes ferramentas: linguagem Python (versão 3.13), com as bibliotecas pandas para manipulação de dados e a biblioteca de conexão compatível com o SGBD adotado (psycopg2 para PostgreSQL, mysql-connector para MySQL ou pymongo para MongoDB). O ambiente de desenvolvimento utilizado foi Jupyter Notebook, e o versionamento do trabalho foi realizado com Git, com repositório hospedado no GitHub.

4. Resultados Esperados

A partir da execução das cinco fases do POP sobre o dataset disponibilizado pelo docente, espera-se obter um conjunto de indicadores operacionais relevantes ao contexto produtivo representado pelos dados. Entre os resultados previstos, destacam-se: (i) a conexão bem-sucedida ao SGBD identificado, com registro da string de conexão e tratamento de erros; (ii) o diagrama do modelo de dados com as tabelas, relacionamentos de cardinalidade e natureza dos vínculos (agregação ou composição), construído a partir da exploração da estrutura real do banco; (iii) as consultas SQL ou pipelines NoSQL documentados e comentados, evidenciando

a aplicação dos conceitos de normalização, junções e agrupamentos; (iv) indicadores de Engenharia de Produção gerados via pandas, tais como tempo médio entre falhas (MTBF), taxa de refugo, volumes de produção por período ou outros índices pertinentes às variáveis disponíveis; e (v) gráficos e tabelas síntese que traduzam os dados brutos em informação gerencial, completando o ciclo dado → informação → conhecimento → decisão proposto por Stair e Reynolds (2011).

Espera-se, ainda, que a execução do POP demonstre a viabilidade técnica e metodológica da extração autônoma de dados pelo Engenheiro de Produção, reduzindo a dependência das equipes de TI e promovendo maior agilidade na tomada de decisão operacional. Os artefatos produzidos, código Python versionado no GitHub, diagrama ER e relatório de indicadores, constituirão evidências concretas da aplicabilidade do procedimento proposto.

5. Considerações Finais

O presente trabalho propôs e estruturou um Procedimento Operacional Padrão (POP) para a extração autônoma de dados operacionais diretamente de bancos de dados relacionais e não relacionais, com o objetivo de ampliar a autonomia analítica do Engenheiro de Produção. A fundamentação teórica articulou conceitos de sistemas de informação, arquitetura de software e modelagem de dados, evidenciando que o acesso direto às fontes primárias de dados é tecnicamente viável e metodologicamente estruturável. O POP proposto, estruturado em cinco fases sequenciais: conexão, exploração, extração, análise e interpretação, demonstra que o Engenheiro de Produção possui a capacidade técnica de acessar fontes primárias de dados e transformá-los em indicadores estratégicos, completando o ciclo dado → informação → conhecimento → decisão descrito por Stair e Reynolds (2011). A padronização desse processo por meio de um POP garante ainda a repetibilidade e a rastreabilidade das análises, princípios fundamentais para a melhoria contínua nos ambientes produtivos (ABNT NBR ISO 9001, 2015). Como desdobramento futuro, a N2 deste trabalho apresentará a execução completa do POP sobre o dataset real fornecido pelo docente, incluindo o diagrama ER, os códigos Python documentados e os indicadores gerados, consolidando as evidências empíricas do procedimento aqui proposto.

REFERÊNCIAS

- ABNT — ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. NBR ISO 9001: sistemas de gestão da qualidade — requisitos. Rio de Janeiro: ABNT, 2015.
- BASS, Len; CLEMENTS, Paul; KAZMAN, Rick. *Software Architecture in Practice*. 3. ed. Boston: Addison-Wesley, 2012.
- CARVALHO, R. B. Competências do Engenheiro de Produção na Indústria 4.0. *Informativo da Gestão da Produção*, 2019.
- CIOLACU, M. et al. Education 4.0: Fostering student's performance with machine learning methods. In: IEEE International Conference on E-Health Networking, Application & Services, 2017. Anais... [S. l.]: IEEE, 2017.
- CODD, E. F. A relational model of data for large shared data banks. *Communications of the ACM*, v. 13, n. 6, p. 377–387, 1970.
- DATE, C. J. *Introdução a Sistemas de Banco de Dados*. 8. ed. Rio de Janeiro: Elsevier, 2004.
- ELMASRI, R.; NAVATHE, S. B. *Sistemas de banco de dados*. 7. ed. São Paulo: Pearson, 2016.
- FOWLER, M.; SADALAGE, P. J. *NoSQL distilled: a brief guide to the emerging world of polyglot persistence*. Boston: Addison-Wesley, 2013.
- FOWLER, Martin. *Patterns of Enterprise Application Architecture*. Boston: Addison-Wesley, 2002.
- FRANCISCONI, L. M. *Modelagem e análise de processos produtivos*. Rio de Janeiro: Elsevier, 2021.
- FUKUDA, D. O.; MARIZ, F. B. A. R.; MESQUITA, M. A. Impactos da Indústria 4.0 na Gestão de Operações. In: Encontro Nacional de Engenharia de Produção (ENEGEP), 37., 2017, Joinville. Anais... Rio de Janeiro: ABEPRO, 2017.
- GIL, A. C. *Como elaborar projetos de pesquisa*. 4. ed. São Paulo: Atlas, 2002.
- KAGERMANN, H.; WAHLSTER, W.; HELBIG, J. *Recommendations for implementing the strategic initiative Industrie 4.0*. Frankfurt: Acatech, 2013.
- LAUDON, Kenneth C.; LAUDON, Jane P. *Sistemas de informação gerenciais*. 11. ed. São Paulo: Pearson Prentice Hall, 2014.
- MARTIN, Robert C. *Clean Architecture: A Craftsman's Guide to Software Structure and Design*. Boston: Prentice Hall, 2017.
- O'BRIEN, James A. *Sistemas de informação e as decisões gerenciais na era da internet*. 2. ed. São Paulo: Saraiva, 2004.

SACKEY, S. M. et al. Challenges and opportunities in engineering education for Industry 4.0. *Global Journal of Engineering Education*, v. 18, n. 1, p. 38-45, 2016.

SENGE, Peter M. *A quinta disciplina: arte e prática da organização que aprende*. São Paulo: Best Seller, 1990.

SOUSA, A. L. et al. Aplicação da modelagem matemática na otimização de sistemas industriais. *Gestão & Produção*, v. 25, n. 4, p. 770-784, 2018.

STAIR, Ralph M.; REYNOLDS, George W. *Princípios de sistemas de informação*. 9. ed. São Paulo: Cengage Learning, 2011.

YIN, R. K. *Estudo de caso: planejamento e métodos*. 5. ed. Porto Alegre: Bookman, 2015.