

FACULDADE DE CIÊNCIAS E TECNOLOGIA – CÂMPUS APARECIDA DE GOIÂNIA

Curso de Engenharia de Produção – Práticas em Engenharia de Produção

Procedimento Operacional Padrão para extração e análise de dados diretamente em bancos de dados relacionais e documentais em contextos de Engenharia de Produção

Guilherme Alves Mousinho

Vinycius Cirilo Machado Pêgo

Faculdade de Ciências e Tecnologia – Câmpus Aparecida de Goiânia

Resumo

O engenheiro de produção opera em ambientes industriais altamente instrumentados, nos quais a tomada de decisão depende cada vez menos de relatórios estáticos e cada vez mais do acesso direto à fonte primária dos dados: o banco de dados (BD) operacional. Este artigo apresenta a fundamentação teórica de um Procedimento Operacional Padrão (POP) para acesso, extração e análise de dados diretamente em SGBDs relacionais e documentais, aplicado ao contexto da Engenharia de Produção. Discutem-se os fundamentos de Sistemas de Informação Gerencial (SIG), a arquitetura de software em camadas que posiciona o BD como camada de infraestrutura desacoplada, a evolução histórica dos bancos de dados desde os modelos hierárquicos até a polyglot persistence, a comparação entre os paradigmas relacional (SQL) e documental (NoSQL), os princípios de normalização (1FN, 2FN, 3FN) e os conceitos de agregação e composição na modelagem de dados. Apresenta-se ainda o procedimento metodológico planejado para a etapa prática (N2), incluindo as ferramentas de conexão, as bibliotecas Python a serem utilizadas e a estrutura preliminar das queries em PostgreSQL e MongoDB. Conclui-se que o domínio do acesso direto ao BD é uma competência analítica essencial para o engenheiro de produção, viabilizando o ciclo dado–informação–conhecimento–decisão com autonomia, rastreabilidade e velocidade.

Palavras-chave: Banco de dados. Engenharia de Produção. PostgreSQL. MongoDB. Sistemas de Informação Gerencial.

1. Introdução

A transformação digital da indústria, frequentemente associada ao paradigma da Indústria 4.0, alterou de forma estrutural a relação entre o engenheiro de produção e os dados que sustentam sua atividade. Sensores instrumentam linhas de montagem, sistemas integrados de gestão (ERP) registram cada movimentação de estoque e cada apontamento de ordem de produção, e plataformas de manufatura conectada produzem séries temporais com granularidade de segundos. Diante desse volume e dessa velocidade, a prática histórica de receber relatórios já consolidados, em formato de planilha ou dashboard fechado, tornou-se uma restrição relevante para a tomada de decisão fundamentada.

Quando o engenheiro de produção depende exclusivamente de camadas intermediárias entre ele e o dado, três limitações se manifestam de forma recorrente. Primeiro, o dado chega filtrado: alguém, em algum momento, decidiu quais campos seriam exportados e quais seriam ocultados, e essa decisão raramente é revista. Segundo, o dado chega atrasado: relatórios diários ou semanais carregam, por construção, a defasagem do seu ciclo de geração. Terceiro,

o dado chega agregado: médias, totais e percentuais escondem precisamente a dispersão e os outliers que o engenheiro precisa investigar.

Diante dessas limitações, o acesso direto ao banco de dados (BD) operacional emerge como uma competência analítica diferenciadora. O engenheiro que escreve suas próprias consultas, que compreende a modelagem das tabelas e coleções, e que articula essas extrações com ferramentas de análise estatística, conquista autonomia para responder questões de produção em ciclos curtos, sem depender da intermediação da área de Tecnologia da Informação para cada nova pergunta.

Este artigo apresenta a fundamentação teórica de um Procedimento Operacional Padrão (POP) para acesso, extração e análise de dados diretamente em SGBDs, no contexto da Engenharia de Produção. O trabalho está estruturado em duas etapas avaliativas: a primeira, aqui apresentada (N1), corresponde à construção teórica e ao planejamento metodológico do procedimento; a segunda (N2) consistirá na execução prática do POP sobre um dataset real fornecido pelo professor. O objetivo desta primeira entrega é demonstrar domínio conceitual sobre Sistemas de Informação Gerencial, arquitetura de software, modelagem de dados e mecanismos de conexão a bancos relacionais e documentais, de modo a embasar tecnicamente a execução da etapa prática.

O artigo está organizado da seguinte forma: a Seção 2 apresenta a fundamentação teórica, abordando SIG, arquitetura de software e bancos de dados; a Seção 3 detalha a metodologia proposta para a parte prática, incluindo o procedimento de conexão e as queries planejadas; e a Seção 4 apresenta as considerações finais desta etapa.

2. Fundamentação Teórica

2.1 Sistemas de Informação Gerencial e pensamento sistêmico

Um Sistema de Informação Gerencial (SIG) é, segundo Laudon e Laudon (2014), um conjunto integrado de componentes — pessoas, processos, tecnologia e dados — que coletam, processam, armazenam e disseminam informações para apoiar a tomada de decisão e o controle em uma organização. No contexto da Engenharia de Produção, os SIGs materializam-se em sistemas ERP (Enterprise Resource Planning), MES (Manufacturing Execution System), WMS (Warehouse Management System) e ferramentas de Business Intelligence, todos sustentados por bancos de dados que constituem sua camada de persistência.

O pensamento sistêmico, fundamento dos SIGs, propõe que organizações sejam compreendidas como sistemas abertos, com entradas, processos de transformação, saídas e mecanismos de retroalimentação. Sob essa ótica, o BD não é um repositório passivo: ele é o nó de articulação entre os subsistemas operacionais e os subsistemas analíticos. O ciclo clássico dado–informação–conhecimento–decisão, descrito por Davenport e Prusak (1998), encontra no BD seu ponto de origem: o dado bruto, registrado por um apontamento de produção ou pela leitura de um sensor, é refinado em informação por meio de queries e agregações; é convertido em conhecimento quando contextualizado por modelos analíticos; e finalmente subsidia a decisão gerencial.

A governança de TI, por sua vez, estabelece as políticas que regulam o acesso ao BD: quem pode ler, quem pode escrever, sob quais regras de segurança e auditoria. Para o engenheiro de produção, compreender essa governança é tão importante quanto dominar a sintaxe das consultas, pois é ela que define os limites legítimos da autonomia analítica dentro da organização.

2.2 Arquitetura de software e o banco de dados como camada de infraestrutura

A arquitetura em camadas é o padrão dominante de organização de sistemas corporativos e parte da premissa de separar responsabilidades em estratos com baixo acoplamento e alta coesão. Em sua formulação tradicional, identificam-se três camadas: apresentação (interface com o usuário), aplicação ou negócio (regras de domínio) e persistência ou infraestrutura (acesso ao banco de dados). Variações como o padrão MVC (Model-View-Controller), a arquitetura hexagonal de Cockburn (2005) e a Clean Architecture de Martin (2017) refinam essa separação, mas mantêm o princípio central: o banco de dados é um detalhe de infraestrutura, e não o núcleo do negócio.

Essa visão tem consequências práticas para o engenheiro de produção. Primeiro, ela esclarece que diferentes sistemas podem compartilhar o mesmo BD, ou que um mesmo sistema pode trocar de SGBD sem que sua lógica de negócio seja afetada. Segundo, ela justifica que o acesso analítico direto ao BD — desde que mediado por usuários de leitura e por políticas de segurança — é uma prática arquiteturalmente legítima, pois opera na camada de infraestrutura sem violar a integridade das camadas superiores. Terceiro, ela aponta que o engenheiro analítico deve compreender o modelo de dados (a estrutura do BD), não apenas o modelo de domínio exposto pela aplicação.

2.3 Evolução histórica dos bancos de dados

A trajetória dos bancos de dados acompanha a evolução das necessidades computacionais das organizações. Na década de 1960, os sistemas de arquivos sequenciais e os bancos hierárquicos, como o IMS (Information Management System) da IBM, organizavam os dados em estruturas de árvore rígidas, otimizadas para consultas previsíveis mas pouco flexíveis para análises ad hoc. Em 1970, Edgar F. Codd publicou seu artigo seminal “A Relational Model of Data for Large Shared Data Banks”, propondo o modelo relacional, no qual os dados são organizados em tabelas (relações) compostas por linhas (tuplas) e colunas (atributos), e os relacionamentos são expressos por chaves primárias e estrangeiras.

Nas décadas de 1980 e 1990, o modelo relacional consolidou-se como padrão de fato, sustentado pela linguagem SQL (Structured Query Language) e pelo surgimento de SGBDs robustos como Oracle, IBM DB2, PostgreSQL e MySQL. A garantia transacional ACID — Atomicidade, Consistência, Isolamento e Durabilidade — tornou-se sinônimo de integridade em sistemas corporativos, especialmente nos contextos financeiro e industrial.

A partir dos anos 2000, novos requisitos passaram a desafiar o paradigma relacional. Aplicações web de larga escala, dispositivos de Internet das Coisas (IoT), redes sociais e plataformas de comércio eletrônico geraram volumes, velocidades e variedades de dados (os “três Vs” do Big Data) que tensionavam tanto o esquema rígido quanto a escalabilidade vertical dos sistemas relacionais. Nesse contexto emergiu o movimento NoSQL (“Not only SQL”),

com famílias distintas: bancos documentais (MongoDB, Couchbase), bancos de família de colunas (Cassandra, HBase), bancos de chave-valor (Redis, DynamoDB) e bancos de grafos (Neo4j).

Na década de 2010 e seguintes, consolidou-se o conceito de polyglot persistence, formulado por Fowler e Sadalage (2012): em vez de adotar um único SGBD para todos os problemas, as organizações passam a combinar diferentes tipos de banco conforme a natureza dos dados e dos acessos. Um mesmo ambiente industrial pode, por exemplo, manter um PostgreSQL para o ERP transacional, um MongoDB para registros de IoT e um Redis para cache de consultas frequentes. Para o engenheiro de produção, isso significa que dominar um único paradigma não é mais suficiente: é necessário compreender as características de cada família e saber quando aplicá-la.

2.4 Estrutura de dados: paradigma relacional versus documental

A comparação entre os paradigmas relacional e documental é o ponto de referência metodológico deste trabalho, que adota uma abordagem comparativa entre PostgreSQL e MongoDB. A Tabela 1 sintetiza as principais distinções entre esses dois paradigmas.

Tabela 1: Comparação entre os paradigmas relacional e documental

Aspecto	Relacional (SQL)	Documental (NoSQL)
Unidade básica	Tabela com linhas e colunas	Documento em JSON/BSON
Esquema	Rígido, definido a priori	Flexível, schema-less
Relacionamentos	Chaves estrangeiras + JOINS	Documentos embutidos ou referências
Transações	ACID — consistência forte	BASE — consistência eventual
Escalabilidade	Predominantemente vertical	Predominantemente horizontal
Linguagem	SQL (padrão ISO)	API/JSON específica do SGBD
Caso de uso típico em EP	ERP, controle de estoque, financeiro	Telemetria de IoT, logs de produção, sensores

Fonte: Adaptado do material da disciplina.

A escolha entre os dois paradigmas raramente é binária. Em muitos cenários industriais, ambos coexistem: o PostgreSQL armazena a ordem de produção e seus itens em tabelas normalizadas, enquanto o MongoDB armazena, em coleções flexíveis, a série temporal de leituras de sensor associada à mesma ordem. O POP descrito neste trabalho contempla deliberadamente essa coexistência, propondo procedimentos de conexão e extração para ambos os SGBDs.

2.5 Normalização e relacionamentos

A normalização, proposta por Codd como complemento ao modelo relacional, é o conjunto de regras que orienta a decomposição de tabelas de modo a eliminar redundâncias e anomalias de inserção, atualização e exclusão. As três formas normais clássicas, suficientes para a maioria dos casos práticos, são descritas a seguir.

Primeira Forma Normal (1FN): exige que cada célula da tabela contenha um valor atômico. Listas, grupos repetitivos ou campos multivalorados violam a 1FN. Em um cenário de produção, um campo “componentes” contendo “rolamento; eixo; mola” deve ser decomposto em uma tabela filha com um componente por linha.

Segunda Forma Normal (2FN): requer que a tabela esteja em 1FN e que todo atributo não-chave dependa da chave primária completa, não apenas de parte dela. É relevante em tabelas com chave composta. Por exemplo, em uma tabela “itens_ordem” com chave (ordem_id, item_id), o nome do produto depende apenas de item_id e, portanto, deve migrar para a tabela “produtos”.

Terceira Forma Normal (3FN): exige que a tabela esteja em 2FN e que nenhum atributo não-chave dependa de outro atributo não-chave. Por exemplo, em uma tabela de “funcionários” com os campos setor_id e nome_setor, o nome do setor depende de setor_id (não da chave do funcionário) e deve migrar para uma tabela “setores”.

A normalização produz, como subproduto, os relacionamentos entre tabelas. A Tabela 2 sumariza os três tipos clássicos com exemplos contextualizados em Engenharia de Produção.

Tabela 2: Tipos de relacionamento e exemplos em Engenharia de Produção

Cardinalidade	Exemplo	Implementação
1:1	Funcionário ↔ Crachá	FK única e exclusiva (UNIQUE) na tabela filha
1:N	Setor ↔ Funcionários	FK na tabela do lado N apontando para a chave primária do lado 1
N:M	Produto ↔ Fornecedor	Tabela associativa contendo as duas FKs como chave composta

Fonte: Elaborada pelo autor a partir do material da disciplina.

2.6 Agregação e composição na modelagem de dados

Para além das formas normais, a modelagem de dados se enriquece com os conceitos de agregação e composição, originalmente formulados no contexto da modelagem orientada a objetos (UML) e diretamente aplicáveis ao desenho de bancos de dados.

A agregação representa uma relação do tipo “tem um” na qual as partes existem de forma independente do todo. O exemplo clássico em Engenharia de Produção é a relação entre Fornecedor e Pedido de Compra: o fornecedor existe na base como entidade autônoma e continua existindo mesmo que não haja, no momento, nenhum pedido associado a ele. Em SGBDs relacionais, essa relação é implementada por uma chave estrangeira convencional, sem regras de exclusão em cascata; em MongoDB, é tipicamente implementada por uma referência via ObjectId entre coleções distintas.

A composição, por sua vez, representa uma relação “parte de” mais forte, na qual as partes não fazem sentido fora do todo e devem ser excluídas junto com ele. O exemplo recorrente é a relação entre Ordem de Produção e seus Itens: cada item existe em função de uma ordem específica e não tem sentido como entidade isolada. No PostgreSQL, essa relação é implementada com chave estrangeira acrescida de ON DELETE CASCADE, garantindo que a remoção da ordem propague a remoção de seus itens. No MongoDB, a forma idiomática é o

documento embutido (embedded document), no qual os itens compõem um array dentro do documento da ordem, sendo fisicamente armazenados junto com ela.

A distinção entre agregação e composição não é meramente teórica: ela orienta decisões concretas de modelagem que afetam o desempenho das consultas, a complexidade das regras de integridade e a robustez do procedimento de extração descrito neste POP.

3. Metodologia Proposta

Esta seção apresenta o procedimento metodológico planejado para a execução prática do POP, a ser realizada na etapa N2. O procedimento é descrito de forma a permitir reprodutibilidade por outro profissional que disponha das mesmas ferramentas e do mesmo dataset.

3.1 Fonte dos dados

Os dados utilizados na etapa prática serão provenientes do dataset disponibilizado pelo professor da disciplina, contendo informações típicas de um ambiente fabril: ordens de produção, apontamentos de tempo de ciclo, linhas de montagem, registros de paradas e parâmetros de qualidade. A opção pelo dataset do professor justifica-se pela necessidade de garantir a reprodutibilidade do procedimento e pela conveniência de evitar exposição de dados sensíveis de organizações reais, respeitando, ainda que indiretamente, os princípios da Lei Geral de Proteção de Dados (LGPD).

3.2 Ferramentas e bibliotecas

O procedimento adotará a linguagem Python como ambiente unificado de conexão e análise, em virtude de seu ecossistema consolidado para ciência de dados e da disponibilidade de drivers oficiais para os dois SGBDs contemplados. As bibliotecas utilizadas são apresentadas na Tabela 3.

Tabela 3: Ferramentas e bibliotecas planejadas para a etapa prática

Camada	Ferramenta	Função no procedimento
SGBD relacional	PostgreSQL 16	Armazenamento dos dados estruturados de produção
SGBD documental	MongoDB 7	Armazenamento de séries de apontamento e eventos
Cliente gráfico	DBeaver / MongoDB Compass	Inspeção visual do esquema e prototipagem de queries
Driver Python (SQL)	psycopg2	Conexão e execução de consultas no PostgreSQL
Driver Python (NoSQL)	pymongo	Conexão e execução de pipelines no MongoDB
Análise tabular	pandas	Manipulação dos DataFrames resultantes
Visualização	matplotlib / seaborn	Geração dos gráficos de indicadores

Fonte: Elaborada pelo autor.

3.2.1 Procedimento de conexão ao PostgreSQL

A conexão ao PostgreSQL é estabelecida via biblioteca psycopg2, que implementa o driver oficial da linguagem Python para o SGBD. O procedimento envolve a definição dos

parâmetros de conexão (host, porta, nome do banco, usuário e senha), a abertura da conexão, a execução da query e o fechamento explícito da conexão para liberação do recurso. A Figura 1 apresenta o esqueleto de código planejado.

Figura 1: Esqueleto de conexão e consulta ao PostgreSQL em Python

```
import psycopg2
import pandas as pd

conn = psycopg2.connect(
    host="servidor.empresa.com",
    port=5432,
    dbname="producao",
    user="eng_producao",
    password="***"
)

query = """
SELECT linha,
       COUNT(*)           AS total_ordens,
       AVG(tempo_ciclo) AS tempo_medio
FROM   ordens_producao
WHERE  data >= '2026-01-01'
GROUP BY linha
ORDER BY tempo_medio DESC;
"""

df = pd.read_sql(query, conn)
print(df.describe())
conn.close()
```

Fonte: Adaptado do material da disciplina.

A query exemplificada aplica três conceitos teóricos discutidos na Seção 2: a agregação SQL (COUNT, AVG) operando sobre dados normalizados, o agrupamento (GROUP BY) que materializa a abstração de “linha de montagem” como entidade analítica, e a filtragem temporal (WHERE) que permite recortar séries históricas para análise comparativa entre períodos.

3.2.2 Procedimento de conexão ao MongoDB

A conexão ao MongoDB é estabelecida via biblioteca pymongo, que expõe a API de coleções e o framework de agregação do SGBD. O paradigma documental dispensa o JOIN, mas oferece, em contrapartida, o pipeline de agregação, no qual estágios sucessivos (\$match, \$group, \$sort, \$project) processam os documentos de forma análoga a uma cadeia de operações de transformação. A Figura 2 apresenta o esqueleto de código planejado.

Figura 2: Esqueleto de conexão e pipeline de agregação no MongoDB em Python

```
from pymongo import MongoClient
import pandas as pd

client = MongoClient("mongodb://host:27017/")
db = client["producao"]

pipeline = [
    {"$match": {"status": "concluida"}},
    {"$group": {
        "_id": "$linha_montagem",
```

```

        "total":      {"$sum": 1},
        "media_ciclo": {"$avg": "$tempo_ciclo_s"}
    }},
    {"$sort": {"total": -1}}
]

resultado = list(db.ordens.aggregate(pipeline))
df = pd.DataFrame(resultado)
print(df)
client.close()

```

Fonte: Adaptado do material da disciplina.

O pipeline acima é funcionalmente equivalente à query SQL apresentada na seção anterior, o que evidencia uma propriedade importante para o engenheiro de produção: indicadores semelhantes podem ser computados em paradigmas distintos, e a escolha entre eles depende mais da estrutura nativa do dado do que da operação analítica em si.

3.3 Etapas do procedimento operacional padrão

O POP propriamente dito, a ser executado na etapa N2, organiza-se em cinco etapas sequenciais, cada uma com produtos verificáveis. A Tabela 4 resume essas etapas.

Tabela 4: Etapas do POP e evidências esperadas

Etapa	O que fazer	Evidência no artigo final (N2)
1. Conectar	Estabelecer conexão segura ao SGBD escolhido	Bloco de código e captura de tela da conexão bem-sucedida
2. Explorar	Mapear a estrutura: tabelas, colunas, coleções, campos	Diagrama do modelo de dados (ER ou diagrama de coleções)
3. Extrair	Escrever queries ou pipelines para obter os dados relevantes	Código SQL ou pipeline MongoDB documentado
4. Analisar	Gerar indicadores típicos de Engenharia de Produção	Tabelas e gráficos com OEE, tempo de ciclo, refugo, etc.
5. Interpretar	Transformar dados em informação e recomendação	Seção de discussão com recomendações fundamentadas

Fonte: Elaborada pelo autor a partir do material da disciplina.

Esse encadeamento materializa, no plano operacional, o ciclo dado–informação–conhecimento–decisão discutido na fundamentação teórica. As três primeiras etapas operam sobre o dado bruto; a quarta o transforma em informação por meio de indicadores; a quinta produz conhecimento aplicável à gestão da operação.

3.4 Considerações sobre segurança e governança

A execução do POP em ambiente real exige a observância de três princípios de governança que devem ser explicitados também no contexto didático. Primeiro, o usuário de banco utilizado para a extração analítica deve possuir permissões exclusivamente de leitura (SELECT no caso do PostgreSQL, find no caso do MongoDB), impedindo qualquer alteração inadvertida dos dados operacionais. Segundo, as credenciais de conexão jamais devem ser registradas em código versionado, devendo ser carregadas a partir de variáveis de ambiente ou de cofres de segredos. Terceiro, quaisquer dados pessoais eventualmente presentes devem ser

anonimizados antes da inclusão em relatórios ou repositórios públicos, em conformidade com a LGPD.

4. Considerações Finais da Etapa N1

Esta primeira entrega do trabalho consolidou a fundamentação teórica e o planejamento metodológico do POP a ser executado na etapa N2. Foram articulados, em uma narrativa única, os conceitos de Sistemas de Informação Gerencial, de arquitetura de software em camadas e de bancos de dados relacionais e documentais, com ênfase nos elementos diretamente mobilizados pelo procedimento: normalização, agregação, composição e mecanismos de conexão em Python.

A opção pela abordagem comparativa entre PostgreSQL e MongoDB, sustentada pelo conceito de polyglot persistence, prepara o terreno para que a etapa prática demonstre, sobre o mesmo conjunto de dados, como diferentes paradigmas de armazenamento influenciam as decisões de modelagem e o estilo das consultas analíticas. Espera-se que, ao final da N2, o POP esteja suficientemente documentado para que outro engenheiro de produção possa reproduzi-lo integralmente a partir deste artigo, executando o ciclo dado–informação–conhecimento–decisão com autonomia e rastreabilidade.

As próximas etapas do trabalho compreendem: (i) o provisionamento do ambiente local com PostgreSQL e MongoDB; (ii) a carga do dataset disponibilizado pelo professor nos dois SGBDs; (iii) a execução das queries e dos pipelines planejados nesta seção metodológica; (iv) a geração dos indicadores e visualizações; e (v) a consolidação do artigo final, incorporando os resultados obtidos e suas interpretações.

5. Referências

CODD, E. F. A relational model of data for large shared data banks. *Communications of the ACM*, v. 13, n. 6, p. 377–387, 1970.

COCKBURN, A. Hexagonal architecture. 2005. Disponível em: <<https://alistair.cockburn.us/hexagonal-architecture/>>.

DAVENPORT, T. H.; PRUSAK, L. *Working knowledge: how organizations manage what they know*. Boston: Harvard Business School Press, 1998.

ELMASRI, R.; NAVATHE, S. B. *Sistemas de banco de dados*. 7. ed. São Paulo: Pearson, 2018.

FOWLER, M.; SADALAGE, P. J. *NoSQL distilled: a brief guide to the emerging world of polyglot persistence*. Boston: Addison-Wesley, 2012.

LAUDON, K. C.; LAUDON, J. P. *Sistemas de informação gerenciais*. 11. ed. São Paulo: Pearson, 2014.

MARTIN, R. C. *Clean architecture: a craftsman's guide to software structure and design*. Upper Saddle River: Prentice Hall, 2017.

MARTINS, D. W. P. *Material didático da disciplina Práticas em Engenharia de Produção*. Aparecida de Goiânia: FCT, 2026.