

Procedimento Operacional Padrão para extração e análise de dados diretamente em bancos de dados relacionais e documentais em contextos de Engenharia de Produção

Guilherme Alves Mousinho (Universidade Federal de Goiás)

Vinycius Cirilo Machado Pêgo (Universidade Federal de Goiás)



Este artigo apresenta a execução prática de um Procedimento Operacional Padrão (POP) para acesso, extração e análise de dados diretamente em Sistemas Gerenciadores de Banco de Dados (SGBDs) relacionais e documentais, aplicado ao contexto da Engenharia de Produção. Dando continuidade à fundamentação teórica da etapa N1, conectou-se, por meio da linguagem Python, a um ERP hospedado em PostgreSQL (26 tabelas) e a um MES hospedado em MongoDB (6 coleções), correspondentes a uma fábrica de bombas e válvulas hidráulicas com dados do exercício de 2025. Foram escritas consultas SQL e pipelines de agregação MongoDB para gerar indicadores clássicos de desempenho industrial — OEE e seus três fatores, MTBF/MTTR, taxa de refugo/FPY, Pareto das paradas (Seis Grandes Perdas), curva ABC de faturamento e acurácia (MAPE) da previsão de demanda — além de um indicador cruzado ERP×MES de aderência da produção real ao plano-mestre. O OEE global apurado foi de 80,7%, com qualidade elevada (98,4%) e perdas concentradas em disponibilidade e performance. Conclui-se que o acesso direto ao BD, articulado a ferramentas de análise, confere ao engenheiro de produção autonomia analítica para completar o ciclo dado–informação–conhecimento–decisão com rastreabilidade e velocidade.

Palavras-chave: Banco de dados, OEE, Engenharia de Produção, PostgreSQL, MongoDB, Polyglot persistence.

1. Introdução

A transformação digital da indústria, associada ao paradigma da Indústria 4.0, alterou a relação entre o engenheiro de produção e os dados que sustentam sua atividade. Sensores instrumentam linhas de montagem, sistemas ERP registram cada movimentação de estoque e cada apontamento de ordem de produção, e sistemas de execução de manufatura (MES) produzem séries temporais com granularidade de minutos. Diante desse volume e dessa velocidade, a prática histórica de receber relatórios já consolidados, em planilhas ou dashboards fechados, tornou-se uma restrição relevante para a tomada de decisão fundamentada: o dado chega filtrado, atrasado e agregado demais, escondendo justamente a dispersão e os outliers que o engenheiro precisa investigar.

Na etapa N1 deste trabalho, consolidou-se a fundamentação teórica e o planejamento metodológico de um Procedimento Operacional Padrão (POP) para acesso, extração e análise de dados diretamente em SGBDs. Esta segunda entrega (N2) executa o POP planejado sobre um ambiente de dados real, disponibilizado pelo professor da disciplina, composto por dois bancos complementares: um ERP relacional em PostgreSQL e um MES documental em MongoDB. O objetivo é demonstrar, na prática, a capacidade de conectar, explorar, extrair, analisar e interpretar dados industriais, gerando indicadores que apoiem decisões de Engenharia de Produção.

O artigo está organizado da seguinte forma: a Seção 2 revisa, de forma condensada, a fundamentação teórica da N1 e acrescenta os indicadores de desempenho mobilizados na análise; a Seção 3 descreve a metodologia efetivamente executada (ambiente, ferramentas, procedimento de conexão e etapas do POP); a Seção 4 apresenta e discute os resultados; e a Seção 5 traz as conclusões e recomendações.

2. Fundamentação Teórica

2.1 Sistemas de Informação Gerencial e o ciclo do dado

Um Sistema de Informação Gerencial (SIG) é, segundo Laudon e Laudon (2014), um conjunto integrado de pessoas, processos, tecnologia e dados que coletam, processam, armazenam e disseminam informações para apoiar a decisão e o controle organizacional. Na Engenharia de Produção, os SIGs materializam-se em sistemas ERP, MES, WMS e ferramentas de Business Intelligence, todos sustentados por bancos de dados que constituem sua camada de persistência. O ciclo clássico dado–informação–conhecimento–decisão

(DAVENPORT; PRUSAK, 1998) encontra no BD seu ponto de origem: o dado bruto é refinado em informação por meio de consultas e agregações, convertido em conhecimento quando contextualizado por modelos analíticos e, por fim, subsidia a decisão gerencial. O presente POP percorre exatamente esse ciclo.

2.2 Arquitetura de software e o banco de dados como infraestrutura

A arquitetura em camadas separa responsabilidades em apresentação, aplicação/negócio e persistência/infraestrutura. Padrões como MVC, a arquitetura hexagonal (COCKBURN, 2005) e a Clean Architecture (MARTIN, 2017) reforçam que o banco de dados é um detalhe de infraestrutura, e não o núcleo do negócio. Disso decorre que o acesso analítico direto ao BD — mediado por usuários de leitura e por políticas de segurança — é uma prática arquiteturalmente legítima, pois opera na camada de infraestrutura sem violar as camadas superiores. É essa legitimidade que fundamenta o procedimento aqui executado.

2.3 Evolução histórica e o paradigma relacional versus documental

Dos arquivos hierárquicos da década de 1960 (IMS/IBM) ao modelo relacional de Codd (1970), e deste à consolidação do SQL nos anos 1980–90 (Oracle, PostgreSQL, MySQL), os bancos de dados evoluíram para atender necessidades crescentes de integridade e escala. A partir dos anos 2000, o movimento NoSQL trouxe famílias documentais (MongoDB), de colunas (Cassandra), chave-valor (Redis) e de grafos (Neo4j). Consolidou-se, na década seguinte, o conceito de polyglot persistence (FOWLER; SADALAGE, 2012): combinar diferentes tipos de banco conforme a natureza dos dados. O ambiente analisado nesta N2 é justamente poliglota — PostgreSQL para o ERP transacional e MongoDB para os apontamentos e eventos do chão de fábrica.

Tabela 1 - Comparação entre os paradigmas relacional e documental

Aspecto	Relacional (SQL)	Documental (NoSQL)
Unidade básica	Tabela (linhas e colunas)	Documento (JSON/BSON)
Esquema	Rígido, definido a priori	Flexível, schema-less
Relacionamentos	Chaves estrangeiras + JOINS	Documentos embutidos ou referências
Transações	ACID (consistência forte)	BASE (consistência eventual)
Escalabilidade	Predominantemente vertical	Predominantemente horizontal
Uso típico em EP	ERP, estoque, financeiro	Telemetria, apontamentos, sensores

Fonte: adaptado do material da disciplina (MARTINS, 2026).

2.4 Normalização, relacionamentos, agregação e composição

A normalização (1FN, 2FN, 3FN) decompõe tabelas para eliminar redundâncias e anomalias, produzindo como subproduto os relacionamentos 1:1, 1:N e N:M. No ERP analisado, esses três tipos aparecem de forma didática: a relação produto–família é 1:N; a relação

pedido–produto é N:M, materializada pela tabela associativa item_pedido; e a estrutura de produto (lista de materiais) é uma relação N:M reflexiva. Os conceitos de agregação (relação “tem um”, partes independentes do todo) e composição (relação “parte de”, partes que não existem sem o todo) também se manifestam: no ERP, a relação ordem_producao–movimentacao_estoque é uma agregação; no MES, o array embutido paradas dentro de cada apontamento é uma composição — os registros de parada só existem dentro do documento do apontamento.

Tabela 2 - Tipos de relacionamento e exemplos no ambiente analisado

Cardinalidade	Exemplo no dataset	Implementação
1:1	Compra ↔ Numeração fiscal	FK única (UNIQUE) na tabela filha
1:N	Família ↔ Produtos	FK no lado N apontando para o lado 1
N:M	Pedido ↔ Produto (item_pedido)	Tabela associativa com duas FKs
Composição	Apontamento ↔ Paradas (MES)	Array embutido (embedded document)

Fonte: elaborada pelos autores.

2.5 Indicadores de desempenho em Engenharia de Produção

A análise desta N2 mobiliza indicadores consagrados na literatura de gestão da produção. O OEE (Overall Equipment Effectiveness), proposto por Nakajima (1988) no âmbito da Manutenção Produtiva Total (TPM), mede a eficácia global de um equipamento como o produto de três fatores: Disponibilidade (tempo operando / tempo planejado), Performance (relação entre o ritmo real e o ritmo ideal de ciclo) e Qualidade (peças boas / peças produzidas). Um OEE de 85% é a referência de “classe mundial”. As perdas que reduzem o OEE são classificadas nas chamadas Seis Grandes Perdas (quebras, setups, pequenas paradas, redução de velocidade, refugos e retrabalho). Complementarmente, os indicadores de confiabilidade MTBF (tempo médio entre falhas) e MTTR (tempo médio de reparo) caracterizam a manutenção; a curva ABC (princípio de Pareto) prioriza itens por relevância; e o MAPE (erro percentual absoluto médio) mede a acurácia da previsão de demanda. Esses indicadores são calculados na Seção 4 a partir dos dados extraídos.

3. Metodologia Executada

3.1 Ambiente e fontes de dados

O ambiente de dados, disponibilizado pelo professor (Opção B – dataset do professor), simula uma fábrica de bombas e válvulas hidráulicas e é composto por dois SGBDs hospedados em nuvem, acessados 24/7 mediante usuário e senha de leitura. O ERP, em PostgreSQL, contém 26 tabelas no schema erp, cobrindo produtos, famílias, estrutura de produto (BOM), roteiros, pedidos de venda, compras, movimentações de estoque, planejamento (plano-mestre e

previsão de demanda) e contabilidade. O MES, em MongoDB, contém 6 coleções: apontamentos_producao (2.088 documentos), eventos_maquina (6.373), inspecoes_qualidade (192), manutencoes (207), maquinas (4) e ordens_producao (96). Os dois bancos compartilham as chaves de negócio — código de ordem de produção (OP-xxxxx), SKU do produto e código de recurso/máquina — o que permite análises integradas. Todos os registros referem-se ao exercício de 2025 (12 meses).

3.2 Ferramentas e bibliotecas

Adotou-se a linguagem Python como ambiente unificado de conexão e análise. A Tabela 3 lista as ferramentas utilizadas. Todo o procedimento foi implementado de forma linear e reproduzível em um caderno executável (notebook), organizado pelas cinco etapas do POP — o código completo consta do Apêndice A e pode ser reexecutado de cima para baixo para regenerar integralmente os resultados apresentados.

Tabela 3 - Ferramentas e bibliotecas utilizadas

Camada	Ferramenta	Função
SGBD relacional	PostgreSQL	ERP — dados estruturados
SGBD documental	MongoDB	MES — apontamentos e eventos
Driver SQL	psycopg2 + SQLAlchemy	Conexão e leitura para DataFrame
Driver NoSQL	pymongo	Pipelines de agregação
Análise	pandas / numpy	Manipulação e cálculo de indicadores
Visualização	matplotlib / seaborn	Gráficos de resultados

Fonte: elaborada pelos autores.

3.3 Procedimento de conexão

A conexão ao PostgreSQL é estabelecida por uma engine SQLAlchemy sobre o driver psycopg2, e a conexão ao MongoDB por um MongoClient (pymongo). As credenciais são lidas de variáveis de ambiente, nunca fixadas no código versionado. O Quadro 1 reproduz o núcleo do módulo de conexão.

Quadro 1 - Núcleo do módulo de conexão (pop/conexao.py)

```
from sqlalchemy import create_engine
from pymongo import MongoClient
import os

# PostgreSQL / ERP (driver psycopg2 via SQLAlchemy)
engine = create_engine(os.getenv("PEP_PG_URI"))

# MongoDB / MES
client = MongoClient(os.getenv("PEP_MONGO_URI"))
db = client["mes"]
```

Fonte: elaborada pelos autores.

3.4 Etapas do Procedimento Operacional Padrão

O POP executado organiza-se em cinco etapas sequenciais, cada uma com produtos

verificáveis (Tabela 4), materializando o ciclo dado–informação–conhecimento–decisão.

Tabela 4 - Etapas do POP e evidências geradas

Etapa	O que foi feito	Evidência
1. Conectar	Conexão de leitura aos dois SGBDs	Log de conexão (Quadro 1)
2. Explorar	Mapeamento de tabelas e coleções	Modelo de dados (Seção 4.1)
3. Extrair	Queries SQL e pipelines MongoDB	Código documentado
4. Analisar	Cálculo de indicadores	Tabelas e figuras
5. Interpretar	Conversão em recomendações	Discussão (Seções 4.2–4.9)

Fonte: elaborada pelos autores.

3.5 Governança, segurança e LGPD

Três princípios de governança foram observados: (i) o usuário de banco possui exclusivamente permissão de leitura (SELECT no PostgreSQL, find no MongoDB), impedindo alterações inadvertidas; (ii) as credenciais são carregadas de variáveis de ambiente, e o arquivo .env é mantido fora do controle de versão; (iii) o dataset é didático e não contém dados pessoais, estando em conformidade com a LGPD.

4. Resultados e Discussão

4.1 Exploração e modelo de dados

A etapa de exploração confirmou a coerência e a complementaridade dos dois bancos. O ERP descreve o que se planeja e o que se comercializa (plano-mestre, previsão de demanda, pedidos e compras), enquanto o MES descreve o que efetivamente ocorre no chão de fábrica (tempos, paradas, peças boas e refugadas, inspeções e manutenções). Oito produtos, distribuídos em três famílias (bombas, válvulas e conjuntos montados), são processados em quatro recursos produtivos (dois tornos CNC, uma injetora e uma linha de montagem), distribuídos em três centros de trabalho (Usinagem, Injeção e Montagem).

4.2 OEE global e por máquina

A partir dos somatórios de tempo planejado, tempo operando, tempo de ciclo ideal e contagem de peças (boas e refugadas) por recurso e mês, calculou-se o OEE e seus três fatores. O OEE global da planta em 2025 foi de 80,7%, resultado do produto entre disponibilidade (89,7%), performance (91,5%) e qualidade (98,4%). O patamar situa-se logo abaixo da referência de classe mundial (85%): a qualidade é excelente, mas perdas de disponibilidade e de performance puxam o indicador para baixo. O Quadro 2 mostra o pipeline de agregação que constrói a base do OEE; a Tabela 5 e a Figura 1 detalham o desempenho por máquina.

Quadro 2 - Pipeline MongoDB que agrega a base do OEE (pop/extracao_mes.py)

```
# Soma tempos e peças por recurso e mês (base do OEE)
pipeline = [
  {"$group": {
    "_id": {"recurso": "$recurso_codigo", "ano_mes": "$ano_mes"},
    "tempo_planejado_min": {"$sum": "$tempo_planejado_min"},
    "tempo_operando_min": {"$sum": "$tempo_operando_min"},
    "pecas_total": {"$sum": "$pecas_total"},
    "pecas_boas": {"$sum": "$pecas_boas"},
    # tempo ideal = ciclo ideal (s) x pecas produzidas
    "tempo_ideal_seg": {"$sum": {"$multiply":
      ["$tempo_ciclo_ideal_seg", "$pecas_total"]}}}}]
# Disponibilidade = operando / planejado
# Performance = tempo_ideal_seg / (operando * 60)
# Qualidade = boas / total | OEE = D x P x Q
```


Fonte: elaborado pelos autores.

Tabela 5 - OEE e fatores por máquina (2025)

Máquina	Centro	Disp. (%)	Perf. (%)	Qual. (%)	OEE (%)
Injetora 01	Injeção	92,2	95,1	98,6	86,5
Torno CNC 01	Usinagem	91,2	93,6	98,3	84,0
Torno CNC 02	Usinagem	89,3	89,8	97,8	78,4
Linha de Montagem 01	Montagem	86,1	87,1	97,2	72,9

Fonte: dados do MES, processados pelos autores.


Figura 1 - OEE por máquina



Fonte: elaborada pelos autores.

A Injetora 01 é o único recurso que atinge a meta de classe mundial (86,5%), ao passo que a Linha de Montagem 01 apresenta o pior desempenho (72,9%), limitada simultaneamente por disponibilidade e performance. A decomposição em fatores (Figura 2) evidencia que a alavanca de melhoria não está na qualidade — uniformemente alta —, mas na redução de paradas e na elevação do ritmo de operação.

Figura 2 - Decomposição do OEE em Disponibilidade, Performance e Qualidade




Fonte: elaborada pelos autores.

4.3 Evolução mensal do OEE

A análise temporal (Figura 3) mostra o OEE oscilando ao longo de 2025 em torno do patamar global, sem tendência clara de melhoria ou deterioração, o que sugere um processo estável porém ainda não submetido a um programa estruturado de melhoria contínua. A estabilidade da curva de qualidade contrasta com a maior variabilidade da disponibilidade, reforçando o diagnóstico de que as perdas são predominantemente de natureza operacional.

Figura 3 - Evolução mensal do OEE e seus fatores



Fonte: elaborada pelos autores.

4.4 Análise das paradas — as Seis Grandes Perdas

O pipeline de agregação que percorre o array embutido paradas (operador \$unwind) totalizou 1.613 horas de parada no ano, distribuídas em seis motivos (Tabela 6 e Figura 4). O Quadro 3 mostra esse pipeline, que aplica o operador \$unwind ao documento embutido — exemplo concreto de composição discutida na Seção 2.4. Diferentemente de um Pareto clássico, em que poucas causas concentram a maior parte das perdas, aqui as seis causas têm pesos semelhantes (de 15,4% a 18,9%). A maior isolada é “Ajuste de processo” (18,9%), seguida de “Falta de operador” e “Falta de material”.

Quadro 3 - Pipeline de Pareto das paradas com \$unwind (pop/extracao_mes.py)

```
# $unwind transforma cada item do array embutido "paradas" em uma linha
pipeline = [
  {"$unwind": "$paradas"},          # composicao -> 1 linha por parada
  {"$group": {"_id": "$paradas.motivo",
    "tempo_total_min": {"$sum": "$paradas.duracao_min"},
    "ocorrencias": {"$sum": 1}}},
  {"$sort": {"tempo_total_min": -1}}]
```


Fonte: elaborado pelos autores.

Tabela 6 - Pareto das paradas de produção (2025)

Motivo	Horas	Ocorrências	% do total	% acum.
Ajuste de processo	304,9	884	18,9	18,9
Falta de operador	276,3	833	17,1	36,0
Falta de material	270,6	821	16,8	52,8
Setup/Troca de ferramenta	258,7	807	16,0	68,8
Pequenas paradas	254,1	781	15,7	84,6
Manutenção corretiva (quebra)	248,6	159	15,4	100,0

Fonte: dados do MES, processados pelos autores.

Figura 4 - Pareto das paradas de produção



Fonte: elaborada pelos autores.

A ausência de uma causa dominante tem implicação gerencial direta: não há um “ponto único” a atacar; a melhoria do OEE exige um programa amplo de TPM e de organização do trabalho que enderece, simultaneamente, ajustes de processo, disponibilidade de operadores, abastecimento de materiais e redução de tempos de setup (SMED).

4.5 Qualidade: refugo, FPY e tipos de defeito


Foram produzidas 606.462 peças no ano, das quais 9.962 foram refugadas — uma taxa global de refugo de 1,64% (FPY de 98,36%). O refugo concentra-se nos conjuntos montados, com destaque para o “Conjunto Pressurizador” (2,82%), enquanto as válvulas apresentam as menores taxas (“Válvula Esfera 3/4””, 1,35%). O padrão é coerente com a complexidade de montagem: produtos com mais operações acumulam mais oportunidades de defeito (Figura 5).

Tabela 7 - Refugo e FPY por produto (2025)

Produto	SKU	Peças	Refugo	Refugo (%)	FPY (%)
Conjunto Pressurizador	CJM-500	21.078	594	2,82	97,18
Conjunto Booster Duplo	CJM-700	10.107	272	2,69	97,31
Bomba Submersa 3cv	BMB-300	86.965	1.928	2,22	97,78
Bomba Centrífuga 2cv	BMB-200	49.266	826	1,68	98,32
Bomba Centrífuga 1cv	BMB-100	73.478	1.223	1,66	98,34
Válvula Gaveta 1"	VLV-100	47.691	685	1,44	98,56
Válvula Esfera 1/2"	VLV-050	204.891	2.909	1,42	98,58
Válvula Esfera 3/4"	VLV-075	112.986	1.525	1,35	98,65

Fonte: dados do MES, processados pelos autores.

Figura 5 - Taxa de refugo por produto



Fonte: elaborada pelos autores.

A análise das 192 inspeções de qualidade complementa o quadro: o tipo de defeito mais

frequente é “Vazamento” (26,9% dos defeitos registrados), seguido de “Dimensional” e “Acabamento”. A predominância de vazamento e de não conformidade dimensional aponta o controle dimensional na usinagem e os testes de estanqueidade na montagem como focos prioritários de um plano de ação da qualidade.

4.6 Confiabilidade: MTBF e MTTR

Cruzando o tempo total operando (MES) com as ordens de manutenção corretiva, calcularam-se os indicadores de confiabilidade (Tabela 8). Os valores de MTBF variam de 80,2 h a 94,5 h e os de MTTR situam-se em torno de 1,5 h, resultando em disponibilidade inerente superior a 98% em todas as máquinas. Como essa disponibilidade inerente (que considera apenas as quebras) é bem maior do que a disponibilidade observada no OEE, conclui-se que a maior parte das perdas de disponibilidade não vem de quebras, e sim de paradas organizacionais (falta de operador, de material e ajustes) — confirmando o diagnóstico da Seção 4.4.

Tabela 8 - Indicadores de confiabilidade por máquina (2025)

Máquina	Horas op.	Falhas	MTBF (h)	MTTR (h)	Disp. inerente (%)
INJ-01	3.609	45	80,2	1,46	98,2
MON-01	3.369	38	88,7	1,76	98,1
TOR-01	3.572	39	91,6	1,45	98,4
TOR-02	3.496	37	94,5	1,61	98,3

Fonte: dados do MES, processados pelos autores.

4.7 Integração ERP×MES: aderência ao plano-mestre

Este indicador ilustra o valor da polyglot persistence ao combinar as duas fontes: a quantidade planejada vem do plano-mestre (ERP/PostgreSQL) e a quantidade efetivamente produzida e aprovada (peças boas) vem dos apontamentos (MES/MongoDB). A aderência média foi de 100,0%, variando de 98,9% a 101,2% entre os produtos (Tabela 9). Os valores próximos de 100% indicam alto cumprimento do plano; desvios acima de 100% sinalizam produção além do planejado para alguns SKUs (possível compensação de refugo ou ajuste de mix), enquanto desvios abaixo apontam itens cuja produção boa ficou aquém da meta, merecendo atenção do PCP.

Tabela 9 - Aderência da produção real (MES) ao plano-mestre (ERP)

Produto	SKU	Planejado (ERP)	Produzido bom (MES)	Aderência (%)
Conjunto Pressurizador	CJM-500	20.721	20.484	98,9
Bomba Submersa 3cv	BMB-300	85.755	85.037	99,2
Válvula Gaveta 1"	VLV-100	47.375	47.006	99,2
Bomba Centrífuga 1cv	BMB-100	72.303	72.255	99,9
Bomba Centrífuga 2cv	BMB-200	48.468	48.440	99,9

Válvula Esfera 3/4"	VLV-075	110.640	111.461	100,7
Conjunto Booster Duplo	CJM-700	9.755	9.835	100,8
Válvula Esfera 1/2"	VLV-050	199.549	201.982	101,2

Fonte: dados integrados ERP e MES, processados pelos autores.

4.8 Visão comercial: curva ABC e acurácia da previsão

No lado relacional, uma consulta SQL com JOINS sobre a tabela associativa item_pedido (relação N:M pedido–produto) apurou o faturamento líquido por produto, totalizando R\$ 562,3 milhões no ano. O Quadro 4 reproduz essa consulta, que aplica os conceitos de normalização e relacionamento da Seção 2.4. A curva ABC (Tabela 10 e Figura 6) classifica 4 dos 8 produtos como classe A, responsáveis por 76,8% da receita — com destaque para a “Bomba Submersa 3cv”, sozinha responsável por 35,1% do faturamento. A margem de contribuição é homogênea (em torno de 52%), de modo que a priorização comercial e de planejamento deve seguir o volume de receita: proteger a disponibilidade dos recursos que produzem os itens classe A é a decisão de maior impacto financeiro.

Quadro 4 - Consulta SQL de faturamento por produto (pop/extracao_erp.py)

```
-- JOIN na tabela associativa item_pedido (relacao N:M pedido-produto)
SELECT p.sku, p.nome,
       SUM(ip.quantidade * ip.preco_unitario
           * (1 - ip.desconto_pct/100.0)) AS receita_liquida
FROM   erp.item_pedido ip
JOIN   erp.pedido_venda pv ON pv.id = ip.pedido_id
JOIN   erp.produto      p  ON p.id = ip.produto_id
WHERE  pv.status = 'FATURADO'
GROUP BY p.sku, p.nome
ORDER BY receita_liquida DESC;
```


Fonte: elaborado pelos autores.

Tabela 10 - Curva ABC de faturamento (2025)

Produto	SKU	Receita (R\$ mi)	% receita	% acum.	Classe
Bomba Submersa 3cv	BMB-300	197,51	35,1	35,1	A
Bomba Centrífuga 2cv	BMB-200	80,07	14,2	49,4	A
Bomba Centrífuga 1cv	BMB-100	77,58	13,8	63,2	A
Conjunto Pressurizador	CJM-500	76,62	13,6	76,8	A
Conjunto Booster Duplo	CJM-700	60,42	10,8	87,5	B
Válvula Esfera 1/2"	VLV-050	32,29	5,7	93,3	B
Válvula Esfera 3/4"	VLV-075	24,27	4,3	97,6	C
Válvula Gaveta 1"	VLV-100	13,56	2,4	100,0	C

Fonte: dados do ERP, processados pelos autores.


Figura 6 - Curva ABC de faturamento por produto



Fonte: elaborada pelos autores.

A acurácia do planejamento de demanda foi avaliada comparando a previsão (previsao_demanda) com as vendas reais. O MAPE global foi de 8,4%, considerado bom para o horizonte mensal, variando de 6,0% a 11,5% entre os SKUs (Figura 7). Observou-se, contudo, um viés sistematicamente positivo: em todos os produtos a previsão superestimou a demanda realizada, o que pode inflar estoques e a ocupação fabril. Recomenda-se calibrar o modelo de previsão para corrigir esse viés de superestimação.

Figura 7 - MAPE da previsão de demanda por produto



Fonte: elaborada pelos autores.

4.9 Síntese e recomendações

A integração das análises permite um conjunto de recomendações fundamentadas em dados:

- (i) instituir um programa de TPM e de redução de paradas organizacionais focado na Linha de

Montagem 01 e no Torno CNC 02, os recursos de menor OEE; (ii) atacar prioritariamente ajustes de processo, falta de operador e falta de material, que juntos respondem por mais da metade das horas paradas; (iii) reforçar o controle dimensional e os testes de estanqueidade para reduzir o refugo dos conjuntos montados; e (iv) recalibrar a previsão de demanda para eliminar o viés de superestimação. Todas essas conclusões derivam diretamente de consultas reprodutíveis sobre a fonte primária dos dados, sem intermediação de relatórios prontos.

5. Conclusão

Esta etapa N2 executou, de ponta a ponta, o Procedimento Operacional Padrão planejado na N1, sobre um ambiente de dados real e poliglota. Conectou-se a um ERP relacional (PostgreSQL) e a um MES documental (MongoDB), explorou-se o modelo de dados, extraíram-se dados por meio de consultas SQL e de pipelines de agregação MongoDB, e geraram-se indicadores clássicos de Engenharia de Produção — OEE e seus fatores, MTBF/MTTR, refugo/FPY, Pareto das Seis Grandes Perdas, curva ABC e MAPE —, além de um indicador integrado ERP×MES de aderência ao plano-mestre.

Os resultados, longe de serem um fim em si, foram convertidos em recomendações de gestão, completando o ciclo dado–informação–conhecimento–decisão discutido na fundamentação. O OEE global de 80,7% e o diagnóstico de que as perdas se concentram em paradas organizacionais (e não em quebras ou em qualidade) são exemplos de conhecimento acionável que somente o acesso direto e detalhado ao banco tornaria possível.

Conclui-se que o domínio do acesso direto ao banco de dados, articulado a ferramentas de análise como Python e pandas, constitui competência analítica essencial para o engenheiro de produção contemporâneo, conferindo-lhe autonomia, rastreabilidade e velocidade na tomada de decisão. O procedimento aqui documentado é reprodutível: outro profissional, de posse das mesmas credenciais de leitura e do código versionado, pode reexecutá-lo integralmente e chegar aos mesmos indicadores.

Glossário de indicadores e resultados

Reúnem-se a seguir as definições dos principais indicadores, termos técnicos e entidades de dados mobilizados neste artigo, com as respectivas fórmulas quando aplicável (Tabela 11).

Tabela 11 - Glossário de indicadores e resultados

Termo	Definição / fórmula
OEE (Overall Equipment Effectiveness)	Eficácia global do equipamento; mede quanto do tempo planejado foi convertido em produção boa no ritmo ideal. $OEE = Disponibilidade \times Performance \times Qualidade$. Referência de classe mundial: 85%.

Disponibilidade	Fração do tempo planejado em que a máquina esteve operando. = tempo operando ÷ tempo planejado.
Performance (Desempenho)	Relação entre o ritmo real e o ritmo ideal de produção. = (tempo de ciclo ideal × peças produzidas) ÷ (tempo operando).
Qualidade	Fração das peças produzidas que são aprovadas (boas). = peças boas ÷ peças totais produzidas.
Seis Grandes Perdas	Classificação das perdas que reduzem o OEE: quebras/falhas, setups e ajustes, pequenas paradas, redução de velocidade, refugos e retrabalho.
MTBF (Mean Time Between Failures)	Tempo médio entre falhas; quanto maior, mais confiável o equipamento. = tempo total operando ÷ n° de falhas (manutenções corretivas).
MTTR (Mean Time To Repair)	Tempo médio para reparar uma falha; quanto menor, melhor. = tempo total de reparo ÷ n° de falhas.
Disponibilidade inerente	Disponibilidade teórica considerando apenas falhas (não paradas organizacionais). = MTBF ÷ (MTBF + MTTR).
Taxa de refugo	Percentual de peças descartadas por não conformidade. = peças refugadas ÷ peças totais × 100.
FPY (First Pass Yield)	Rendimento de primeira passagem: percentual de peças aprovadas sem retrabalho. = peças boas ÷ peças totais × 100 = 100% – taxa de refugo.
Curva ABC (Pareto)	Classificação de itens por relevância: classe A (≈80% do valor), B (próximos ≈15%) e C (restante). Orienta a priorização gerencial.
Margem de contribuição	Receita líquida menos custo variável do produto; indica quanto cada produto contribui para cobrir custos fixos e gerar lucro.
MAPE (Mean Absolute Percentage Error)	Erro percentual absoluto médio da previsão de demanda. = média de $ \text{previsto} - \text{real} \div \text{real} \times 100$. Menor é melhor.
Viés (da previsão)	Tendência sistemática de erro. Viés positivo indica superestimação (previsto > real); negativo, subestimação.
Aderência ao plano-mestre	Grau de cumprimento do planejado. Neste trabalho: produção boa real (MES) ÷ quantidade planejada no plano-mestre (ERP) × 100.
Plano-mestre de produção (PMP)	Planejamento de quanto produzir de cada produto por período; entrada do PCP, registrada no ERP.
Previsão de demanda	Estimativa de vendas futuras por produto e período, base para o planejamento da produção e dos estoques.
Polyglot persistence	Estratégia de usar tipos diferentes de banco conforme a natureza do dado (aqui, PostgreSQL para o ERP e MongoDB para o MES).
ERP / MES	ERP (Enterprise Resource Planning): sistema de gestão integrada (planejamento, vendas, compras). MES (Manufacturing Execution System): sistema de execução da manufatura (apontamentos do chão de fábrica).
SKU / BOM	SKU (Stock Keeping Unit): código único do produto. BOM (Bill of Materials): estrutura/lista de materiais que compõem um produto.
Pipeline de agregação (\$group, \$unwind)	Sequência de estágios de processamento no MongoDB, análoga ao GROUP BY do SQL; \$unwind expande arrays embutidos em linhas.

Fonte: elaborada pelos autores.

REFERÊNCIAS

COCKBURN, A. Hexagonal architecture. 2005. Disponível em:

<https://alistair.cockburn.us/hexagonal-architecture/>.

CODD, E. F. A relational model of data for large shared data banks. Communications of the ACM, v. 13, n. 6, p. 377–387, 1970.

DAVENPORT, T. H.; PRUSAK, L. Working knowledge: how organizations manage what they know. Boston: Harvard Business School Press, 1998.

ELMASRI, R.; NAVATHE, S. B. Sistemas de banco de dados. 7. ed. São Paulo: Pearson, 2018.

FOWLER, M.; SADALAGE, P. J. NoSQL distilled: a brief guide to the emerging world of polyglot persistence. Boston: Addison-Wesley, 2012.

LAUDON, K. C.; LAUDON, J. P. Sistemas de informação gerenciais. 11. ed. São Paulo: Pearson, 2014.

MARTIN, R. C. Clean architecture: a craftsman's guide to software structure and design. Upper Saddle River: Prentice Hall, 2017.

MARTINS, D. W. P. Material didático da disciplina Práticas em Engenharia de Produção. Aparecida de Goiânia: FCT, 2026.

NAKAJIMA, S. Introduction to TPM: total productive maintenance. Cambridge: Productivity Press, 1988.

Apêndice A — Código-fonte do POP (procedimento passo a passo)

Este apêndice reproduz, na íntegra e de forma linear, o código que executa o Procedimento Operacional Padrão, organizado pelas cinco etapas do procedimento. Trata-se do mesmo código do caderno executável POP.ipynb: outro profissional, de posse das credenciais de leitura, pode reexecutá-lo de cima para baixo e reproduzir integralmente os indicadores deste artigo. Os comentários (linhas iniciadas por # ou --) explicam cada passo.

Etapa 0 — Preparação do ambiente

```
# Se alguma biblioteca faltar, descomente a linha abaixo e execute uma vez:
# %pip install pandas numpy sqlalchemy psycopg2-binary pymongo matplotlib seaborn

import os
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sqlalchemy import create_engine, text
from pymongo import MongoClient

sns.set_theme(style="whitegrid")
pd.set_option("display.float_format", lambda v: f"{v:,.2f}")

# Credenciais (variável de ambiente -> fallback didático)
PG_URI = os.getenv(
    "PEP_PG_URI",
    "postgresql+psycopg2://erp:Fg669s80GBgxTqL1C6gHv6FX7EJR"
    "@pep-postgresql.arch7.dev:5432/erp")
MONGO_URI = os.getenv(
    "PEP_MONGO_URI",
    "mongodb://mes:UT1EF3jReDHpf547q5P8BWivqLsx"
    "@pep-mongo.arch7.dev:27018/?authSource=admin")
print("Ambiente pronto.")
```

Etapa 1 — Conectar

```
# --- PostgreSQL / ERP (relacional) ---
engine = create_engine(PG_URI, connect_args={"connect_timeout": 30})
with engine.connect() as c:
    n_tabelas = c.execute(text(
        "SELECT count(*) FROM information_schema.tables "
        "WHERE table_schema = 'erp'")).scalar()
print(f"ERP (PostgreSQL): conectado – {n_tabelas} tabelas no schema 'erp'.")

# --- MongoDB / MES (documental) ---
client = MongoClient(MONGO_URI, serverSelectionTimeoutMS=30000)
db = client["mes"]
print(f"MES (MongoDB): conectado – {len(db.list_collection_names())} coleções.")
```

Etapa 2 — Explorar

```
# Tabelas do ERP
tabelas = pd.read_sql(
    "SELECT table_name FROM information_schema.tables "
    "WHERE table_schema='erp' ORDER BY table_name", engine)
print("ERP – 26 tabelas:")
print(", ".join(tabelas["table_name"]))

# Coleções do MES e contagem de documentos
```

```
print("\nMES - coleções (documentos):")
for col in db.list_collection_names():
    print(f" - {col}: {db[col].count_documents({})}")
# Como é um apontamento de produção (documento do MES)? Note o array embutido
# "paradas" (composição) - base do OEE e do Pareto de paradas.
exemplo = db.apontamentos_producao.find_one({}, {"_id": 0})
import pprint; pprint.pp(exemplo)
```

3.1 MES (pipeline) — somatórios que formam a base do OEE

```
# Pipeline: soma tempos e peças por recurso (máquina) e mês.
pipeline_oe = [
    {"$group": {
        "_id": {"recurso": "$recurso_codigo", "recurso_nome": "$recurso_nome",
            "centro": "$centro_trabalho", "ano_mes": "$ano_mes"},
        "tempo_planejado_min": {"$sum": "$tempo_planejado_min"},
        "tempo_operando_min": {"$sum": "$tempo_operando_min"},
        "pecas_total": {"$sum": "$pecas_total"},
        "pecas_boas": {"$sum": "$pecas_boas"},
        "pecas_refugo": {"$sum": "$pecas_refugo"},
        # tempo ideal de produção = ciclo ideal (s) x peças produzidas
        "tempo_ideal_seg": {"$sum": {"$multiply":
            ["$tempo_ciclo_ideal_seg", "$pecas_total"]}},
    }},
]
base = pd.json_normalize(list(db.apontamentos_producao.aggregate(pipeline_oe)))
base = base.rename(columns=lambda c: c.replace("_id.", ""))
base.head()
```

3.2 ERP (SQL) — faturamento por produto

```
sql_faturamento = '''
SELECT  p.sku, p.nome AS produto, f.nome AS familia,
        SUM(ip.quantidade) AS qtd_vendida,
        SUM(ip.quantidade * ip.preco_unitario * (1 - ip.desconto_pct/100.0))
        AS receita_liquida,
        SUM(ip.quantidade * p.custo_padrao_unitario) AS custo_total
FROM    erp.item_pedido ip
JOIN    erp.pedido_venda pv ON pv.id = ip.pedido_id
JOIN    erp.produto      p  ON p.id = ip.produto_id
JOIN    erp.familia_produto f ON f.id = p.familia_id
WHERE   pv.status = 'FATURADO'
GROUP BY p.sku, p.nome, f.nome
ORDER BY receita_liquida DESC;
'''

faturamento = pd.read_sql(sql_faturamento, engine)
faturamento["margem_contribuicao"] = (faturamento["receita_liquida"]
    - faturamento["custo_total"])

faturamento
```

4.1 OEE — Overall Equipment Effectiveness

```
def calcular_oe(df):
    d = df.copy()
    d["disponibilidade"] = d["tempo_operando_min"] / d["tempo_planejado_min"]
    d["performance"] = (d["tempo_ideal_seg"] / (d["tempo_operando_min"] *
60)).clip(upper=1)
    d["qualidade"] = d["pecas_boas"] / d["pecas_total"]
    d["oe"] = d["disponibilidade"] * d["performance"] * d["qualidade"]
    return d

# OEE global da planta
g = calcular_oe(base[["tempo_planejado_min", "tempo_operando_min",
    "tempo_ideal_seg", "pecas_total", "pecas_boas"]].sum().to_frame().T)
oe_g = g.iloc[0]
```

```
print(f"OEE GLOBAL = {oe_g['oe']*100:.1f}% "
      f"(Disponibilidade {oe_g['disponibilidade']*100:.1f}% | "
      f"Performance {oe_g['performance']*100:.1f}% | "
      f"Qualidade {oe_g['qualidade']*100:.1f}%)")
# OEE por máquina
oe_maq = (base.groupby(["recurso", "recurso_nome", "centro"], as_index=False)
          [["tempo_planejado_min", "tempo_operando_min", "tempo_ideal_seg",
            "pecas_total", "pecas_boas"]].sum())
oe_maq = calcular_oe(oe_maq).sort_values("oe", ascending=False)
oe_maq[["recurso_nome", "centro", "disponibilidade", "performance", "qualidade", "oe"]]
# Gráfico: OEE por máquina (verde = atingiu a meta de 85%)
fig, ax = plt.subplots(figsize=(8, 4))
cores = ["#2a9d8f" if v >= .85 else "#e9c46a" for v in oe_maq["oe"]]
ax.bar(oe_maq["recurso_nome"], oe_maq["oe"]*100, color=cores)
ax.axhline(85, ls="--", color="gray", label="Meta classe mundial (85%)")
ax.set_ylabel("OEE (%)"); ax.set_ylim(0, 100); ax.set_title("OEE por máquina – 2025")
for i, v in enumerate(oe_maq["oe"]*100):
    ax.text(i, v+1.5, f"{v:.1f}%", ha="center")
ax.legend(); plt.xticks(rotation=15); plt.tight_layout(); plt.show()
```

4.2 Análise das paradas — as Seis Grandes Perdas

```
pipeline_paradas = [
    {"$unwind": "$paradas"},
    {"$group": {"_id": "$paradas.motivo",
                "tempo_total_min": {"$sum": "$paradas.duracao_min"},
                "ocorrencias": {"$sum": 1}}},
    {"$sort": {"tempo_total_min": -1}},
]
paradas = pd.DataFrame(list(db.apontamentos_producao.aggregate(pipeline_paradas)))
paradas = paradas.rename(columns={"_id": "motivo"})
paradas["horas"] = paradas["tempo_total_min"] / 60
paradas["pct"] = 100 * paradas["tempo_total_min"] / paradas["tempo_total_min"].sum()
paradas["pct_acum"] = paradas["pct"].cumsum()
paradas[["motivo", "horas", "ocorrencias", "pct", "pct_acum"]]
# Gráfico de Pareto das paradas
fig, ax1 = plt.subplots(figsize=(9, 4.2))
ax1.bar(paradas["motivo"], paradas["horas"], color="#e76f51")
ax1.set_ylabel("Horas paradas"); ax1.set_title("Pareto das paradas – Seis Grandes Perdas")
plt.setp(ax1.get_xticklabels(), rotation=25, ha="right")
ax2 = ax1.twinx()
ax2.plot(paradas["motivo"], paradas["pct_acum"], color="#264653", marker="o")
ax2.axhline(80, ls="--", color="gray"); ax2.set_ylabel("% acumulado"); ax2.set_ylim(0, 105)
plt.tight_layout(); plt.show()
```

4.3 Qualidade — refugo e FPY por produto

```
pipeline_refugo = [
    {"$group": {"_id": {"sku": "$produto_sku", "nome": "$produto_nome"},
                "pecas_total": {"$sum": "$pecas_total"},
                "pecas_boas": {"$sum": "$pecas_boas"},
                "pecas_refugo": {"$sum": "$pecas_refugo"}}},
]
refugo = pd.json_normalize(list(db.apontamentos_producao.aggregate(pipeline_refugo)))
refugo = refugo.rename(columns=lambda c: c.replace("_id.", ""))
refugo["taxa_refugo_%"] = 100 * refugo["pecas_refugo"] / refugo["pecas_total"]
refugo["FPY_%"] = 100 * refugo["pecas_boas"] / refugo["pecas_total"]
refugo.sort_values("taxa_refugo_%", ascending=False)[
    ["nome", "sku", "pecas_total", "pecas_refugo", "taxa_refugo_%", "FPY_%"]]
```

4.4 Confiabilidade — MTBF e MTTR

```
# Manutenções corretivas por máquina
corr = pd.DataFrame(list(db.manutencoes.aggregate([
```

```
{ "$match": { "tipo": "CORRETIVA" } },
{ "$group": { "_id": "$maquina_codigo",
  "falhas": { "$sum": 1 },
  "tempo_reparo_min": { "$sum": "$duracao_min" } } } } } )
corr = corr.rename(columns={"_id": "recurso"})

op = base.groupby("recurso", as_index=False)["tempo_operando_min"].sum()
op["horas_operando"] = op["tempo_operando_min"] / 60

conf = op.merge(corr, on="recurso", how="left")
conf["MTBF_h"] = conf["horas_operando"] / conf["falhas"]
conf["MTTR_h"] = (conf["tempo_reparo_min"] / 60) / conf["falhas"]
conf["disp_inerente_%"] = 100 * conf["MTBF_h"] / (conf["MTBF_h"] + conf["MTTR_h"])
conf[["recurso", "horas_operando", "falhas", "MTBF_h", "MTTR_h", "disp_inerente_%"]]
```

4.5 Curva ABC de faturamento

```
abc = faturamento.sort_values("receita_liquida", ascending=False).reset_index(drop=True)
abc["pct"] = 100 * abc["receita_liquida"] / abc["receita_liquida"].sum()
abc["pct_acum"] = abc["pct"].cumsum()
abc["classe"] = pd.cut(abc["pct_acum"], [0, 80, 95, 100], labels=["A", "B", "C"])
print(f"Receita total: R$ {abc['receita_liquida'].sum()/1e6:.1f} milhões")
abc[["produto", "sku", "receita_liquida", "pct", "pct_acum", "classe"]]
# Gráfico da curva ABC
fig, ax1 = plt.subplots(figsize=(9, 4.2))
cmap = {"A": "#2a9d8f", "B": "#e9c46a", "C": "#e76f51"}
ax1.bar(abc["sku"], abc["receita_liquida"]/1e6, color=[cmap[c] for c in abc["classe"]])
ax1.set_ylabel("Receita (R$ milhões)"); ax1.set_title("Curva ABC de faturamento – 2025")
ax2 = ax1.twinx()
ax2.plot(abc["sku"], abc["pct_acum"], color="#264653", marker="o")
ax2.axhline(80, ls="--", color="gray"); ax2.set_ylabel("% acumulado"); ax2.set_ylim(0, 105)
plt.setp(ax1.get_xticklabels(), rotation=20); plt.tight_layout(); plt.show()
```

4.6 Acurácia da previsão de demanda (MAPE)

```
sql_prev = '''
WITH vendas AS (
  SELECT ip.produto_id, to_char(pv.data_pedido, 'YYYY-MM') AS ano_mes,
    SUM(ip.quantidade) AS qtd_real
  FROM erp.item_pedido ip JOIN erp.pedido_venda pv ON pv.id = ip.pedido_id
  WHERE pv.status='FATURADO' GROUP BY 1,2)
SELECT pd.ano_mes, p.sku, pd.qtd_prevista, COALESCE(v.qtd_real,0) AS qtd_real
FROM erp.previsao_demanda pd
JOIN erp.produto p ON p.id = pd.produto_id
LEFT JOIN vendas v ON v.produto_id = pd.produto_id AND v.ano_mes = pd.ano_mes
'''

prev = pd.read_sql(sql_prev, engine)
prev = prev[prev["qtd_real"] > 0].copy()
prev["erro_abs_%"] = 100 * (prev["qtd_prevista"] - prev["qtd_real"]).abs() /
prev["qtd_real"]
print(f"MAPE global = {prev['erro_abs_%'].mean():.1f}%")
mape_sku = prev.groupby("sku",
as_index=False)["erro_abs_%"].mean().sort_values("erro_abs_%")
mape_sku
```

4.7 Integração ERP × MES — aderência da produção ao plano-mestre

```
plano = pd.read_sql(
  "SELECT p.sku, SUM(pm.qtd_planejada) AS qtd_planejada "
  "FROM erp.plano_mestre pm JOIN erp.produto p ON p.id=pm.produto_id "
  "GROUP BY p.sku", engine)
aderencia = refugo[["sku", "nome", "pecas_boas"]].merge(plano, on="sku")
aderencia["aderencia_%"] = 100 * aderencia["pecas_boas"] / aderencia["qtd_planejada"]
aderencia.sort_values("aderencia_%")[["nome", "sku", "qtd_planejada", "pecas_boas", "aderencia_%"]]
```

Etapa 5 — Interpretar (dado → informação → conhecimento → decisão)

```
# Encerramento – sempre fechar as conexões  
client.close()  
engine.dispose()  
print("Conexões encerradas. POP concluído.")
```