

POP para Acesso a Dados em Engenharia de Produção

Lavínia Mosquem Padilha da Silva (UFG)
Odilon Ribeiro Pimentel (UFG)

Este trabalho analisa a importância do acesso direto a bancos de dados pelo Engenheiro de Produção como fator estratégico para a tomada de decisão em ambientes orientados por dados. Discute-se como a dependência exclusiva de relatórios e dashboards limita a autonomia analítica, reduz a granularidade das informações e compromete a agilidade decisória. A pesquisa fundamenta-se em conceitos de Sistemas de Informação Gerencial, arquitetura de software e bancos de dados relacionais e não relacionais. Metodologicamente, propõe-se a extração e análise de dados operacionais em ambiente corporativo utilizando Databricks, SQL e Python para geração de indicadores logísticos. Conclui-se que o acesso direto ao banco de dados amplia a autonomia analítica do Engenheiro de Produção, melhora a qualidade das análises e fortalece sua atuação estratégica nas organizações.

Palavras-chave: Banco de Dados, Engenharia de Produção, Sistemas de Informação.

1. Introdução

A atuação do Engenheiro de Produção está diretamente relacionada à tomada de decisão em sistemas complexos (ABEPRO, 2018). Em termos conceituais, decidir implica transformar dados brutos em informação e, posteriormente, em conhecimento aplicável — ciclo que depende fundamentalmente da qualidade e da fidedignidade das informações utilizadas (DAVENPORT; PRUSAK, 1998; SIMON, 1996). No contexto da Indústria 4.0, caracterizada pela integração entre sistemas físicos e digitais, IoT e big data, emerge a necessidade de autonomia analítica do engenheiro: a capacidade de acessar, manipular e interpretar dados sem dependência excessiva de intermediários organizacionais (SCHWAB, 2016; KAGERMANN; WAHLSTER; HELBIG, 2013).

Na prática, entretanto, os dados raramente chegam ao engenheiro em estado bruto. Eles percorrem camadas intermediárias — relatórios, dashboards e planilhas — que introduzem três problemas fundamentais: filtragem prévia das variáveis, limitando o escopo analítico; defasagem temporal, pois relatórios representam o passado e não o estado atual do sistema; e agregação excessiva, resultando em perda de granularidade (KIMBALL; ROSS, 2013; INMON, 2005). Somado a isso, a dependência de TI para extração de dados cria um gargalo operacional: cada nova pergunta exige um novo ciclo de solicitação, reduzindo a agilidade decisória (SLACK; CHAMBERS; JOHNSTON, 2009).

O acesso direto ao banco de dados reposiciona o engenheiro dentro do sistema decisório. O banco de dados é a fonte primária da verdade operacional — onde os dados são armazenados com integridade, rastreabilidade e atualidade (DATE, 2004; ELMASRI; NAVATHE, 2018). Ao operar diretamente sobre essa fonte, o EP controla o nível de detalhe da análise, garante a atualidade das informações e reduz dependências organizacionais. O argumento central deste trabalho é que o engenheiro que depende exclusivamente de relatórios possui autonomia analítica limitada, ao passo que aquele que acessa diretamente o banco de dados detém maior controle sobre a qualidade e integridade das informações (TURBAN; SHARDA; DELEN, 2014; MCAFEE; BRYNJOLFSSON, 2012). Em um ambiente competitivo orientado por dados, essa diferença não é apenas técnica, é estratégica.

2. Revisão Bibliográfica

2.1 Sistema de Informação Gerencial (SIG)

Um Sistema de Informação Gerencial (SIG) é um processo de transformação de dados em informações utilizadas na estrutura decisória da organização, sustentando administrativamente a otimização dos resultados esperados (OLIVEIRA, 2014). Sua lógica não está centrada na tecnologia isoladamente, mas na qualidade do fluxo informacional que conecta o subsistema de informação ao subsistema de decisão e, por consequência, ao subsistema de ação — estruturado de forma integrada, planejado e modularizado para evitar ilhas de automação.

A base desse funcionamento está na distinção entre dado, informação e conhecimento. Dado representa uma coleção de fatos objetivos relativos a eventos, sem interpretação ou base sustentável para a tomada de ação; informação é o dado organizado dentro de um contexto, com finalidade de proporcionar mudança em quem a recebe; e conhecimento é gerado a partir da análise da informação, capaz de reduzir incertezas e orientar ações (DAVENPORT; PRUSAK, 1998). Em ambientes industriais, essa distinção é concreta: sensores captam valores numéricos, relatórios transformam esses valores em informações e algoritmos preditivos identificam padrões de degradação, gerando conhecimento que antecipa falhas. O ciclo abaixo (representado na figura 1), ganha criticidade na Indústria 4.0, onde dados em tempo real permitem que o Engenheiro de Produção atue em decisões táticas e estratégicas.

Figura 1: Processo de transformação de dados em decisões.



Fonte: Autores

Os tipos de sistemas de informação exercem papéis complementares nesse fluxo. O TPS registra transações operacionais em tempo real, constituindo a base de dados do sistema produtivo. O MIS transforma esses registros em relatórios gerenciais e indicadores de desempenho. O DSS aplica modelos analíticos para apoiar decisões complexas. O ERP integra todos esses sistemas em uma única plataforma, sustentada por um banco de dados central que garante consistência, modularidade e governança (OLIVEIRA, 2014; STAIR; REYNOLDS, 2011).

Sob a ótica do pensamento sistêmico, o fluxo de dados na produção segue o padrão apresentado na Figura 2:

Figura 2: Fluxo de transformação de dados do sensor a ação concreta.



Fonte: Autores

Assim, produção, qualidade, logística e financeiro compartilham a mesma base de dados integrada, a falha de um subsistema no fornecimento correto de dados compromete toda a cadeia decisória (OLIVEIRA, 2014).

Nesse contexto, a governança de TI torna-se elemento estruturante. Ela estabelece políticas, controles e responsabilidades sobre o uso dos dados organizacionais, garantindo integridade, segurança e rastreabilidade (ISACA, 2019). Um mecanismo central dessa governança é o audit trail, trilha de auditoria que registra todo acesso ou modificação no banco de dados com data, hora e autoria, permitindo identificar ações prejudiciais internas ou externas, intencionais ou não (RORATTO; DIAS, 2014). Enquanto planilhas compartilhadas não oferecem garantias de integridade ou autoria, o banco de dados corporativo mantém histórico completo e auditável, posicionando o EP em um ambiente controlado e confiável para análises críticas.

2.2 Arquitetura de Software

Na prática industrial, o EP não desenvolve sistemas, mas opera dentro deles e depende da extração correta de dados para analisar processos e sustentar decisões. Compreender a arquitetura de software é, portanto, uma competência funcional do engenheiro: a forma como o sistema é arquitetado determina onde o dado está armazenado, como é estruturado e por quais caminhos pode ser acessado (ROCHA, 2018).

A arquitetura em camadas organiza o sistema em três níveis: a camada de apresentação, composta por interfaces, relatórios e dashboards; a camada de lógica de negócio, que contém as regras operacionais como OEE, MRP e controle de estoque; e a camada de dados, onde reside o banco de dados com tabelas, coleções e registros que armazenam o estado real da operação. Essa separação garante manutenção facilitada, segurança e escalabilidade — e posiciona o EP estrategicamente, pois permite acesso direto à camada de dados sem dependência da camada de apresentação (VALENTE, 2022).

No padrão MVC, o Model representa os dados e as regras de acesso ao banco, a View é o que o usuário visualiza e o Controller faz a intermediação entre ambos (VALENTE, 2022). Em

um sistema de ordens de produção, as tabelas que armazenam as ordens são o Model, a tela do operador é a View e a regra que valida a abertura da ordem é o Controller. O EP que acessa o banco diretamente opera no nível do Model, sem as limitações impostas pela interface (ROCHA, 2018).

Na perspectiva da Clean Architecture, proposta por Martin (2018), o banco de dados é um detalhe de infraestrutura desacoplado da lógica de negócio — a empresa pode substituir a tecnologia de armazenamento sem reescrever as regras operacionais, pois a regra de negócio deve ser separada do banco de dados por uma interface. Dessa forma, o banco de dados funciona como a memória da manufatura: acessá-lo diretamente proporciona maior velocidade, granularidade e autonomia analítica do que qualquer interface intermediária.

2.3 Bancos de Dados

Na década de 1960, os dados eram organizados em modelos hierárquicos como o IBM IMS, com estrutura rígida e pouca flexibilidade analítica. Em 1970, Edgar F. Codd propôs o modelo relacional — dados em tabelas fundamentadas na álgebra relacional — eliminando a dependência da estrutura física e permitindo consultas declarativas. Nas décadas de 1980 e 1990, a consolidação do SQL impulsionou soluções como Oracle, PostgreSQL e MySQL, sobre as quais os ERPs industriais foram construídos. A partir dos anos 2000, limitações de escalabilidade horizontal do modelo relacional impulsionaram o movimento NoSQL, com MongoDB, Apache Cassandra e Redis. Após 2010, consolida-se o conceito de polyglot persistence: diferentes tipos de bancos coexistem na mesma organização, cada um escolhido conforme a natureza do problema (SADALAGE; FOWLER, 2013).

O banco relacional organiza dados em tabelas com chave primária e chaves estrangeiras que estabelecem relacionamentos entre entidades, permitindo consultas via SELECT, JOIN e GROUP BY. Opera sob as propriedades ACID — atomicidade, consistência, isolamento e durabilidade — que garantem integridade transacional (ELMASRI; NAVATHE, 2018). No contexto do EP, isso se materializa nas tabelas de ordens de produção, estoque, fornecedores e funcionários do ERP.

Os bancos NoSQL atendem cenários com alto volume, estrutura variável e necessidade de escalabilidade horizontal. Bancos documentais como MongoDB armazenam dados em JSON com estrutura flexível; bancos colunares como Cassandra são otimizados para séries temporais e escrita massiva; bancos chave-valor como Redis permitem acesso ultrarrápido em cache. Operam sob o princípio BASE — disponibilidade, estado suave e consistência eventual (SADALAGE; FOWLER, 2013). No EP, aplicam-se ao armazenamento de dados de sensores

IoT, logs de máquinas e telemetria industrial.

A escolha entre relacional e NoSQL depende da estrutura do dado, volume, frequência de acesso e necessidade de consistência. Processos transacionais como estoque e ordens de produção permanecem no relacional. Dados de monitoramento contínuo beneficiam-se do NoSQL. Em muitas organizações industriais, aplica-se polyglot persistence: PostgreSQL para dados transacionais e Cassandra para séries temporais (SADALAGE; FOWLER, 2013).

A confiabilidade desses dados é garantida pela normalização. Na 1FN, cada célula contém um único valor atômico. Na 2FN, todo atributo não-chave depende da chave primária completa. Na 3FN, nenhum atributo não-chave depende de outro atributo não-chave. Esse processo elimina redundâncias e garante que o dado extraído pelo EP represente fielmente a operação (DATE, 2015; ELMASRI; NAVATHE, 2018).

Os relacionamentos entre entidades seguem padrões definidos: 1:1 entre funcionário e crachá; 1:N entre setor e funcionários; N:M entre produto e fornecedor, exigindo tabela associativa (HEUSER, 2009). Quanto à dependência estrutural, na agregação as partes existem independentemente do todo, como fornecedor e pedido de compra; na composição as partes não existem sem o todo, como ordem de produção e seus itens, implementada com ON DELETE CASCADE no relacional ou documentos embutidos no NoSQL (ELMASRI; NAVATHE, 2018).

O acesso a esses dados segue um procedimento técnico padronizado: conexão via string contendo servidor, porta, banco, usuário e senha; execução da consulta; carregamento do resultado; encerramento da conexão. Em ambiente analítico, bibliotecas Python como psycopg2, mysql-connector e pymongo, integradas ao pandas via read_sql, estruturam a extração dos dados (ELMASRI; NAVATHE, 2018). A título de exemplo, em um banco PostgreSQL essa conexão é estabelecida da seguinte forma:

```
import os
import psycopg2
import pandas as pd
conexao = psycopg2.connect(
    host=os.environ["DB_HOST"],
    port=5432,
    dbname=os.environ["DB_NAME"],
    user=os.environ["DB_USER"],
```


```
password=os.environ["DB_PASSWORD"]
)
df = pd.read_sql("SELECT * FROM producao.ordens_producao WHERE
status = 'aberta';", conexao) conexao.close()
```

2.4 Modelagem de Dados do Cenário Logístico

Para exemplificar a aplicação dos conceitos de modelagem de dados em um contexto real de Engenharia de Produção, foi analisado um cenário operacional de logística e supply chain. Nesse ambiente, as informações são organizadas em quatro entidades principais: **Viagem**, responsável pelo registro das operações logísticas; **Transporte**, que representa os diferentes segmentos de uma viagem; **Filial**, relacionada às unidades operacionais da empresa; e **Veículo**, que identifica os recursos utilizados na execução do transporte.

A estrutura proposta permite representar de forma organizada as relações existentes entre os elementos da operação. Uma filial pode estar associada a diversas viagens, enquanto cada viagem pode conter um ou mais transportes. Por sua vez, cada transporte é vinculado a um veículo específico. A Figura 03 apresenta essa estrutura por meio de um diagrama entidade-relacionamento.

Figura 03: Diagrama entidade-relacionamento do cenário logístico.



Fonte: Autores.

A organização dos dados segue os princípios de normalização, buscando reduzir redundâncias e preservar a consistência das informações. Dessa forma, atributos relacionados ao transporte são mantidos em uma entidade própria, evitando duplicidades e facilitando a manutenção dos registros. Da mesma maneira, as informações das filiais são armazenadas separadamente, permitindo que sejam reutilizadas em diferentes operações sem repetição desnecessária de dados.

Essa modelagem garante maior integridade ao banco de dados e facilita consultas operacionais, possibilitando rastrear viagens, veículos e unidades envolvidas em cada operação logística. Além disso, fornece uma base estruturada para a geração de indicadores e análises gerenciais, apoiando atividades de monitoramento, planejamento e tomada de decisão.

Embora as análises apresentadas posteriormente utilizem um modelo dimensional voltado ao ambiente analítico, a estrutura transacional descrita nesta seção permanece fundamental, pois representa a origem dos dados e assegurar sua consistência antes das etapas de tratamento, consolidação e visualização.

2.4.1 Agregação e Composição no Cenário Logístico

Além dos relacionamentos tradicionais entre entidades, o modelo logístico também permite identificar estruturas de agregação e composição. Na agregação, as entidades mantêm sua existência independentemente do relacionamento estabelecido. Esse comportamento pode ser observado entre as entidades **Filial** e **Viagem**, uma vez que uma filial continua existindo mesmo que não possua viagens registradas em determinado período. De forma semelhante, a entidade **Veículo** existe independentemente dos transportes aos quais esteja associada, podendo permanecer cadastrada mesmo sem participação em operações ativas.

Ademais, a composição caracteriza relações em que a existência de uma entidade depende diretamente de outra. No modelo proposto, essa situação ocorre entre **Viagem** e **Transporte**. Os registros de transporte representam segmentos operacionais de uma viagem e não possuem significado isoladamente fora desse contexto. Dessa forma, a exclusão de uma viagem implica também a remoção dos transportes a ela vinculados, caracterizando uma relação de composição.

A identificação dessas estruturas contribui para a correta modelagem dos dados e para a preservação da integridade das informações operacionais, garantindo que os relacionamentos reflitam adequadamente as regras de negócio presentes no processo logístico.

3. Metodologia

Este trabalho adota como procedimento metodológico a conexão direta ao ambiente corporativo de dados para extração e análise de informações operacionais de logística e supply chain, executada pelos autores em contexto de estágio supervisionado.

A plataforma utilizada é o Databricks, solução corporativa construída sobre Apache Spark com Delta Lake como camada de armazenamento. Essa arquitetura combina propriedades ACID com escalabilidade distribuída, sendo a fonte primária de dados operacionais da organização. O acesso direto à plataforma elimina intermediários como relatórios exportados ou planilhas agregadas, garantindo granularidade, atualidade e rastreabilidade dos dados extraídos, condições essenciais para análise confiável em Engenharia de Produção.

Embora o Databricks não conste isoladamente entre os SGBDs estudados na disciplina (PostgreSQL, MySQL, MongoDB, Cassandra), sua adoção neste trabalho justifica-se por se tratar do ambiente corporativo efetivamente disponível aos autores no contexto do estágio supervisionado, conforme previsto, quanto à possibilidade de uso do banco real da empresa em que os autores estão inseridos. Tecnicamente, o vínculo com os conteúdos da disciplina permanece: o motor subjacente ao Delta Lake organiza os dados em tabelas acessadas por SQL declarativo (SELECT, WHERE, JOIN, GROUP BY) e preserva as propriedades ACID, os mesmos fundamentos do modelo relacional discutidos na seção 2.3, ainda que sobre uma camada de armazenamento distribuída construída sobre o Apache Spark, distinta da arquitetura monolítica de SGBDs relacionais tradicionais como PostgreSQL e MySQL.

O procedimento será executado em cinco etapas sequenciais: conexão ao workspace Databricks via credencial corporativa; mapeamento das tabelas e esquemas disponíveis no Delta Lake relacionados à operação logística; extração dos dados por meio de queries SQL nativas no ambiente de notebook; transformação dos resultados em DataFrame pandas para geração de indicadores operacionais; e interpretação dos indicadores conforme o ciclo dado de informação, conhecimento, decisão fundamentado na seção anterior.

Os indicadores planejados para extração cobrem disponibilidade de frota, ociosidade, quebras e volume tático. Todo o código, queries e outputs serão versionados no repositório GitHub da turma, garantindo reprodutibilidade e rastreabilidade do procedimento. Dados pessoais serão anonimizados em conformidade com a LGPD, e credenciais de acesso não serão expostas no código.

4. Resultados e Discussões


4.1 Extração dos Dados via Databricks

A extração dos dados foi realizada diretamente no ambiente Databricks, utilizando SQL nativo sobre a camada lakehouse do Delta Lake. O procedimento seguiu as etapas definidas na metodologia: conexão ao workspace via credencial corporativa, identificação das tabelas no catálogo “lakehouse.logistica”, execução das queries e exportação dos resultados para modelagem no Power Query.

Foram utilizadas duas queries. A query principal extrai os registros consolidados de viagens da tabela “onelog_viagem_consolidado”, aplicando filtros por ano, mês, regional e unidades operacionais. A coluna “data_fim_viagem” foi formatada para o padrão brasileiro via função “date_format”, e o campo “numero_viagem” foi convertido para inteiro via CAST, garantindo compatibilidade com o modelo de dados no Power BI.

No workspace do Databricks, o acesso parte do menu Catalog, onde se localiza o catálogo lakehouse e o schema logistica; a partir da tabela onelog_viagem_consolidado, abre-se um notebook anexado ao cluster de computação do workspace, no qual a query SQL é escrita e executada em uma célula do tipo %sql, com o resultado renderizado automaticamente em formato tabular, como ilustrado na Figura 04.

Figura 04: Query no Databricks.



```
SELECT *,
    date_format(data_fim_viagem, 'dd/MM/yyyy') AS Data_Fim,
    CAST(numero_viagem AS BIGINT) AS Transporte
FROM lakehouse.logistica.onelog_viagem_consolidado
WHERE ano = '2026'
AND mes IN ( '05')
AND regional = 'RG-SE/CO'
AND unidade IN ( 'CD APG',
    'CD BRASILIA',
    'CD CUIABA',
    'TSP CAMPO GRANDE',
    'TSP TOCANTINS')
```


s	dia	numero_viagem	numero_multitransporte	tipo_operacao	regional	unidade	placa	transportadora
	01	0131748607	null	Distribuição	RG-SE/CO	TSP CAMPO GRANDE	FE4J58	PEGORARO TRANSI
	01	0131748608	null	Distribuição	RG-SE/CO	TSP CAMPO GRANDE	NRZ1255	PEGORARO TRANSI

Fonte: Autores

A query complementar extraiu a tabela de apoio filial, utilizada para enriquecer o modelo com

informações de localização e expedição por unidade da regional:

Figura 4 : Query no Databricks.



The screenshot shows a Databricks SQL query editor with a dark theme. At the top, there are buttons for 'Run all (1000)', 'Just now (<1s)', 'lakehouse', 'acessos', 'New SQL editor: ON', and a refresh icon. The SQL query is as follows:

```
1 select
2   lexp,
3   local_expedicao,
4   regional
5   from `lakehouse`.`logistica`.`apoio_filial`
6   WHERE local_expedicao IN ('CD APG', 'CD BRASILIA', 'CD CUIABA', 'TSP TOCANTINS', 'TSP CAMPO GRANDE')
```

Below the query, there is a table with 5 rows and 4 columns. The columns are labeled 'lexp', 'local_expedicao', and 'regional'. The first column is unlabeled but contains row numbers 1 through 5.


	lexp	local_expedicao	regional
1	1117	CD APG	RG-SUDOESTE
2	1400	CD BRASILIA	RG-SUDOESTE
3	1409	CD CUIABA	RG-SUDOESTE
4	1427	TSP TOCANTINS	RG-SUDOESTE
5	1633	TSP CAMPO GRANDE	RG-SUDOESTE

Fonte: Autores

4.2 Modelagem no Power Query

Os dados extraídos do Databricks foram importados no Power BI via conector nativo, e a modelagem foi realizada no Power Query. As etapas aplicadas compreenderam: padronização de tipos de dados, com conversão de campos de data e inteiros conforme os tipos definidos nas queries; tratamento de valores nulos no campo numero_multitransporte, identificados na extração e mantidos como nulos controlados para não distorcer contagens de viagem; e estabelecimento dos relacionamentos entre as tabelas conforme o modelo dimensional apresentado na Figura 04, composto pelas tabelas Diarias_D-1, DIMFILIAL, Frota, Calendário, Onelog_consolidado, Z060584, Tático e Ociosos.

Figura 4: Relacionamentos no power query.



Fonte: Autores

O modelo resultante segue a arquitetura star schema, com a tabela Diarias_D-1 como fato central e as demais como dimensões, permitindo consultas analíticas segmentadas por filial, período, tipo de veículo e transportadora.

4.3 Indicadores Gerados e Análise

A partir do modelo construído, foram desenvolvidos dois painéis analíticos com finalidades distintas e complementares: um painel operacional voltado à tomada de decisão no dia, e um painel histórico voltado à análise do comportamento da frota ao longo do mês.

Figura 5: Painel de previsibilidade de retorno diário.

Previsibilidade de Retorno												
Unidade		Em Viagem-41										
CD APG		Ter	Qua	Qui	Sex	Sáb	Dom	Seg	Ter	Qua	Qui	Sex
Em Andamento		#####	#####	28/05/2026	#####	#####	#####	#####	#####	03/06/2026	#####	#####
		lead-1	lead-2	lead-3	lead-4	lead-5	lead-6	lead-7	lead-8	lead-9	lead-10	lead-11
84		35	28	13	0	0	0	0	0	0	0	0
Total		Tático										
220			78	33	39	36	34					
EM ANDAMENTO				FINALIZADAS								
Diárias D-1		Comerci	Logístic	Transporta	Diárias D-1		Comerci	Logístic	Transporta			
10		3	6	1	2		0	2	0			
Média Diária s	9	Ociosidade	2		Quebrados	9						
Estimativa de veículos previstos para retorno hoje: 39.												

Fonte: Autores


O primeiro painel tem como objetivo central responder à pergunta operacional do dia: quantos veículos estão disponíveis para novas saídas? Para isso, o painel consolida em tempo real os veículos em viagem, distribuídos por lead time de retorno — indicando em quantos dias úteis cada grupo de veículos está previsto para retornar à unidade. Os indicadores apresentados são:

- Veículos em andamento: contagem de viagens ativas por unidade, com distinção entre viagens de distribuição simples e operações multitransporte, identificadas pelo preenchimento do campo numero_multitransporte
- Estimativa de retorno por lead time: distribuição dos veículos em viagem pelos dias úteis seguintes, permitindo ao gestor antecipar a disponibilidade de frota e planejar novas operações sem gerar ociosidade ou ruptura
- Veículos ociosos do dia: quantidade de veículos disponíveis sem viagem ativa por filial, cruzados com a dimensão DIMFILIAL
- Veículos quebrados do dia: ocorrências registradas que indisponibilizam veículos, extraídas da tabela Z060584, originada do sistema SAP
- Volume tático: comparativo entre a quantidade de viagens planejadas e executadas por unidade, extraído da tabela Tático

Esse painel traduz diretamente o ciclo SIG aplicado à operação: o dado bruto de status de viagem extraído do Databricks é transformado em informação de disponibilidade de frota,

gerando conhecimento que sustenta a decisão de quantas e quais saídas podem ser programadas para o dia.

Figura 6: Painel de utilização de frota.



Fonte: Autores

O segundo painel apresenta o comportamento consolidado da frota ao longo do mês, sob múltiplas perspectivas de utilização. Os indicadores apresentados são:

- Qtde de frota por tipo: distribuição dos veículos entre frota própria, mista, NES e spot, permitindo avaliar a composição operacional da regional;
- Ociosos por semana: evolução semanal dos veículos disponíveis sem utilização, evidenciando períodos de subutilização da frota;
- Bloqueados por semana: veículos impedidos de operar por razões administrativas ou regulatórias, segmentados semanalmente;
- Fixo indisponível por semana: frota fixa fora de operação por outros impedimentos
- Improdutivos por semana: veículos que não performaram conforme o planejado por omissão do transportador;
- Viagem GDL por semana: volume de diárias criadas no GDL, com série histórica semanal;
- Complementar Spot por semana: utilização de frota spot como complemento à frota fixa, indicando pressão de demanda acima da capacidade própria;
- Quebrados por semana: evolução semanal das ocorrências de quebra, permitindo identificar padrões de falha recorrente por período.

A partir das observações, podemos concluir que o Painel de previsibilidade opera na dimensão do tempo real e suporta decisões imediatas, enquanto o Painel de utilização de frota opera na dimensão histórica e suporta decisões táticas e estratégicas, como renegociação de contratos de frota, identificação de períodos críticos de manutenção e avaliação da eficiência operacional da regional ao longo do mês.

Assim sendo, o conjunto dos dois painéis completa o ciclo proposto na fundamentação

teórica: os dados brutos extraídos do Databricks foram transformados em informação gerencial estruturada, gerando conhecimento operacional que sustenta tanto decisões imediatas de planejamento de frota quanto decisões táticas de gestão da utilização de veículos na regional CO.

5. Conclusão

Este trabalho demonstrou, de forma estruturada e reproduzível, que o Engenheiro de Produção é capaz de executar autonomamente o ciclo completo de transformação de dados operacionais em conhecimento gerencial aplicável. O procedimento foi executado em etapas sequenciais de extração via SQL no Databricks, modelagem no Power Query e geração de indicadores no Power BI, completando o ciclo dado → informação → conhecimento → decisão que foi proposto na fundamentação teórica e documentado na forma de um Procedimento Operacional Padrão.

Os resultados obtidos demonstram que o acesso direto ao banco de dados confere ao engenheiro granularidade, atualidade e controle sobre a análise, condições impossíveis de garantir por meio de relatórios intermediários. Os dois painéis desenvolvidos evidenciam essa distinção de forma concreta: o Painel de Previsibilidade operacionaliza a decisão diária de disponibilidade de frota, respondendo em tempo real quantos veículos estão aptos para largada, já o Painel de Utilização da Frota fornece a visão histórica mensal da operação, permitindo identificar padrões de ociosidade, improdutividade e quebras recorrentes que sustentam decisões táticas e estratégicas de gestão da regional CO.

Do ponto de vista metodológico, o POP desenvolvido é repetível, auditável e transferível. As queries documentadas, o modelo dimensional construído e os painéis gerados constituem um procedimento padronizado que qualquer profissional com acesso ao ambiente Databricks da organização consegue reproduzir e atualizar.

6. Referências

ABEPRO – ASSOCIAÇÃO BRASILEIRA DE ENGENHARIA DE PRODUÇÃO. Áreas e sub-áreas de Engenharia de Produção. [S. l.]: ABEPRO, 2018. Disponível em: <https://portal.abepro.org.br/abepro2024/profissao/>. Acesso em: 30 abr. 2025.

DATE, C. J. Introdução a sistemas de bancos de dados. 8. ed. Rio de Janeiro: Elsevier, 2004.

DATE, C. J. Projeto de banco de dados e teoria relacional: formas normais e tudo mais. 1. ed. São Paulo: Novatec, 2015.

DAVENPORT, T. H.; PRUSAK, L. Conhecimento empresarial: como as organizações gerenciam o seu capital intelectual. Rio de Janeiro: Campus, 1998.

ELMASRI, R.; NAVATHE, S. B. Sistemas de banco de dados. 7. ed. São Paulo: Pearson, 2018.

HEUSER, C. A. Projeto de banco de dados. 6. ed. Porto Alegre: Bookman, 2009.

INMON, W. H. Building the data warehouse. 4. ed. Indianapolis: Wiley, 2005.

ISACA. COBIT 2019 Framework: Introduction and Methodology. Rolling Meadows: ISACA, 2019.

KAGERMANN, H.; WAHLSTER, W.; HELBIG, J. Recommendations for implementing the strategic initiative Industrie 4.0: final report of the Industrie 4.0 Working Group. Berlin: Acatech – National Academy of Science and Engineering, 2013. Disponível em: <https://en.acatech.de/publication/recommendations-for-implementing-the-strategic-initiative-in-industrie-4-0-final-report-of-the-industrie-4-0-working-group/>. Acesso em: 30 abr. 2026.

KIMBALL, R.; ROSS, M. The data warehouse toolkit: the definitive guide to dimensional modeling. 3. ed. Indianapolis: Wiley, 2013.

MARTIN, R. C. Arquitetura limpa: o guia do artesão para estrutura e design de software. São Paulo: Alta Books, 2018.

MCAFEE, A.; BRYNJOLFSSON, E. Big data: the management revolution. Harvard Business Review, Boston, v. 90, n. 10, p. 60-68, out. 2012.

OLIVEIRA, D. P. R. Sistemas de informações gerenciais: estratégicas, táticas, operacionais. 16. ed. São Paulo: Atlas, 2014.

ROCHA, J. G. Arquitetura em camadas com uso do paradigma MVC e processo unificado na programação de software orientado a objetos. Revista Tecnologias em Projeção, v. 9, n. 1, p. 32–42, 2018.

RORATTO, R.; DIAS, E. D. Security information in production and operations: a study on audit trails in database systems. Journal of Information Systems and Technology Management, v. 11, n. 3, p. 717–734, 2014. DOI: 10.4301/S1807-17752014000300010.

SADALAGE, P. J.; FOWLER, M. NoSQL distilled: a brief guide to the emerging world of polyglot persistence. Upper Saddle River: Addison-Wesley, 2013.

SCHWAB, K. A quarta revolução industrial. Tradução de Daniel Moreira Miranda. São Paulo: Edipro, 2016.

SIMON, H. A. The sciences of the artificial. 3. ed. Cambridge: MIT Press, 1996.

SLACK, N.; CHAMBERS, S.; JOHNSTON, R. Administração da produção. 3. ed. São Paulo: Atlas, 2009.

STAIR, R. M.; REYNOLDS, G. W. Princípios de sistemas de informação. 9. ed. São Paulo: Cengage Learning, 2011.

TURBAN, E.; SHARDA, R.; DELEN, D. Business intelligence e análise de dados para gestão do negócio. 3. ed. Porto Alegre: Bookman, 2014.

VALENTE, M. T. Engenharia de software moderna: princípios e práticas para desenvolvimento de software com produtividade. Belo Horizonte: [s.n.], 2022. Disponível em: <https://engsoftmoderna.info>. Acesso em: mai. 2026.