

POP para Acesso a Dados em Engenharia de Produção

Lavínia Mosquem Padilha da Silva (UFG)
Odilon Ribeiro Pimentel (UFG)

Este trabalho analisa a importância do acesso direto a bancos de dados pelo Engenheiro de Produção como fator estratégico para a tomada de decisão em ambientes orientados por dados. Discute-se como a dependência exclusiva de relatórios e dashboards limita a autonomia analítica, reduz a granularidade das informações e compromete a agilidade decisória. A pesquisa fundamenta-se em conceitos de Sistemas de Informação Gerencial, arquitetura de software e bancos de dados relacionais e não relacionais. Metodologicamente, propõe-se a extração e análise de dados operacionais em ambiente corporativo utilizando Databricks, SQL e Python para geração de indicadores logísticos. Conclui-se que o acesso direto ao banco de dados amplia a autonomia analítica do Engenheiro de Produção, melhora a qualidade das análises e fortalece sua atuação estratégica nas organizações.

Palavras-chave: Banco de Dados, Engenharia de Produção, Sistemas de Informação.

1. Introdução

A atuação do Engenheiro de Produção está diretamente relacionada à tomada de decisão em sistemas complexos (ABEPRO, 2018). Em termos conceituais, decidir implica transformar dados brutos em informação e, posteriormente, em conhecimento aplicável — ciclo que depende fundamentalmente da qualidade e da fidedignidade das informações utilizadas (DAVENPORT; PRUSAK, 1998; SIMON, 1996). No contexto da Indústria 4.0, caracterizada pela integração entre sistemas físicos e digitais, IoT e big data, emerge a necessidade de autonomia analítica do engenheiro: a capacidade de acessar, manipular e interpretar dados sem dependência excessiva de intermediários organizacionais (SCHWAB, 2016; KAGERMANN; WAHLSTER; HELBIG, 2013).

Na prática, entretanto, os dados raramente chegam ao engenheiro em estado bruto. Eles percorrem camadas intermediárias — relatórios, dashboards e planilhas — que introduzem três problemas fundamentais: filtragem prévia das variáveis, limitando o escopo analítico; defasagem temporal, pois relatórios representam o passado e não o estado atual do sistema; e agregação excessiva, resultando em perda de granularidade (KIMBALL; ROSS, 2013; INMON, 2005). Somado a isso, a dependência de TI para extração de dados cria um gargalo operacional: cada nova pergunta exige um novo ciclo de solicitação, reduzindo a agilidade decisória (SLACK; CHAMBERS; JOHNSTON, 2009).

O acesso direto ao banco de dados reposiciona o engenheiro dentro do sistema decisório. O banco de dados é a fonte primária da verdade operacional — onde os dados são armazenados com integridade, rastreabilidade e atualidade (DATE, 2004; ELMASRI; NAVATHE, 2016). Ao operar diretamente sobre essa fonte, o EP controla o nível de detalhe da análise, garante a atualidade das informações e reduz dependências organizacionais. O argumento central deste trabalho é que o engenheiro que depende exclusivamente de relatórios possui autonomia analítica limitada, ao passo que aquele que acessa diretamente o banco de dados detém maior controle sobre a qualidade e integridade das informações (TURBAN; SHARDA; DELEN, 2014; MCAFEE; BRYNJOLFSSON, 2012). Em um ambiente competitivo orientado por dados, essa diferença não é apenas técnica — é estratégica.

2. Revisão Bibliográfica

2.1 Sistema de Informação Gerencial (SIG)

Um Sistema de Informação Gerencial (SIG) é um processo de transformação de dados em informações utilizadas na estrutura decisória da organização, sustentando administrativamente a otimização dos resultados esperados (OLIVEIRA, 2014). Sua lógica não está centrada na tecnologia isoladamente, mas na qualidade do fluxo informacional que conecta o subsistema de informação ao subsistema de decisão e, por consequência, ao subsistema de ação — estruturado de forma integrada, planejado e modularizado para evitar ilhas de automação.

A base desse funcionamento está na distinção entre dado, informação e conhecimento. Dado representa uma coleção de fatos objetivos relativos a eventos, sem interpretação ou base sustentável para a tomada de ação; informação é o dado organizado dentro de um contexto, com finalidade de proporcionar mudança em quem a recebe; e conhecimento é gerado a partir da análise da informação, capaz de reduzir incertezas e orientar ações (DAVENPORT; PRUSAK, 1998). Em ambientes industriais, essa distinção é concreta: sensores captam valores numéricos, relatórios transformam esses valores em informações e algoritmos preditivos identificam padrões de degradação, gerando conhecimento que antecipa falhas. O ciclo abaixo, ganha criticidade na Indústria 4.0, onde dados em tempo real permitem que o Engenheiro de Produção atue em decisões táticas e estratégicas.



Os tipos de sistemas de informação exercem papéis complementares nesse fluxo. O TPS registra transações operacionais em tempo real, constituindo a base de dados do sistema produtivo. O MIS transforma esses registros em relatórios gerenciais e indicadores de desempenho. O DSS aplica modelos analíticos para apoiar decisões complexas. O ERP integra todos esses sistemas em uma única plataforma, sustentada por um banco de dados central que garante consistência, modularidade e governança (OLIVEIRA, 2014; STAIR; REYNOLDS, 2011).

Sob a ótica do pensamento sistêmico, o fluxo de dados na produção segue o padrão:



Assim, produção, qualidade, logística e financeiro compartilham a mesma base de dados integrada — a falha de um subsistema no fornecimento correto de dados compromete toda a cadeia decisória (OLIVEIRA, 2014).

Nesse contexto, a governança de TI torna-se elemento estruturante. Ela estabelece políticas, controles e responsabilidades sobre o uso dos dados organizacionais, garantindo integridade, segurança e rastreabilidade (ISACA, 2019). Um mecanismo central dessa governança é o audit trail — trilha de auditoria que registra todo acesso ou modificação no banco de dados com data, hora e autoria, permitindo identificar ações prejudiciais internas ou externas, intencionais ou não (RORATTO; DIAS, 2014). Enquanto planilhas compartilhadas não oferecem garantias de integridade ou autoria, o banco de dados corporativo mantém histórico completo e auditável, posicionando o EP em um ambiente controlado e confiável para análises críticas.

2.2 Arquitetura de Software

Na prática industrial, o EP não desenvolve sistemas, mas opera dentro deles e depende da extração correta de dados para analisar processos e sustentar decisões. Compreender a arquitetura de software é, portanto, uma competência funcional do engenheiro: a forma como o sistema é arquitetado determina onde o dado está armazenado, como é estruturado e por quais caminhos pode ser acessado (ROCHA, 2018).

A arquitetura em camadas organiza o sistema em três níveis: a camada de apresentação, composta por interfaces, relatórios e dashboards; a camada de lógica de negócio, que contém as regras operacionais como OEE, MRP e controle de estoque; e a camada de dados, onde reside o banco de dados com tabelas, coleções e registros que armazenam o estado real da operação. Essa separação garante manutenção facilitada, segurança e escalabilidade — e posiciona o EP estrategicamente, pois permite acesso direto à camada de dados sem dependência da camada de apresentação (VALENTE, 2022).

No padrão MVC, o Model representa os dados e as regras de acesso ao banco, a View é o que o usuário visualiza e o Controller faz a intermediação entre ambos (VALENTE, 2022). Em um sistema de ordens de produção, as tabelas que

armazenam as ordens são o Model, a tela do operador é a View e a regra que valida a abertura da ordem é o Controller. O EP que acessa o banco diretamente opera no nível do Model, sem as limitações impostas pela interface (ROCHA, 2018).

Na perspectiva da Clean Architecture, proposta por Martin (2018), o banco de dados é um detalhe de infraestrutura desacoplado da lógica de negócio — a empresa pode substituir a tecnologia de armazenamento sem reescrever as regras operacionais, pois a regra de negócio deve ser separada do banco de dados por uma interface. Dessa forma, o banco de dados funciona como a memória da manufatura: acessá-lo diretamente proporciona maior velocidade, granularidade e autonomia analítica do que qualquer interface intermediária.

2.3 Bancos de Dados

Na década de 1960, os dados eram organizados em modelos hierárquicos como o IBM IMS, com estrutura rígida e pouca flexibilidade analítica. Em 1970, Edgar F. Codd propôs o modelo relacional — dados em tabelas fundamentadas na álgebra relacional — eliminando a dependência da estrutura física e permitindo consultas declarativas. Nas décadas de 1980 e 1990, a consolidação do SQL impulsionou soluções como Oracle, PostgreSQL e MySQL, sobre as quais os ERPs industriais foram construídos. A partir dos anos 2000, limitações de escalabilidade horizontal do modelo relacional impulsionaram o movimento NoSQL, com MongoDB, Apache Cassandra e Redis. Após 2010, consolida-se o conceito de polyglot persistence: diferentes tipos de bancos coexistem na mesma organização, cada um escolhido conforme a natureza do problema (SADALAGE; FOWLER, 2013).

O banco relacional organiza dados em tabelas com chave primária e chaves estrangeiras que estabelecem relacionamentos entre entidades, permitindo consultas via SELECT, JOIN e GROUP BY. Opera sob as propriedades ACID — atomicidade, consistência, isolamento e durabilidade — que garantem integridade transacional (ELMASRI; NAVATHE, 2018). No contexto do EP, isso se materializa nas tabelas de ordens de produção, estoque, fornecedores e funcionários do ERP.

Os bancos NoSQL atendem cenários com alto volume, estrutura variável e necessidade de escalabilidade horizontal. Bancos documentais como MongoDB armazenam dados em JSON com estrutura flexível; bancos colunares como Cassandra são otimizados para séries temporais e escrita massiva; bancos chave-valor como Redis permitem acesso ultrarrápido em cache. Operam sob o princípio BASE — disponibilidade, estado suave e consistência eventual (SADALAGE;

FOWLER, 2013). No EP, aplicam-se ao armazenamento de dados de sensores IoT, logs de máquinas e telemetria industrial.

A escolha entre relacional e NoSQL depende da estrutura do dado, volume, frequência de acesso e necessidade de consistência. Processos transacionais como estoque e ordens de produção permanecem no relacional. Dados de monitoramento contínuo beneficiam-se do NoSQL. Em muitas organizações industriais, aplica-se polyglot persistence: PostgreSQL para dados transacionais e Cassandra para séries temporais (SADALAGE; FOWLER, 2013).

A confiabilidade desses dados é garantida pela normalização. Na 1FN, cada célula contém um único valor atômico. Na 2FN, todo atributo não-chave depende da chave primária completa. Na 3FN, nenhum atributo não-chave depende de outro atributo não-chave. Esse processo elimina redundâncias e garante que o dado extraído pelo EP represente fielmente a operação (DATE, 2015; ELMASRI; NAVATHE, 2018).

Os relacionamentos entre entidades seguem padrões definidos: 1:1 entre funcionário e crachá; 1:N entre setor e funcionários; N:M entre produto e fornecedor, exigindo tabela associativa (HEUSER, 2009). Quanto à dependência estrutural, na agregação as partes existem independentemente do todo — como fornecedor e pedido de compra; na composição as partes não existem sem o todo — como ordem de produção e seus itens, implementada com ON DELETE CASCADE no relacional ou documentos embutidos no NoSQL (ELMASRI; NAVATHE, 2018).

O acesso a esses dados segue um procedimento técnico padronizado: conexão via string contendo servidor, porta, banco, usuário e senha; execução da consulta; carregamento do resultado; encerramento da conexão. Em ambiente analítico, bibliotecas Python como psycopg2, mysql-connector e pymongo, integradas ao pandas via read_sql, estruturam a extração dos dados (ELMASRI; NAVATHE, 2018). Boas práticas exigem que credenciais não sejam expostas no código, utilizando variáveis de ambiente. Quando documentado, esse processo transforma o acesso ao banco em um POP repetível, auditável e transferível.

3. Metodologia

Este trabalho adota como procedimento metodológico a conexão direta ao ambiente corporativo de dados para extração e análise de informações operacionais de logística e supply chain, executada pelo autor em contexto de estágio supervisionado.

A plataforma utilizada é o Databricks, solução corporativa construída sobre Apache Spark com Delta Lake como camada de armazenamento. Essa arquitetura combina propriedades ACID com escalabilidade distribuída, sendo a fonte primária de dados operacionais da organização. O acesso direto à plataforma elimina intermediários como relatórios exportados ou planilhas agregadas, garantindo granularidade, atualidade e rastreabilidade dos dados extraídos, condições essenciais para análise confiável em Engenharia de Produção.

O procedimento será executado em cinco etapas sequenciais: conexão ao workspace Databricks via credencial corporativa; mapeamento das tabelas e esquemas disponíveis no Delta Lake relacionados à operação logística; extração dos dados por meio de queries SQL nativas no ambiente de notebook; transformação dos resultados em DataFrame pandas para geração de indicadores operacionais; e interpretação dos indicadores conforme o ciclo dado de informação, conhecimento, decisão fundamentado na seção anterior.

Os indicadores planejados para extração cobrem volume de ordens por período, tempo médio de entrega, taxa de cumprimento de prazo e identificação de gargalos por centro de distribuição. Todo o código, queries e outputs serão versionados no repositório GitHub da turma, garantindo reprodutibilidade e rastreabilidade do procedimento. Dados pessoais serão anonimizados em conformidade com a LGPD, e credenciais de acesso não serão expostas no código.

4. Resultados e Discussões

5. Conclusão

6. Referências

ABEPRO – ASSOCIAÇÃO BRASILEIRA DE ENGENHARIA DE PRODUÇÃO. Áreas e sub-áreas de Engenharia de Produção. [S. I.]: ABEPRO, 2018. Disponível em: <https://portal.abepro.org.br/abepro2024/profissao/>. Acesso em: 30 abr. 2025.

DATE, C. J. Introdução a sistemas de bancos de dados. 8. ed. Rio de Janeiro: Elsevier, 2004.

DATE, C. J. Projeto de banco de dados e teoria relacional: formas normais e tudo mais. 1. ed. São Paulo: Novatec, 2015.

DAVENPORT, T. H.; PRUSAK, L. Conhecimento empresarial: como as organizações

gerenciam o seu capital intelectual. Rio de Janeiro: Campus, 1998.

ELMASRI, R.; NAVATHE, S. B. Sistemas de banco de dados. 7. ed. São Paulo: Pearson, 2016.

ELMASRI, R.; NAVATHE, S. B. Sistemas de banco de dados. 7. ed. São Paulo: Pearson, 2018.

HEUSER, C. A. Projeto de banco de dados. 6. ed. Porto Alegre: Bookman, 2009.

INMON, W. H. Building the data warehouse. 4. ed. Indianapolis: Wiley, 2005.

ISACA. COBIT 2019 Framework: Introduction and Methodology. Rolling Meadows: ISACA, 2019.

KAGERMANN, H.; WAHLSTER, W.; HELBIG, J. Recommendations for implementing the strategic initiative Industrie 4.0: final report of the Industrie 4.0 Working Group. Berlin: Acatech – National Academy of Science and Engineering, 2013. Disponível em: <https://en.acatech.de/publication/recommendations-for-implementing-the-strategic-initiative-industrie-4-0-final-report-of-the-industrie-4-0-working-group/>.

Acesso em: 30 abr. 2026.

KIMBALL, R.; ROSS, M. The data warehouse toolkit: the definitive guide to dimensional modeling. 3. ed. Indianapolis: Wiley, 2013.

MARTIN, R. C. Arquitetura limpa: o guia do artesão para estrutura e design de software. São Paulo: Alta Books, 2018.

MCAFEE, A.; BRYNJOLFSSON, E. Big data: the management revolution. Harvard Business Review, Boston, v. 90, n. 10, p. 60-68, out. 2012.

OLIVEIRA, D. P. R. Sistemas de informações gerenciais: estratégicas, táticas, operacionais. 16. ed. São Paulo: Atlas, 2014.

ROCHA, J. G. Arquitetura em camadas com uso do paradigma MVC e processo unificado na programação de software orientado a objetos. Revista Tecnologias em Projeção, v. 9, n. 1, p. 32–42, 2018.

RORATTO, R.; DIAS, E. D. Security information in production and operations: a

study on audit trails in database systems. *Journal of Information Systems and Technology Management*, v. 11, n. 3, p. 717–734, 2014. DOI: 10.4301/S1807-17752014000300010.

SADALAGE, P. J.; FOWLER, M. *NoSQL distilled: a brief guide to the emerging world of polyglot persistence*. Upper Saddle River: Addison-Wesley, 2013.

SCHWAB, K. *A quarta revolução industrial*. Tradução de Daniel Moreira Miranda. São Paulo: Edipro, 2016.

SIMON, H. A. *The sciences of the artificial*. 3. ed. Cambridge: MIT Press, 1996.

SLACK, N.; CHAMBERS, S.; JOHNSTON, R. *Administração da produção*. 3. ed. São Paulo: Atlas, 2009.

STAIR, R. M.; REYNOLDS, G. W. *Princípios de sistemas de informação*. 9. ed. São Paulo: Cengage Learning, 2011.

TURBAN, E.; SHARDA, R.; DELEN, D. *Business intelligence e análise de dados para gestão do negócio*. 3. ed. Porto Alegre: Bookman, 2014.

VALENTE, M. T. *Engenharia de software moderna: princípios e práticas para desenvolvimento de software com produtividade*. Belo Horizonte: [s.n.], 2022. Disponível em: <https://engsoftmoderna.info>. Acesso em: mai. 2026.